

REPUBLIQUE DU CAMEROUN
Paix-Travail-Patrie

MINISTRE DE L'ENSEIGNEMENT
SUPERIEUR

UNIVERSITE DE DSCHANG

FACULTE DES SCIENCES

B.P.: 96 Dschang-Cameroun-Tel :
(237) 233
45 13 81
Email : udsrectorat@univ-
dschang.org



REPUBLIC OF CAMEROON
Peace-Work-Fatherland

MINISTRY OF HIGHER
EDUCATION

UNIVERSITY OF DSCHANG

FACULTY OF SCIENCE

PO BOX: 96 Dschang-Cameroun-Tel:
(237)
233 45 13 81
Email: udsrectorat@univ-
dschang.org

Projet d'Architecture des Systèmes Intelligents (IAR521)

**THEME : SUPPORT VECTOR MACHINES, RANDOM
FORESTS & EXTREME GRADIENT BOOSTING**

Niveau : MASTER 2

Option : Intelligence Artificielle

Sous la supervision de :

Pr. KENGNE TCHENDJI Vianney

Maître de Conférences, Université de Dschang

Membres du groupe 3	
LEKANE KENFACK VERGEZ	CM-UDS-21SCI0569
MBOUMEU YOUNBI AXEL AUBIN	CM-UDS-21SCI0589
MOUNCHIKPOU MEFIRE HAMED KAMAL	CM-UDS-21SCI0601
NJIH ASONYU SENGE	CM-UDS-21SCI0625

Année académique : 2025 - 2026

TABLE DES MATIÈRES

TABLE DES MATIÈRES	i
LISTE DES FIGURES	iii
LISTE DES TABLEAUX	iv
LISTE DES ABRÉVIATIONS	v
RESUME	vi
INTRODUCTION GÉNÉRALE	1
I ÉTUDE EXPÉRIMENTALE ET APPLICATION AU CAS DE LA DETECTION DU DIABETE	5
1 ETAT DE L'ART SUR LA DETECTION DU DIABETE A L'AIDE DE L'APPRENTISSAGE AUTOMATIQUE	6
1.1 Introduction	6
1.2 Approches traditionnelles de détection du diabète	8
1.3 Approches basées sur l'apprentissage automatique	8
1.4 Études comparatives utilisant SVM, Random Forest et XGBoost	9
1.4.1 Comparaisons sur la base PIDD	10
1.4.2 Comparaisons multi-algorithmes incluant XGBoost	10
1.4.3 Apport des techniques de prétraitement et d'optimisation	10
1.5 Analyse critique des travaux existants	11
1.5.1 Hétérogénéité des protocoles expérimentaux	11
1.5.2 Déséquilibre des classes et biais des métriques	11
1.5.3 Généralisation limitée	12
1.5.4 Explicabilité insuffisante	12
1.5.5 Optimisation du seuil de décision	12
1.6 Positionnement et apport du présent travail	12
2 CONCEPTION METHODOLOGIQUE ET ÉVALUATION EXPÉRIMENTALE DES MODELES DE DÉTECTION DU DIABETE	14
2.1 Introduction	14
2.2 Présentation du jeu de données	15
2.2.1 Description générale et origine des données	15
2.2.2 Description détaillée des attributs cliniques	15

2.2.3	Analyse de la distribution des classes	16
2.3	Chaîne de prétraitement et optimisation des données	18
2.3.1	Détection scrupuleuse et imputation conditionnelle des données aberrantes	18
2.3.2	Rectification des valeurs extrêmes (Winsorisation asymétrique) . . .	19
2.3.3	Ingénierie avancée des caractéristiques (Feature Engineering)	21
2.3.4	Partition de l'espace, normalisation structurelle et augmentation endogène	22
2.4	Sélection rigoureuse des attributs descriptifs	22
2.5	Environnement d'exécution et stratégie de paramétrage	23
2.5.1	L'écosystème d'évaluation	23
2.5.2	Exploration multidimensionnelle via Optuna	24
2.6	Évaluation systématique des algorithmes isolés	24
2.6.1	Synthèse du classificateur SVM à noyau paramétrique	24
2.6.2	Évaluation du groupement d'arbres décisionnels (Random Forest) .	24
2.6.3	Déploiement évaluatif de XGBoost	25
2.7	Déploiement analytique d'architectures ensemblistes complexes	26
3	ANALYSE DES RESULTATS, DISCUSSION ET PERSPECTIVES	28
3.1	Analyse des Résultats	28
3.1.1	Évaluation des Modèles Individuels (SVM, Random Forest, XGBoost)	28
3.1.2	Impact des Modèles Avancés (Voting Ensemble et Stacking)	28
3.1.3	Analyse Comparative et Sélection du Meilleur Modèle	29
3.2	Discussion	31
3.2.1	Impact Décisif du Prétraitement et de l'Ingénierie des Données . . .	31
3.2.2	Biais et Variance : Analyse des Courbes d'Apprentissage	31
3.2.3	Interprétation Clinique des Métriques	32
3.2.4	Limites de l'Étude Expérimentale	32
3.2.5	Confrontation des résultats avec la littérature	34
3.3	Perspectives	35
3.3.1	Amélioration Continue du Modèle	35
3.3.2	Déploiement et Application Pratique	35
	CONCLUSION GÉNÉRALE	36
	BIBLIOGRAPHIE	40
	ANNEXE	42

LISTE DES FIGURES

2.1	Distribution des caractéristiques par classe (Bleu : Non Diabétique, Rouge : Diabétique)	16
2.2	Matrice de corrélation de Pearson entre les différentes variables et la cible .	17
2.3	Boxplots de chaque caractéristique selon la classe	18
2.4	Analyse des zéros biologiquement impossibles (valeurs manquantes déguisées)	19
2.5	Comparatif des distributions de l'Insuline et du Glucose avant et après imputation et winsorisation	20
2.6	Rééquilibrage strict des classes d'apprentissage grâce au Borderline-SMOTE	22
2.7	Visualisation graphique des scores d'Information Mutuelle (MI) calculés pour l'intégralité des 16 variables. Plus la barre est étendue, plus la variable est porteuse d'informations prédictives concernant la présence du diabète. .	23
2.8	Matrices de confusion normalisées représentant les décisions finales (en pourcentages) des trois approches concurrentes (SVM, Random Forest et XGBoost) évaluées conjointement sur l'ultime cohorte dissimulée (154 patientes). La précision supérieure des approches ensemblistes pour dépister correctement les patientes diabétiques est ici directement chiffrée.	25
2.9	Représentation détaillée des courbes de la fonction d'efficacité du récepteur (ROC) illustrant la primauté de l'architecture XGBoost par le gain incontestable de l'aire sous-jacente au profil.	26
3.1	Comparatif multi-métriques de l'ensemble des modèles via un graphique en radar	30
3.2	Comparaison de l'importance des caractéristiques (Random Forest vs XGBoost)	31
3.3	Courbes d'apprentissage mesurant l'évolution de la qualité analytique (ROC-AUC) selon le volume de données fournies.	32
3.4	Matrices de Confusion des algorithmes les plus performants	33
3.5	Courbes ROC de l'ensemble des modèles évalués	33
3.6	Courbes Précision-Rappel pour tous les modèles	34

LISTE DES TABLEAUX

1.1	Synthèse des principales études comparatives de ML pour la détection du diabète	11
2.1	Description exhaustive des variables cliniques de la base PIDDD	15
2.2	Recensement minutieux du volume d'imputation des valeurs manquantes par attribut biométrique	19
2.3	Nombre d'observations rectifiées aux bornes extrêmes par le processus de winsorisation	20
2.4	Description des caractéristiques dérivées et évaluation de leur corrélation de Pearson avec le diagnostic final	21
2.5	Rendement quantifié concernant le classificateur SVM (configuration RBF)	24
2.6	Rendement quantifié concernant le modèle prédictif Random Forest	25
2.7	Rendement quantifié concernant l'infrastructure algorithmique XGBoost .	25
3.1	Comparaison des performances des modèles sur le jeu de test	29
3.2	Mesure de l'impact des optimisations sur la précision finale du XGBoost .	34

LISTE DES ABRÉVIATIONS

ADA	American Diabetes Association
ADASYN	Adaptive Synthetic Sampling
AUC-ROC	Area Under the Receiver Operating Characteristic Curve
BNB	Bernoulli Naive Bayes
CART	Classification and Regression Trees
DT	Decision Tree (Arbre de Décision)
F1	F1-Score (moyenne harmonique de la précision et du rappel)
GBM	Gradient Boosting Machine
K-NN	K-Nearest Neighbors (K Plus Proches Voisins)
LR	Logistic Regression (Régression Logistique)
MDA	Mean Decrease in Accuracy (Diminution Moyenne de la Précision)
MDI	Mean Decrease in Impurity (Diminution Moyenne de l'Impureté)
ML	Machine Learning (Apprentissage Automatique)
MNIST	Modified National Institute of Standards and Technology (base d'images)
mRMR	Minimum Redundancy Maximum Relevance (sélection de variables)
MSE	Mean Squared Error (Erreur Quadratique Moyenne)
NB	Naive Bayes (Classifieur Naïf de Bayes)
OOB	Out-of-Bag (échantillons non utilisés lors du bootstrap)
PCA	Principal Component Analysis (Analyse en Composantes Principales)
PIDD	Pima Indians Diabetes Database
RBF	Radial Basis Function (Noyau Gaussien)
RF	Random Forest (Forêt Aléatoire)
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
SVM	Support Vector Machine (Machine à Vecteurs de Support)
XGBoost	eXtreme Gradient Boosting

RESUME

Le diabète sucré constitue l'un des enjeux de santé publique les plus critiques du 21^e siècle, touchant plus de 500 millions de personnes à travers le monde. Sa détection précoce est essentielle pour prévenir des complications graves et réduire la charge des systèmes de santé. Dans ce contexte, les méthodes d'apprentissage automatique supervisé offrent des perspectives prometteuses pour l'exploitation des données cliniques à des fins diagnostiques.

Ce travail présente une évaluation comparative rigoureuse de trois algorithmes de machine learning — les **Machines à Vecteurs de Support (SVM)**, les **Forêts Aléatoires (Random Forests)** et **XGBoost** — appliqués à la classification du risque diabétique sur la base de données *Pima Indians Diabetes Database* (PIDD). Ce jeu de données, composé de 768 patientes issues de la communauté Pima présentant une prévalence élevée de diabète de type 2, regroupe huit variables cliniques clés telles que la glycémie plasmatique, l'indice de masse corporelle, l'insulinémie, la pression artérielle et la fonction de prédisposition héréditaire.

Dans un premier temps, les fondements théoriques de chacun des trois algorithmes sont présentés : le formalisme de la maximisation de la marge et l'astuce du noyau pour les SVM, les mécanismes de bagging et de sélection aléatoire des caractéristiques pour les forêts aléatoires, ainsi que le gradient boosting régularisé et l'approximation de Taylor de second ordre propres à XGBoost. Un état de l'art de l'application de ces méthodes à la détection du diabète est ensuite conduit, soulignant les limites des approches existantes et motivant les choix méthodologiques retenus dans ce travail.

Sur le plan expérimental, les trois modèles sont entraînés et évalués selon un protocole strict incluant une validation croisée, une gestion explicite du déséquilibre de classes (environ 65 % de cas négatifs contre 35 % de cas positifs), ainsi qu'une optimisation des hyperparamètres. L'évaluation repose sur un ensemble complet de métriques cliniquement pertinentes : précision (*accuracy*), rappel (*recall*), F1-score, aire sous la courbe ROC (AUC-ROC) et matrice de confusion.

Les résultats expérimentaux révèlent que **XGBoost** obtient les meilleures performances globales, avec notamment les scores AUC-ROC et F1 les plus élevés, confirmant la supériorité des méthodes de boosting par gradient pour ce type de tâche clinique. Les **Forêts Aléatoires** présentent des performances comparables, avec l'avantage d'une plus grande robustesse au surapprentissage et d'une intégration naturelle de l'estimation d'erreur *out-of-bag*. Les **SVM** avec noyau RBF offrent de bonnes performances sur les métriques de précision mais se montrent plus sensibles aux réglages d'hyperparamètres et au déséquilibre des classes. La glycémie plasmatique ressort systématiquement comme le prédicteur le plus informatif dans les trois modèles, en accord avec les connaissances médicales établies.

Ces travaux contribuent à fournir une base comparative reproductible et cliniquement orientée pour le choix d'un algorithme de détection du diabète, et ouvrent des perspectives

vers des approches hybrides et des analyses d'explicabilité plus poussées à l'aide d'outils tels que SHAP.

Mots-clés : Apprentissage automatique, Diabète, PIDD, SVM, Forêts Aléatoires, XGBoost, Classification, AUC-ROC, Données médicales.

INTRODUCTION GÉNÉRALE

Contexte et enjeux de la détection du diabète

Le diabète constitue l'une des maladies chroniques les plus répandues à l'échelle mondiale, représentant un défi majeur pour les systèmes de santé publique. Selon l'Organisation Mondiale de la Santé (OMS), le nombre de personnes atteintes de diabète a quadruplé depuis 1980, atteignant aujourd'hui plus de 500 millions d'individus dans le monde, avec une prévalence croissante aussi bien dans les pays développés que dans les pays en développement. Cette maladie, caractérisée par une hyperglycémie chronique résultant d'une insuffisance de production ou d'utilisation de l'insuline, entraîne de graves complications à long terme : maladies cardiovasculaires, insuffisance rénale, neuropathies et cécité.

Au-delà de ses conséquences sanitaires directes, le diabète génère des coûts économiques considérables, tant pour les patients que pour les systèmes de santé. Son diagnostic tardif, fréquent dans les régions à ressources limitées, aggrave le pronostic et alourdit la charge thérapeutique. Dans ce contexte, la détection précoce et fiable du diabète constitue un enjeu clinique et économique de premier ordre, justifiant le recours à des approches innovantes capables d'exploiter les données médicales disponibles.

Motivation du recours aux méthodes d'apprentissage automatique

Face à la complexité des mécanismes biologiques impliqués dans le diabète et à la multidimensionnalité des données cliniques (glycémie, indice de masse corporelle, pression artérielle, âge, antécédents familiaux, etc.), les approches diagnostiques traditionnelles reposant sur des seuils cliniques fixes atteignent rapidement leurs limites. Ces méthodes ne permettent pas de capturer les interactions non linéaires entre les variables, ni de personnaliser le diagnostic en fonction du profil individuel du patient.

L'apprentissage automatique (*machine learning*) offre une alternative particulièrement prometteuse. Grâce à leur capacité à identifier des patterns complexes dans des jeux de données de grande dimension, les algorithmes supervisés peuvent apprendre à discriminer les patients diabétiques des individus sains avec une précision souvent supérieure à celle des critères cliniques classiques. Ils permettent également d'intégrer de manière cohérente des variables hétérogènes et de produire des scores de risque individualisés, ouvrant la voie à une médecine prédictive et préventive plus efficace.

Problématique de recherche

Si plusieurs algorithmes d'apprentissage supervisé ont été appliqués à la détection du diabète dans la littérature, le choix de l'algorithme optimal demeure une question ouverte. En effet, différents modèles reposent sur des hypothèses et des architectures fondamentalement distinctes, ce qui se traduit par des comportements variés selon les caractéristiques du jeu de données : dimensionnalité, présence de valeurs manquantes, déséquilibre entre classes, ou encore bruit dans les mesures cliniques.

La problématique centrale de ce travail peut donc être formulée comme suit : *parmi les algorithmes de machine learning supervisé (Support Vector Machines (SVM), Random Forests et XGBoost), lequel offre les meilleures performances pour la détection du diabète,*

et dans quelles conditions chacun est-il préférable ? Cette question soulève des enjeux à la fois théoriques, liés aux fondements mathématiques de chaque modèle, et pratiques, relatifs à leur utilisabilité en contexte clinique réel.

Objectifs du travail

Ce rapport poursuit trois objectifs complémentaires.

Premièrement, il s'agit de présenter de manière rigoureuse les fondements théoriques des trois algorithmes étudiés (SVM, Random Forests et XGBoost) en mettant en évidence les propriétés qui conditionnent leurs performances sur des données médicales.

Deuxièmement, ce travail vise à construire un cadre d'évaluation comparative structuré, intégrant des métriques de classification classiques (précision, rappel, F1-score, AUC-ROC) ainsi que des considérations pratiques liées au déploiement clinique, notamment la gestion du déséquilibre des classes et l'interprétabilité des décisions.

Troisièmement, ce travail cherche à formuler des recommandations concrètes sur le choix algorithmique en fonction des contraintes du contexte médical : disponibilité des données, exigences de temps de réponse, besoin d'explicabilité pour les praticiens de santé, et robustesse face aux données imparfaites.

Démarche générale adoptée

Pour atteindre ces objectifs, une démarche en trois temps a été adoptée. Dans un premier temps, une étude théorique approfondie des trois algorithmes est conduite, portant sur leurs mécanismes d'apprentissage, leurs hyperparamètres clés et leurs comportements face aux spécificités des données médicales. Dans un second temps, un état de l'art est réalisé afin de recenser les travaux existants sur l'application de ces méthodes à la détection du diabète, et d'identifier les lacunes que ce travail cherche à combler. Enfin, une évaluation expérimentale est menée sur un jeu de données réel de patients, permettant une comparaison empirique rigoureuse des trois modèles selon plusieurs axes de performance.

Une attention particulière est portée à la gestion du déséquilibre des classes ; les cas positifs (diabétiques) étant généralement moins représentés, ainsi qu'à l'optimisation du seuil de décision, deux facteurs critiques pour la pertinence clinique des prédictions.

Organisation du rapport

Ce rapport est structuré en six parties complémentaires. Le **Chapitre 1** est consacré aux Support Vector Machines (SVM), en couvrant leur formalisme mathématique, le principe de maximisation de la marge et l'astuce du noyau pour les données non linéairement séparables. Le **Chapitre 2** présente les Random Forests, depuis les fondements de l'apprentissage en ensemble jusqu'aux mécanismes de bagging, de sélection aléatoire des caractéristiques et d'estimation de l'erreur out-of-bag. Le **Chapitre 3** détaille XGBoost, en insistant sur ses innovations mathématiques : régularisation, approximation de Taylor de second ordre, et ses optimisations systèmes. Le **Chapitre 4** propose un état de l'art sur l'application des méthodes d'apprentissage automatique à la détection du diabète. Le

Chapitre 5 présente la méthodologie et les résultats expérimentaux de l'évaluation comparative des trois modèles. Enfin, le **Chapitre 6** synthétise les résultats et formule des recommandations pratiques pour le choix du modèle en contexte clinique. Une conclusion générale clôt le document.

Partie I

ÉTUDE EXPÉRIMENTALE ET APPLICATION AU CAS DE LA DETECTION DU DIABETE

1

ETAT DE L'ART SUR LA DETECTION DU DIABETE A L'AIDE DE L'APPRENTISSAGE AUTOMATIQUE

1.1 Introduction

Le diabète sucré (*Diabetes Mellitus*, DM) est une maladie métabolique chronique caractérisée par une hyperglycémie persistante, c'est-à-dire une concentration anormalement élevée de glucose dans le sang. Cette anomalie résulte soit d'une déficience de la sécrétion d'insuline par le pancréas, soit d'une résistance des cellules à l'action de cette hormone, soit d'une combinaison des deux mécanismes (Iparraguirre-Villanueva et al., 2023a). L'insuline, hormone produite par les cellules bêta des îlots de Langerhans, joue un rôle fondamental dans la régulation glycémique : elle permet aux cellules d'absorber le glucose circulant dans le sang pour le convertir en énergie. En son absence ou en cas de résistance à son action, le glucose s'accumule dans la circulation sanguine, entraînant à long terme des dommages irréversibles sur de nombreux organes et systèmes.

Types de diabète

On distingue principalement trois formes cliniques du diabète :

Le diabète de type 1 (DT1) est une maladie auto-immune dans laquelle le système immunitaire attaque et détruit les cellules bêta pancréatiques productrices d'insuline. Il représente environ 5 à 10% des cas diagnostiqués et se manifeste généralement durant l'enfance ou l'adolescence. Les patients atteints de DT1 dépendent à vie d'injections d'insuline exogène pour leur survie (Iparraguirre-Villanueva et al., 2023a; Zou et al., 2018).

Le diabète de type 2 (DT2) constitue la forme la plus répandue, représentant plus de 90% des cas mondiaux. Il se caractérise par une résistance progressive à l'insuline, combinée à une sécrétion pancréatique insuffisante pour compenser cette résistance. Son développement est fortement lié au mode de vie — sédentarité, obésité, alimentation hypercalorique — ainsi qu'à une prédisposition génétique. Contrairement au DT1, il survient le plus souvent à l'âge adulte, bien qu'une tendance croissante soit observée chez les

adolescents dans les pays développés (Zou et al., 2018).

Le diabète gestationnel apparaît durant la grossesse chez des femmes ne présentant pas de diabète préalable. Il se résorbe généralement après l'accouchement, mais augmente significativement le risque de développer un DT2 ultérieurement, aussi bien chez la mère que chez l'enfant. La base de données Pima Indians Diabetes Database (PIDD), utilisée dans ce travail, concerne exclusivement des femmes adultes de la communauté Pima, une population présentant une prévalence exceptionnellement élevée de DT2, dont une part importante est liée à des antécédents de diabète gestationnel.

Facteurs de risque et variables cliniques déterminantes

La progression vers le diabète de type 2 est influencée par un ensemble de facteurs biologiques et comportementaux. Parmi les principaux indicateurs cliniques figurant dans la littérature et dans la PIDD, on trouve (Zou et al., 2018; Iparraguirre-Villanueva et al., 2023a) :

- **La glycémie (glucose plasmatique)** : principal marqueur diagnostique, mesurée à jeun ou après une charge orale en glucose. Un taux supérieur à 126 mg/dL à jeun est diagnostique du diabète selon les critères de l'American Diabetes Association (ADA). C'est la variable de plus grande importance prédictive dans les études sur la PIDD.
- **L'indice de masse corporelle (IMC ou BMI)** : fortement corrélé au risque de DT2, un IMC supérieur à 30 kg/m² indique une obésité et constitue un facteur de risque majeur de résistance à l'insuline.
- **Le taux d'insuline** : une élévation chronique de l'insulinémie peut signaler une résistance à l'insuline précédant le diabète clinique.
- **La pression artérielle diastolique** : l'hypertension est à la fois un facteur de risque et une comorbidité fréquente du diabète, augmentant le risque cardiovasculaire.
- **L'épaisseur du pli cutané tricipital** : indicateur indirect de la masse grasse corporelle, corrélé à l'obésité et à la résistance à l'insuline.
- **La fonction pedigree du diabète (Diabetes Pedigree Function)** : score composite reflétant l'hérédité familiale diabétique, intégrant la prévalence du diabète chez les apparentés et leur degré de parenté.
- **L'âge** : le risque de DT2 augmente avec l'âge, particulièrement après 45 ans.
- **Le nombre de grossesses** : dans la population Pima, le nombre de grossesses est corrélé à l'âge et constitue un facteur de risque indirect via le diabète gestationnel.

Conséquences et enjeux cliniques

Non traité ou mal contrôlé, le diabète entraîne des complications graves : néphropathie diabétique pouvant évoluer vers l'insuffisance rénale terminale, rétinopathie et cécité, neuropathie périphérique, maladies cardiovasculaires et artériopathie des membres inférieurs pouvant mener à l'amputation. La détection précoce est donc cruciale : elle permet d'initier des interventions sur le mode de vie et des traitements pharmacologiques avant l'apparition des complications irréversibles (Wee et al., 2024; Khanam and Foo, 2021).

1.2 Approches traditionnelles de détection du diabète

Historiquement, le diagnostic du diabète repose sur des critères biochimiques standardisés établis par des organisations de référence telles que l'OMS et l'ADA. Ces critères incluent la mesure de la glycémie à jeun (≥ 126 mg/dL), la glycémie deux heures après une charge orale en glucose de 75g (≥ 200 mg/dL), ou le taux d'hémoglobine glyquée HbA1c ($\geq 6,5\%$). Ces mesures constituent des seuils fixes, appliqués uniformément à l'ensemble de la population.

Si ces méthodes présentent l'avantage d'être standardisées, reproductibles et bien comprises cliniquement, elles souffrent de plusieurs limitations importantes dans un contexte de prévention et de dépistage de masse (Sisodia and Sisodia, 2018) :

1. **Absence d'intégration multi-variables** : les critères traditionnels ne tiennent pas compte simultanément des multiples facteurs de risque. Or, la progression vers le DT2 est un phénomène multidimensionnel impliquant des interactions complexes entre variables génétiques, métaboliques et comportementales.
2. **Détection tardive** : Ils diagnostiquent un diabète déclaré, souvent après plusieurs années de dysrégulation glycémique silencieuse (stade prédiabétique). L'étude de Lv et al. (2023) souligne d'ailleurs que certaines personnes ayant une glycémie à jeun normale peuvent en réalité être diabétiques, passant ainsi inaperçues lors des examens de routine.
3. **Coût et accessibilité** : les tests biologiques (HOMA-IR, OGTT) requièrent des prélèvements à jeun et une infrastructure de laboratoire, ce qui limite leur accessibilité dans les systèmes de santé à ressources limitées.
4. **Variabilité inter-individuelle** : deux individus présentant la même glycémie à jeun peuvent avoir des profils de risque très différents selon leurs caractéristiques anthropométriques, héréditaires et comportementales.

Ces limites ont motivé l'exploration de méthodes analytiques capables d'exploiter l'ensemble des données cliniques disponibles pour produire des prédictions personnalisées du risque diabétique (Sisodia and Sisodia, 2018; Kavakiotis et al., 2017).

1.3 Approches basées sur l'apprentissage automatique

L'application de l'apprentissage automatique à la détection du diabète a fait l'objet de nombreuses recherches, utilisant une variété d'algorithmes et de jeux de données.

Dans une étude visant à évaluer l'efficacité de différents algorithmes pour la détection précoce du diabète de type 2, Gowthami et al. (2024) ont utilisé un ensemble de données de 520 patients du Sylhet Diabetes Hospital au Bangladesh, comprenant 17 attributs. Leur méthodologie a mis l'accent sur la sélection de caractéristiques (feature selection) pour réduire la dimensionnalité et améliorer la précision. En comparant des modèles tels que la régression logistique, les K-plus proches voisins (KNN), les arbres de décision, les forêts aléatoires et les machines à vecteurs de support, ils ont démontré que l'algorithme Random Forest atteignait une précision impressionnante de 98%, soulignant le potentiel de ces méthodes pour un dépistage précis et non invasif.

De leur côté, Iparraguirre-Villanueva et al. (2023b) se sont concentrés sur la détection et la classification du diabète de type 2 en utilisant le jeu de données PIMA Indian. Ils ont investigué cinq modèles de ML : K-NN, Bernoulli Naive Bayes (BNB), arbre de décision (DT), régression logistique (LR) et SVM. Face à la petite taille du jeu de données, ils ont appliqué la technique de suréchantillonnage SMOTE pour équilibrer les classes. Leurs résultats ont montré que les modèles K-NN et BNB surpassaient les autres, avec des précisions respectives de 79,6% et 77,2%, concluant que l'utilisation de modèles ML pour la détection précoce du diabète est très prometteuse.

S'inscrivant dans une démarche similaire, Saihood and Sonuç (2023) ont proposé un cadre pratique en trois étapes pour le diagnostic du diabète, incluant un prétraitement poussé des données (gestion des valeurs manquantes, des outliers, équilibrage des classes, sélection de caractéristiques), un réglage fin des hyperparamètres par recherche par grille (grid search), et l'utilisation de méthodes d'ensemble (bagging, boosting, stacking). En testant leur approche sur le jeu de données PIDD, ils ont constaté la supériorité des méthodes d'ensemble. Le stacking, combinant Random Forest et SVM, a obtenu la meilleure précision (97,50%), suivi de près par Random Forest (97,20%) et XGBoost (97,10%). Ces résultats confirment que l'attention portée au prétraitement et l'utilisation d'ensembles de modèles sont cruciales pour une performance élevée.

Lv et al. (2023) ont abordé la problématique sous un angle original : détecter les patients diabétiques parmi les personnes ayant une glycémie à jeun normale, qui passent donc inaperçues lors des examens standards. En utilisant les données d'examen physiques de plus de 60 000 individus issus de trois cohortes chinoises, ils ont construit un modèle de prédiction appelé DRING (Diabetes Risk of Individuals with Normal fasting Glucose). Leur modèle, basé sur la régression logistique, a montré d'excellentes performances avec seulement 13 caractéristiques cliniques courantes (dont l'âge, l'IMC, la numération lymphocytaire). Ils ont également développé un cadre pour identifier les facteurs de risque personnalisés pour un individu donné, démontrant la faisabilité d'une approche de dépistage plus fine et personnalisée.

Enfin, une revue de la littérature exhaustive menée par Juwono et al. (2024) a analysé plus de 50 modèles de ML et d'apprentissage profond pour la détection du diabète. Leur analyse souligne plusieurs points critiques : (1) la majorité des études utilisent des ensembles de données invasifs comme le PIDD, alors que le développement d'outils basés sur des mesures anthropométriques non invasives est une demande clinique forte ; (2) le suréchantillonnage, bien que souvent utilisé, n'améliore pas systématiquement les performances s'il est appliqué sur des données bruitées ; (3) la sélection de caractéristiques, si elle est bénéfique pour les modèles de ML, peut pénaliser les modèles de deep learning sur de petits jeux de données en réduisant encore le nombre d'échantillons disponibles. Leurs travaux mettent en lumière l'importance cruciale de la qualité et de la nature des données, ainsi que le compromis entre complexité du modèle et performance réelle.

1.4 Études comparatives utilisant SVM, Random Forest et XGBoost

Un corpus croissant de travaux propose des comparaisons directes entre les trois algorithmes ciblés dans ce mémoire, offrant une base empirique solide pour orienter le choix du modèle en contexte clinique.

1.4.1 Comparaisons sur la base PIDD

Iparraguirre-Villanueva et al. comparent cinq algorithmes — K-NN, Naïf de Bayes, arbres de décision, régression logistique et SVM — sur la PIDD avec application de SMOTE pour l'équilibrage des classes (Iparraguirre-Villanueva et al., 2023a). Leurs résultats montrent que K-NN et Bernoulli NB surpassent le SVM (71,7% d'exactitude) dans ce contexte. Cette relative contre-performance du SVM est attribuée à la petite taille du jeu de données et à la sensibilité de l'algorithme aux hyperparamètres dans des espaces de faible dimensionnalité.

Zou et al. proposent une comparaison systématique sur la PIDD incluant les forêts aléatoires, les arbres de décision et les réseaux de neurones, avec application de techniques de réduction de dimensionnalité (PCA et mRMR) (Zou et al., 2018). La Random Forest obtient la meilleure exactitude globale (80,84%), ce résultat étant robuste aux différentes configurations de sélection de variables testées. Les auteurs soulignent que le glucose est systématiquement identifié comme la variable de plus haute importance, tant par les critères d'entropie dans les arbres que par l'importance des variables dans la Random Forest.

1.4.2 Comparaisons multi-algorithmes incluant XGBoost

Wee et al. proposent une revue approfondie des méthodes de ML et de deep learning appliquées à la détection du diabète sur plusieurs bases de données publiques (Wee et al., 2024). Leur analyse met en évidence la supériorité systématique des méthodes ensemblistes (Random Forest, XGBoost) sur les méthodes à modèle unique (régression logistique, SVM) en termes d'exactitude, de F1-score et d'AUC-ROC. XGBoost se distingue notamment par ses mécanismes intégrés de régularisation et sa gestion native des valeurs manquantes, deux propriétés particulièrement avantageuses pour les données médicales réelles souvent incomplètes.

Khanam and Foo réalisent une comparaison de sept algorithmes de ML pour la prédiction du diabète, incluant SVM, Random Forest, régression logistique, K-NN, arbres de décision, réseaux de neurones et Naïf de Bayes (Khanam and Foo, 2021). Sur la PIDD, les résultats montrent que la régression logistique et le SVM obtiennent les meilleures performances en termes d'exactitude, tandis que la Random Forest excelle sur le rappel (*recall*), métrique particulièrement importante en contexte médical pour minimiser les faux négatifs (patients diabétiques non détectés).

1.4.3 Apport des techniques de prétraitement et d'optimisation

Plusieurs études soulignent que les performances comparatives dépendent fortement des stratégies de prétraitement adoptées. Gündoğdu montrent que la sélection de variables par Random Forest permet d'améliorer significativement les performances de XGBoost en réduisant le bruit introduit par les variables non informatives (Gündoğdu, 2023). Iparraguirre-Villanueva et al. démontrent que l'application de SMOTE améliore systématiquement les métriques de classification pour tous les algorithmes testés sur la PIDD, en réduisant le déséquilibre entre les classes positives (diabétiques, 35% du jeu de données) et négatives (Iparraguirre-Villanueva et al., 2023a).

Le Tableau 1.1 synthétise les principales études comparatives identifiées dans la littérature.

TABLE 1.1 – Synthèse des principales études comparatives de ML pour la détection du diabète

Étude	Dataset	Algorithmes	Meilleur résultat	Métrique
Zou et al. (2018)	PIDD + Luzhou	RF, DT, NN	RF : 80,84%	ACC
Iparraguirre et al. (2023a)	PIDD (SMOTE)	K-NN, NB, DT, LR, SVM	K-NN : 79,6%	ACC
Wee et al. (2024)	Multiple	RF, XGB, SVM, DL	XGBoost	AUC-ROC
Khanam & Foo (2021)	PIDD	7 algorithmes	LR/SVM	ACC / Recall
Gündoğdu & Gündoğdu (2023)	Sylhet, BD	RF + XGB	RF-XGB : 98,6%	AUC
Sisodia & Sisodia (2018)	PIDD	NB, DT, SVM	NB : 76,3%	ACC

1.5 Analyse critique des travaux existants

L'examen de la littérature permet d'identifier plusieurs constats et limites récurrents qui méritent une discussion approfondie.

1.5.1 Hétérogénéité des protocoles expérimentaux

La comparabilité des résultats entre études est sérieusement compromise par l'hétérogénéité des protocoles. Les différences portent sur la stratégie de partitionnement des données (hold-out simple vs. validation croisée k-fold), le traitement des valeurs manquantes et des zéros biologiquement impossibles dans la PIDD (certaines études les suppriment, d'autres les imputent), l'usage ou non de techniques de rééchantillonnage (SMOTE, ADASYN), ainsi que le choix des métriques d'évaluation. Ces disparités rendent les comparaisons directes entre études délicates et expliquent en partie la grande variabilité des performances rapportées pour un même algorithme (Wee et al., 2024).

1.5.2 Déséquilibre des classes et biais des métriques

La PIDD présente un déséquilibre significatif entre les classes : environ 35% de cas positifs contre 65% de cas négatifs. Cette asymétrie induit un biais dans l'interprétation de l'exactitude simple (*accuracy*), qui peut être artificiellement élevée même pour un classifieur majoritaire. Plusieurs études publiées antérieurement ne reportent que l'exactitude, occultant les performances sur la classe minoritaire (diabétiques) qui est pourtant la plus cliniquement pertinente (Khanam and Foo, 2021; Iparraguirre-Villanueva et al., 2023a). Une analyse rigoureuse doit systématiquement inclure le rappel (sensibilité), la précision, le F1-score et l'AUC-ROC pour chaque classe.

1.5.3 Généralisation limitée

La majorité des études comparatives se concentrent sur la PIDD, une base de données de 768 instances issues d'une population très spécifique (femmes Pima de plus de 21 ans). La généralisation de ces résultats à d'autres populations reste une question ouverte. Les caractéristiques démographiques, génétiques et métaboliques de la population Pima sont atypiques à l'échelle mondiale, ce qui limite l'extrapolation directe des modèles développés (Zou et al., 2018; Wee et al., 2024).

1.5.4 Explicabilité insuffisante

Peu d'études analysent l'importance des variables de manière rigoureuse ou n'explorent les mécanismes de décision des modèles au-delà des simples scores d'importance. L'émergence d'outils d'explicabilité comme SHAP (*SHapley Additive exPlanations*) offre des perspectives prometteuses pour rendre les modèles ensemblistes interprétables par les cliniciens, mais leur utilisation reste marginale dans la littérature sur la PIDD (Wee et al., 2024).

1.5.5 Optimisation du seuil de décision

La quasi-totalité des études utilise le seuil de classification par défaut de 0,5, sans l'optimiser en fonction du contexte clinique. En détection du diabète, un faux négatif (patient diabétique non détecté) est généralement plus coûteux qu'un faux positif, ce qui justifie l'utilisation de seuils inférieurs à 0,5 pour maximiser la sensibilité. Cette dimension de l'évaluation est systématiquement négligée dans les études existantes (Khanam and Foo, 2021).

1.6 Positionnement et apport du présent travail

À la lumière de cette revue de littérature, le présent travail se positionne dans le prolongement des études comparatives existantes tout en apportant plusieurs contributions spécifiques.

Premièrement, contrairement aux études qui comparent un grand nombre d'algorithmes superficiellement, ce mémoire se concentre sur trois algorithmes majeurs — SVM, Random Forest et XGBoost — avec une analyse approfondie de leurs mécanismes théoriques et de leur comportement face aux spécificités de la PIDD. Ce choix est motivé par la complémentarité des approches : les SVM représentent les méthodes à noyau, la Random Forest représente le bagging ensembliste, et XGBoost représente le boosting par gradient.

Deuxièmement, l'évaluation adoptée dans ce travail va au-delà de la simple exactitude pour inclure un ensemble complet de métriques adapté au contexte médical : précision, rappel, F1-score, AUC-ROC et matrice de confusion par classe. Une attention particulière est portée à la sensibilité (rappel de la classe positive), directement liée au taux de détection des patients diabétiques.

Troisièmement, ce mémoire intègre une analyse de l'importance des variables pour chaque modèle, permettant d'identifier les prédicteurs les plus déterminants dans la PIDD et de confronter les conclusions algorithmiques aux connaissances médicales établies.

Quatrièmement, la gestion du déséquilibre des classes est traitée de manière explicite, en comparant différentes stratégies : pondération des classes, techniques de rééchantillonnage, et paramètres natifs (comme `scale_pos_weight` dans XGBoost) pour évaluer leur impact sur les performances finales.

En somme, ce travail vise à produire une évaluation comparative rigoureuse, reproductible et cliniquement orientée, dont les conclusions peuvent guider des praticiens ou des équipes de recherche souhaitant déployer un modèle de détection du diabète sur la PIDD ou des jeux de données cliniques similaires.

2

CONCEPTION METHODOLOGIQUE ET ÉVALUATION EXPÉRIMENTALE DES MODELES DE DÉTECTION DU DIABETE

2.1 Introduction

Ce chapitre détaille la mise en œuvre expérimentale des trois algorithmes étudiés dans la partie théorique, à savoir la Machine à Vecteurs de Support (SVM), les Forêts Aléatoires (Random Forest) et l'algorithme XGBoost, appliqués spécifiquement à la détection du diabète. L'intégralité du traitement de bout en bout, depuis l'acquisition des données brutes jusqu'à l'évaluation rigoureuse des modèles prédictifs, a été programmée en Python en exploitant les bibliothèques `scikit-learn`, `XGBoost`, `imbalanced-learn` et `Optuna`.

L'approche adoptée dans ce chapitre vise un triple objectif. Premièrement, il s'agit de décrire avec une grande minutie le jeu de données exploité et de souligner ses particularités statistiques. Deuxièmement, nous exposons de façon exhaustive la chaîne de prétraitement et le processus de création de nouvelles entités prédictives (ingénierie des caractéristiques), étape fondamentale qui constitue l'une des contributions majeures de notre étude. Troisièmement, nous détaillons les résultats quantitatifs obtenus, tant pour les modèles individuels que pour les approches combinées (méthodes ensemblistes), en proposant une lecture éclairée de leurs performances.

2.2 Présentation du jeu de données

2.2.1 Description générale et origine des données

La base de données sélectionnée pour cette étude est la *Pima Indians Diabetes Database* (PIDD). Il s’agit d’un corpus de référence incontournable dans la littérature scientifique consacrée à l’apprentissage automatique dans le domaine de la santé. Initialement compilée par l’Institut national américain du diabète et des maladies digestives et rénales (NIDDK), cette base a été rendue accessible à la communauté scientifique par le biais du dépôt géré par Jason Brownlee (Sisodia and Sisodia, 2018).

Ce jeu de données regroupe un total de **768 observations** cliniques. Celles-ci correspondent exclusivement à des patientes de sexe féminin, d’ascendance amérindienne Pima et âgées de 21 ans ou plus. Cette population a été historiquement identifiée comme présentant une prévalence remarquablement élevée pour le diabète de type 2. Chaque observation est structurée autour de **8 variables cliniques quantitatives** et d’une variable cible binaire indiquant le diagnostic.

2.2.2 Description détaillée des attributs cliniques

TABLE 2.1 – Description exhaustive des variables cliniques de la base PIDD

Attribut	Signification clinique et unité de mesure
Pregnancies	Nombre total de grossesses menées à terme ou non par la patiente.
Glucose	Concentration plasmatique en glucose mesurée lors d’un test oral de tolérance au glucose couvrant une durée de 2 heures (exprimée en mg/dL).
BloodPressure	Mesure de la pression artérielle diastolique (exprimée en mm Hg).
SkinThickness	Épaisseur du pli cutané tricipital mesurée au niveau du bras (exprimée en mm), souvent utilisée pour estimer l’adiposité corporelle.
Insulin	Taux d’insuline sérique mesuré deux heures après l’ingestion de glucose (exprimé en $\mu\text{U/ml}$).
BMI	Indice de masse corporelle, un indicateur de corpulence calculé comme le ratio du poids sur le carré de la taille (exprimé en kg/m^2).
DiabetesPedigreeFunction	Fonction mathématique générant un score synthétique modélisant la prédisposition héréditaire au diabète en fonction des antécédents familiaux de la patiente.
Age	Âge révolu de la patiente au moment de l’examen clinique (exprimé en années).
Outcome	Variable cible binaire désignant le diagnostic clinique final : 0 correspond à une patiente saine (non diabétique), et 1 à une patiente diagnostiquée diabétique.

2.2.3 Analyse de la distribution des classes

L'examen de la variable cible révèle un déséquilibre modéré au sein du corpus. Plus précisément, **500 observations** s'inscrivent dans la classe majoritaire (patientes non diabétiques), ce qui représente 65,1% de l'échantillon, tandis que **268 observations** relèvent de la classe minoritaire (patientes diagnostiquées diabétiques), soit 34,9% du jeu de données. Cette asymétrie de distribution reflète de manière réaliste la dynamique épidémiologique d'une population à haut risque de développer un trouble métabolique. Toutefois, sur le plan de l'apprentissage automatique, ce déséquilibre représente un défi technique substantiel. Cette contrainte fondamentale justifie l'emploi ultérieur de méthodes avancées de rééchantillonnage algorithmique, ainsi que le recours systématique à des métriques d'évaluation spécialisées (telles que le score F1 ou l'aire sous la courbe ROC) afin d'éviter les biais d'interprétation inhérents à la simple exactitude globale (*accuracy*).

La Figure 2.1 illustre la distribution de chaque variable selon la classe. On observe que les distributions des patientes diabétiques (en rouge) sont souvent décalées vers des valeurs plus élevées, notamment pour le **Glucose**, le **BMI** et l'**Age**.




FIGURE 2.1 – Distribution des caractéristiques par classe (Bleu : Non Diabétique, Rouge : Diabétique)

L'analyse des corrélations linéaires (Pearson), présentée en Figure 2.2, révèle que le **Glucose** ($r = 0.47$) et le **BMI** ($r = 0.29$) sont les variables les plus fortement corrélées avec la présence du diabète.




FIGURE 2.2 – Matrice de corrélation de Pearson entre les différentes variables et la cible

L'examen des boîtes à moustaches (Figure 2.3) confirme ces tendances tout en mettant en évidence la présence de nombreuses valeurs atypiques, particulièrement pour l'Insulin et la DiabetesPedigreeFunction. On y remarque d'ores et déjà des valeurs nulles physiologiquement impossibles, par exemple pour le Glucose ou le BMI.




FIGURE 2.3 – Boxplots de chaque caractéristique selon la classe

2.3 Chaîne de prétraitement et optimisation des données

La préparation rigoureuse des données s'impose comme l'étape la plus déterminante d'un projet de modélisation prédictive, tout particulièrement dans le secteur médical où les relevés cliniques souffrent fréquemment d'incohérences de mesure ou de valeurs manquantes. La méthodologie élaborée dans le cadre de ce mémoire se structure autour de quatre étapes successives et hautement spécialisées.

2.3.1 Détection scrupuleuse et imputation conditionnelle des données aberrantes

Une analyse approfondie des données met en exergue la présence récurrente de variables nulles concernant cinq attributs biométriques pour lesquels une mesure à zéro est physiologiquement impossible. Ces variables sont **Glucose**, **BloodPressure**, **SkinThickness**, **Insulin** et **BMI**. Dans la conception du corpus PIDD originel, ces zéros agissent comme des marqueurs signalant des relevés manquants.

La substitution arbitraire de ces valeurs manquantes par la médiane globale de l'échantillon constituerait un biais méthodologique profond, dans la mesure où cette approche omettrait l'impact intrinsèque de la pathophysiologie du diabète sur la distribution de ces variables. Pour y remédier de manière rigoureuse, nous avons mis en œuvre une **imputation conditionnelle par la médiane de classe**. Concrètement, pour un attribut donné

et pour chaque classe cible de façon indépendante, toute valeur manquante est substituée par la médiane calculée de manière exclusive sur les patientes de la même classe (patientes saines ou diabétiques) dont les mesures sont valides. Le tableau 2.2 récapitule de manière détaillée l’étendue des substitutions réalisées.

TABLE 2.2 – Recensement minutieux du volume d’imputation des valeurs manquantes par attribut biométrique

Attribut clinique	Nombre de valeurs substituées
Insulin	374
SkinThickness	227
BloodPressure	35
BMI	11
Glucose	5




FIGURE 2.4 – Analyse des zéros biologiquement impossibles (valeurs manquantes déguisées)

2.3.2 Rectification des valeurs extrêmes (Winsorisation asymétrique)

Même après la phase d’imputation ciblée, le jeu de données conserve des occurrences résiduelles de valeurs extrêmes susceptibles d’altérer la convergence des algorithmes d’optimisation mathématique sous-jacents aux modèles de classification. Dans cette optique, nous avons opéré sur l’ensemble des descripteurs une **procédure de winsorisation fixée aux percentiles 1 et 99**. Suivant ce protocole systématique, toute valeur biologique isolée tombant en deçà du 1^{er} percentile d’une distribution est rehaussée à cette même borne, tandis qu’inversement, toute mesure dépassant le 99^{ème} percentile est tronquée à cette limite supérieure. Cette opération chirurgicale sauvegarde la forme générale de la distribution tout en neutralisant de façon stricte l’impact des anomalies isolées. Le récapitulatif des interventions, par attribut, figure dans le tableau 2.3.

La Figure 2.5 illustre l’impact très positif de ces deux opérations sur les distributions de l’insuline et du glucose, dont l’allure est ramenée vers une forme plus représentative de la réalité biologique.

TABLE 2.3 – Nombre d’observations rectifiées aux bornes extrêmes par le processus de winsorisation

Attribut clinique	Occurrences rectifiées (capping)
Insulin	16
DiabetesPedigreeFunction	16
BMI	15
Glucose	14
BloodPressure	12
SkinThickness	12
Age	6
Pregnancies	4



FIGURE 2.5 – Comparatif des distributions de l’Insuline et du Glucose avant et après imputation et winsorisation

2.3.3 Ingénierie avancée des caractéristiques (Feature Engineering)

Afin d'enrichir la base de connaissances fournie aux classificateurs mathématiques, nous avons synthétisé 8 nouveaux marqueurs prédictifs qui consolident et explicitent des interactions médicalement fondamentales mais implicites dans les données originelles. Cette extraction d'information rehausse de fait l'espace vectoriel d'entrée à un total de **16 dimensions**.

TABLE 2.4 – Description des caractéristiques dérivées et évaluation de leur corrélation de Pearson avec le diagnostic final

Nouvelle Caractéristique	Définition et Modélisation Clinique	Corrélation globale (r)
Risk_Score	Agrégation pondérée et normalisée évaluant le risque multifactoriel (impliquant Glucose, BMI, Âge, DPF).	+0.535
Glucose_BMI	Produit vectoriel évaluant la synergie pathologique entre la glycémie et la sévérité de la corpulence.	+0.526
Glucose_High	Transformation binaire identifiant un état flagrant d'hyperglycémie (seuil établi à 140 mg/dL).	+0.421
N_Risk_Factors	Somme cumulative comptabilisant le nombre de seuils cliniques pathologiques simultanément franchis par la patiente.	+0.427
BMI_Obese	Transformation binaire isolant strictement l'état d'obésité clinique (seuil fixé à 30 kg/m ²).	+0.297
BMI_Age	Produit vectoriel mesurant l'évolution du risque pondéral aggravée par le vieillissement métabolique.	+0.365
Insulin_Glucose_Ratio	Quotient spécifique servant d'estimateur indirect du phénomène de résistance insulino-tissulaire.	+0.262
Preg_Age_Ratio	Densité des gestations rapportée à la durée de la vie de l'individu.	+0.164

Le paramètre **Risk_Score** constitue une démonstration éclairante de notre tentative d'hybrider expertise médicale et logique mathématique. Ce dernier agrège les traits de la patiente en pondérant rigoureusement l'impact normalisé de son taux de glucose à hauteur de 35%, de sa mesure de corpulence à 25%, de son âge à 20%, et de sa prédisposition génétique à 20%. Ces coefficients s'inspirent méticuleusement de l'abondante bibliographie scientifique portant sur les facteurs de risques de l'apparition de la pathologie (Zou et al., 2018).

2.3.4 Partition de l'espace, normalisation structurelle et augmentation endogène

Pour garantir une objectivité totale lors des validations, le jeu de données source a été scindé à travers un découpage constant de 80% pour la matrice d'entraînement (totalisant 614 échantillons) et de 20% alloués à la matrice isolée de test (soit 154 échantillons). Cette séparation respecte fidèlement la technique de stratification, garantissant ainsi que la fréquence relative des occurrences saines et pathologiques reste strictement équivalente de part et d'autre.

Le lissage numérique de nos observations s'appuie sur la **transformation par puissance de Yeo-Johnson**. Ce mécanisme normalisateur surpasse largement la standardisation naïve (type *Z-score*), particulièrement face aux lois de distribution singulièrement étirées ou asymétriques telles que celles caractérisant les variables l'insuline et de l'épaisseur du pli tricépital. Il est à préciser que le transformateur de distribution a été ajusté en excluant fermement le lot de validation, proscrivant ainsi toute interférence de donnée (*data leakage*).

Face au constat du déséquilibre endémique au sein du sous-ensemble d'apprentissage (où l'on compte 400 profils sains pour seulement 214 profils malades), la démarche s'est dotée de l'algorithme avancé **Borderline-SMOTE**. S'écartant délibérément de l'algorithme SMOTE rudimentaire, cette solution de sur-échantillonnage cible uniquement la frange limite entre les nuages de points classifiés, pour synthétiser mécaniquement 186 profils diabétiques additionnels sans empiéter sur le territoire majoritaire. L'ensemble rectifié s'appuie in fine sur un équilibre parfait de 400 échantillons structurés pour la classe 0 contre 400 échantillons structurés pour la classe 1 (Wee et al., 2024). La Figure 2.6 illustre cet équilibrage.




FIGURE 2.6 – Rééquilibrage strict des classes d'apprentissage grâce au Borderline-SMOTE

2.4 Sélection rigoureuse des attributs descriptifs

Afin de mesurer l'impact théorique des variables sans dépendre de l'architecture d'un modèle en particulier, nous avons appliqué la méthode de l'Information Mutuelle (*Mutual Information*). Ce procédé non-paramétrique quantifie, à travers l'entropie, la réduction de l'incertitude induite sur le diagnostic final par la simple connaissance d'une variable donnée.




FIGURE 2.7 – Visualisation graphique des scores d’Information Mutuelle (MI) calculés pour l’intégralité des 16 variables. Plus la barre est étendue, plus la variable est porteuse d’informations prédictives concernant la présence du diabète.

Les mesures extraites par le biais de ce protocole, clairement observables à la figure 2.7, prouvent sans équivoque la primauté de l’estimateur de l’insuline (réévalué après un filtrage complet des omissions) et confirment par ailleurs l’immense intérêt mathématique de l’entité composite **Risk_Score** que nous avons intégralement modélisée. Contrastivement, la mesure du **DiabetesPedigreeFunction**, largement cautionnée par la base médicale historique pour sa capacité évocatrice potentielle, offre sous ce prisme statistique l’apport prédictif individuel le plus modéré du lot. L’immense influence recouvrée par l’indice **Insulin**, dont précisément 374 valeurs furent scientifiquement consolidées par la médiane pathologique, valide indiscutablement l’impact décisif de la stratégie d’imputation que nous avons préalablement défendue.

2.5 Environnement d’exécution et stratégie de paramétrage

2.5.1 L’écosystème d’évaluation

Le protocole permettant d’attester de la fiabilité et de la force de généralisation des algorithmes repose sur une combinaison simultanée de plusieurs procédures de contrôle intraitables. Le processus intègre premièrement un partitionnement de test opaque dit *holdout set*, strictement mis à l’écart durant la phase entière de calibrage et réservé exclusivement au jugement final. En second lieu, afin de mitiger l’aléa induit par les découpages simples, une matrice de validation croisée stratifiée et rebouclée sur 10 sections distinctes, répétée trois fois consécutives, est exploitée en vue de stabiliser l’intervalle de confiance lié à la surface sous la courbe (désigné **CV_AUC**).

Enfin, une étape extrêmement critique en science médicale repose sur l’approche de révision empirique des seuils probabilistes de discrimination. Les frontières théoriques ne sont plus confinées à la valeur neutre de 0,5 mais sont modulées unitairement sur l’ensemble modélisé afin de maximiser rigoureusement le point de crête de la métrique F1 (moyenne harmonique synthétisant le rapport Précision et Rappel).

2.5.2 Exploration multidimensionnelle via Optuna

Oubliant les méthodes naïves d’exploration spatiale de type grille exhaustive, nous avons orienté l’intégralité de la quête des hyperparamètres vers l’environnement très évolué **Optuna**. Cette infrastructure moderne orchestre les recherches mathématiques par les processus des approximateurs de Parzen structurés en arborisation probabiliste (TPE). L’architecture du classificateur SVM (reposant sur l’induction gaussienne RBF) fut criblée sur 100 itérations séquentielles afin de définir rigoureusement la pénalité C et le coefficient sphérique γ , aboutissant à des optimas fixés à $C = 2.70$ et $\gamma = 0.585$. Quant à la méthode d’assemblage des forêts arborescentes (Random Forest), l’espace hyper-complexe des fractionnements et des limites hiérarchiques fut traversé en long et en large sur un cycle de 150 explorations. Enfin, l’architecture colossale de XGBoost, riche de très multiples degrés de tension numérique (relatifs aux pénalisations mathématiques et aux coefficients d’érosion algorithmiques), a imposé au minimum 200 évaluations massives pour trouver sa configuration optimale.

2.6 Évaluation systématique des algorithmes isolés

2.6.1 Synthèse du classificateur SVM à noyau paramétrique

S’appuyant intimement sur la transformation des vecteurs de Yeats-Johnson corrélée à un renfort des minorités par SMOTE, l’architecture à vecteurs de supports calibrée offre un diagnostic mitigé.

TABLE 2.5 – Rendement quantifié concernant le classificateur SVM (configuration RBF)

Indicateur évaluatif	Constat chiffré
Exactitude générale (<i>Accuracy</i>)	0.8052
Mesure d’harmonie (F1-Score)	0.7000
Proportion discriminatoire (AUC-ROC)	0.8589
Fiabilité croisée (CV AUC 10-fold $\times$ 3)	0.8714 ± 0.0442
Ligne de démarcation optimale (Seuil)	0.339

Alors qu’une base discriminatoire (repérée par l’aire de 0.859) manifeste d’évidentes capacités de classement, la détresse du F1-Score (effondré à 0.700) souligne la difficulté chronique du système affineur à dépister les cas avérés de la pathologie. La contrainte du réglage probabiliste (recalculé drastiquement en deçà, à la cote singulière de 0.339) atteste fondamentalement d’une architecture intrinsèquement désorientée par le déséquilibre des probabilités asymétriques issues du modèle gaussien.

2.6.2 Évaluation du groupement d’arbres décisionnels (Random Forest)

Se déployant sur une trame arborescente densifiée de multiples nœuds de fractionnements aléatoires, la conception de la forêt aléatoire éclipse spectaculairement l’architecture vectorielle précédente. Flirtant presque continuellement au-delà des 0.94 de discrimination empirique, ce regroupement décisionnel affiche des statistiques d’exception. De plus, l’intervalle restrictif

TABLE 2.6 – Rendement quantifié concernant le modèle prédictif Random Forest

Indicateur évaluatif	Constat chiffré
Exactitude générale (<i>Accuracy</i>)	0.8896
Mesure d’harmonie (F1-Score)	0.8440
Proportion discriminatoire (AUC-ROC)	0.9453
Fiabilité croisée (CV AUC 10-fold $\times$ 3)	0.9378 ± 0.0242
Ligne de démarcation optimale (Seuil)	0.549

décelé aux marges d’erreur liées à la double vérification croisée confirme sans ambiguïté la fiabilité structurelle de la randomisation ensembliste.

2.6.3 Déploiement évaluatif de XGBoost

Désormais promu en qualité de standard absolu parmi la sphère algorithmique dédiée aux bases matricielles, le modèle de boosting de complexité extrême (XGBoost), dont les hyperparamètres ont été scrutés impitoyablement à travers le maillage Optuna, prend logiquement l’ascendant.

TABLE 2.7 – Rendement quantifié concernant l’infrastructure algorithmique XGBoost

Indicateur évaluatif	Constat chiffré
Exactitude générale (<i>Accuracy</i>)	0.8896
Mesure d’harmonie (F1-Score)	0.8440
Proportion discriminatoire (AUC-ROC)	0.9496
Fiabilité croisée (CV AUC 10-fold $\times$ 3)	0.9442 ± 0.0235
Ligne de démarcation optimale (Seuil)	0.639




FIGURE 2.8 – Matrices de confusion normalisées représentant les décisions finales (en pourcentages) des trois approches concurrentes (SVM, Random Forest et XGBoost) évaluées conjointement sur l’ultime cohorte dissimulée (154 patientes). La précision supérieure des approches ensemblistes pour dépister correctement les patientes diabétiques est ici directement chiffrée.

Les capacités du modèle s’incarnent parfaitement dans les matrices chiffrées (voir figure 2.8). L’agglomération algorithmique du XGBoost engendre un succès exceptionnel

lors de l'isolement pathologique de la cohorte mineure. Cette performance technique, atteignant plus de 85,19% de détection réelle des individus atteints, soulage par voie de conséquence la crainte des faux négatifs préjudiciables. En effet, dans la clinique journalière du praticien médical, accuser une non-détection d'une situation avérée a des implications considérablement plus fâcheuses qu'un doute provisoire non fondé (faux positif).




FIGURE 2.9 – Représentation détaillée des courbes de la fonction d'efficacité du récepteur (ROC) illustrant la primauté de l'architecture XGBoost par le gain incontestable de l'aire sous-jacente au profil.

L'inspection géométrique globale des taux d'omissions en fonction des classifications excessives (figure 2.9) vient graver dans la matrice la prépondérance irréfutable du système optimisé de gradient boosting.

2.7 Déploiement analytique d'architectures ensemblistes complexes

Afin d'ausculter l'ultime marge de progression, d'audacieuses combinaisons tentant la fusion synchrone des trois précurseurs ont été entreprises.

Sous sa forme dite *Soft Voting*, l'algorithme a harmonisé collégialement la projection de certitude des trois moteurs distincts (SVM, Random Forest et XGBoost). Il parvient in fine à un seuil discriminatoire s'élevant très fidèlement à 0.932 et consolide l'indice F1-score au point optimal de 0.845. Concrètement, cette approche offre une résilience louable car très réactive grâce au consensus multilatéral des estimateurs.

Les architectures de classe *Stacking*, plus exigeantes théoriquement, structurent la chaîne algorithmique en soumettant les outputs prédictifs rudimentaires vers des méta-apprenants régulateurs. D'un côté, lorsque le régulateur principal s'incarne en un analyseur logistique primitif (Régression Logistique), le modèle cumule 0.929 de taux d'AUC globale. D'un autre côté, en convoquant un deuxième étage d'architecture poussée combinant à nouveau XGBoost avec accès perméable, le taux final de l'aire culmine timidement à l'indice 0.939, ce qui limite globalement l'utilité pratique d'un tel empilement computationnel démesuré comparé au modèle individuel optimal.

3

ANALYSE DES RESULTATS, DISCUSSION ET PERSPECTIVES

3.1 Analyse des Résultats

3.1.1 Évaluation des Modèles Individuels (SVM, Random Forest, XGBoost)

Dans cette première phase d'analyse, nous comparons les performances des trois modèles d'apprentissage automatique de base (SVM, Random Forest et XGBoost) sur notre jeu de données de détection du diabète. Les métriques évaluées comprennent l'Accuracy (exactitude), la Précision, le Recall (sensibilité), le F1-Score et l'aire sous la courbe ROC (ROC-AUC).

D'après les résultats expérimentaux obtenus, le modèle **SVM avec noyau RBF** présente les performances les plus modestes, avec une Accuracy de 0.8052 et un F1-Score de 0.7000. Son Recall de 0.6481 indique une difficulté à identifier correctement tous les patients diabétiques.

En revanche, les modèles basés sur les arbres de décision offrent des résultats nettement supérieurs. Le **Random Forest** atteint une Accuracy de 0.8896 et un F1-Score de 0.8440, montrant une excellente capacité de généralisation. Le modèle **XGBoost** se distingue particulièrement avec des performances similaires en Accuracy (0.8896) mais un F1-Score légèrement supérieur (0.8496) et un Recall optimal de 0.8889, prouvant sa robustesse face à des données complexes et déséquilibrées.

3.1.2 Impact des Modèles Avancés (Voting Ensemble et Stacking)

Afin de repousser les limites des modèles individuels, plusieurs architectures d'apprentissage ensembliste avancées ont été testées : un *Soft Voting Ensemble*, un *Stacking avec Régression Logistique* et un *Stacking (v2) avec XGBoost* comme méta-apprenant.

Le modèle *Stacking v2*, qui permet au méta-apprenant d'accéder aux caractéristiques originales (passthrough), obtient d'excellents résultats avec un ROC-AUC de 0.9461. Cependant, son F1-Score (0.8077) et son Recall (0.7778) reste en deçà de ceux du modèle

XGBoost individuel. Le *Soft Voting Ensemble* présente quant à lui une approche équilibrée mais n'améliore pas significativement les performances par rapport aux meilleurs modèles de base (Accuracy de 0.8701).

Ces résultats démontrent que, bien que les méthodes de Stacking et de Voting soient structurellement plus complexes et théoriquement plus performantes, elles ne surpassent pas nécessairement un algorithme XGBoost rigoureusement optimisé, notamment grâce à notre recherche fine d'hyperparamètres via Optuna (plus de 200 essais).

3.1.3 Analyse Comparative et Sélection du Meilleur Modèle

Le tableau ci-dessous et la Figure 3.1 synthétisent les performances des différents modèles évalués :

Modèle	Accuracy	Precision	Recall	F1-Score	ROC-AUC	CV AUC
XGBoost	0.8896	0.8136	0.8889	0.8496	0.9517	0.9486
Stacking v2	0.8701	0.8400	0.7778	0.8077	0.9461	0.9455
Random Forest	0.8896	0.8364	0.8519	0.8440	0.9453	0.9378
Stacking (LR)	0.8766	0.8302	0.8148	0.8224	0.9317	0.9439
Voting Ensemble	0.8701	0.7931	0.8519	0.8214	0.9337	0.9384
SVM (RBF)	0.8052	0.7609	0.6481	0.7000	0.8589	0.8714

TABLE 3.1 – Comparaison des performances des modèles sur le jeu de test

À la lumière de ce tableau, **XGBoost** est sélectionné comme le meilleur modèle global. Il excelle sur la majorité des métriques, avec le ROC-AUC le plus élevé (0.9517) et une excellente stabilité en validation croisée (0.9486). Avec une Accuracy frôlant les 90%, il représente le compromis idéal entre précision de prédiction et sensibilité au dépistage.




FIGURE 3.1 – Comparatif multi-métriques de l’ensemble des modèles via un graphique en radar

3.2 Discussion

3.2.1 Impact Décisif du Prétraitement et de l’Ingénierie des Données

Une part majeure du succès de notre modèle réside dans la phase rigoureuse de préparation des données. L’application d’une stratégie d’imputation par classe (médiane) pour corriger les zéros aberrants (ex : taux de glucose ou tension artérielle nuls), combinée à la technique de Winsorization (1er et 99ème percentiles) pour atténuer l’impact des valeurs extrêmes, a considérablement purifié l’espace des descripteurs.

De plus, la distribution initiale des données souffrait d’un asymétrie de classes (500 non diabétiques / 268 diabétiques). L’utilisation de l’algorithme **Borderline-SMOTE**, couplée à une transformation de puissance (PowerTransformer, méthode Yeo-Johnson), a permis de générer des échantillons synthétiques de haute qualité près des frontières de décision. Par rapport à une approche basique sans ce pipeline avancé, les performances globales ont connu un bond exceptionnel : **+0.1364** en Accuracy (passant de 0.7532 à 0.8896) et **+0.2150** en F1-Score.

Il est également intéressant d’analyser l’importance des variables utilisées par les modèles, illustrée en Figure 3.2. Les caractéristiques cliniques (comme la glycémie, l’âge, le BMI et l’insuline) jouent un rôle prépondérant dans la prise de décision, avec des corrélations fortes mesurées via l’Information Mutuelle.




FIGURE 3.2 – Comparaison de l’importance des caractéristiques (Random Forest vs XGBoost)

3.2.2 Biais et Variance : Analyse des Courbes d’Apprentissage

Les courbes d’apprentissage (Figure 3.3) permettent d’ausculter le comportement des algorithmes vis-à-vis de la taille du corpus. On remarque que les réseaux d’arbres (RF, XGBoost) préservent une excellente validation croisée démontrant leur robustesse.




FIGURE 3.3 – Courbes d'apprentissage mesurant l'évolution de la qualité analytique (ROC-AUC) selon le volume de données fournies.

3.2.3 Interprétation Clinique des Métriques

Dans le cadre du diagnostic médical assisté par intelligence artificielle, particulièrement pour une pathologie silencieuse et grave comme le diabète, l'Accuracy globale n'est pas la seule métrique à observer. Il est fondamental de minimiser les *faux négatifs* (un patient malade diagnostiqué à tort comme sain), car un retard de prise en charge peut entraîner de lourdes complications.

C'est pourquoi l'optimisation a fortement ciblé le **Recall** (sensibilité) et le **F1-Score**. Selon le rapport de classification final de XGBoost, le modèle atteint un Recall de 0.8889 sur la classe "Diabétique". Cela signifie que l'algorithme identifie correctement près de 89% des patients réellement atteints de diabète, offrant ainsi un excellent outil de dépistage précoce limitant les risques de non-détection.

La Figure 3.4 illustre la matrice de confusion obtenue par les trois meilleurs modèles (XGBoost, Stacking v2, Random Forest) sur l'ensemble de test. Elle met en évidence la capacité de XGBoost à identifier la grande majorité des patients diabétiques (réduisant les faux négatifs à 11.1%). La performance globale comparative est également confirmée par la Figure 3.5, où la courbe ROC de XGBoost et des modèles d'ensemble dominent l'espace, résultant en d'excellents scores ROC-AUC (> 0.94).

L'analyse des courbes Précision-Rappel (Figure 3.6) apporte une dimension supplémentaire : dans ce corpus déséquilibré, ces courbes offrent une vision plus réaliste de l'efficacité algorithmique. Là encore, le modèle XGBoost s'avère supérieur, conservant un *Average Precision* très élevé face aux autres approches.

3.2.4 Limites de l'Étude Expérimentale

Malgré ces résultats très encourageants, l'étude présente certaines limites inhérentes au jeu de données "Pima Indians Diabetes". D'une part, la taille relativement modeste du dataset (768 individus dont seulement 154 en jeu de test) rend les scores d'évaluation sensibles aux variations d'échantillonnage, bien que la validation croisée stratifiée atténue ce risque.

D'autre part, la technique de suréchantillonnage Borderline-SMOTE, bien que très efficace, génère des données synthétiques. Cela implique une forte dépendance aux paramètres du SMOTE, et le modèle pourrait potentiellement réagir différemment en condition réelle face à une distribution de patients fondamentalement nouvelle.




FIGURE 3.4 – Matrices de Confusion des algorithmes les plus performants




FIGURE 3.5 – Courbes ROC de l'ensemble des modèles évalués




FIGURE 3.6 – Courbes Précision-Rappel pour tous les modèles

3.2.5 Confrontation des résultats avec la littérature

Si l’on compare nos performances définitives aux travaux examinés lors de notre revue de littérature (Chapitre 4), l’approche intégrée proposée dans ce projet s’inscrit au-delà de nombreuses références. Par exemple, tandis que Zou et al. faisaient aboutir un Random Forest à 80,84% d’exactitude (sur PIDD), notre tuning hyper-paramétrique repousse ce score à 88,96% (pour XGBoost et Random Forest). Similairement, bien que Iparraguirre-Villanueva et al. valident l’usage du système SMOTE (atteignant 79,6% avec K-NN), l’intégration combinée d’un *Borderline-SMOTE*, d’une transformation *Yeo-Johnson* et d’un Feature Engineering médical (Ratio Glucose/Insuline, BMI_Age) démontre dans cette étude une synergie empirique très nette. Le tableau ci-dessous synthétise ce saut qualitatif par rapport à l’ancien pipeline brut du dataset (sans optimisation avancée).

TABLE 3.2 – Mesure de l’impact des optimisations sur la précision finale du XGBoost

Métrique	Approche Traditionnelle	Approche Optimisée (Pipeline actuel)	Gain mesuré
Accuracy	75,32 %	88,96 %	+13,64 %
F1-Score	63,46 %	84,96 %	+21,50 %
ROC-AUC	82,61 %	95,17 %	+12,56 %

3.3 Perspectives

3.3.1 Amélioration Continue du Modèle

Plusieurs pistes techniques pourraient être envisagées pour affiner davantage ce système d'aide au diagnostic. L'intégration de réseaux de neurones profonds (Deep Learning, comme les perceptrons multicouches testés en amont) pourrait capturer des interactions non linéaires complexes supplémentaires. De plus, une collecte de données cliniques issues d'hôpitaux locaux, plus vastes et plus diversifiées génétiquement que la population originelle (Pima Indians), serait nécessaire pour valider formellement la généralisation géographique et démographique du modèle de détection.

3.3.2 Déploiement et Application Pratique

D'un point de vue architectural, l'aboutissement de ce projet ne réside pas uniquement dans l'entraînement d'un modèle performant, mais dans sa capacité à être déployé. La prochaine étape logique consiste à encapsuler ce modèle XGBoost au sein d'une architecture de **Système Multi-Agents (SMA)** ou d'une API de type microservice. Un agent intelligent "Diagnostic" pourrait alors s'interfacer en temps réel avec le dossier médical numérique des patients, analyser en continu leurs constantes biologiques (glycémie, IMC, tension artérielle) et alerter proactivement le personnel médical en cas de risque élevé, réalisant ainsi l'objectif premier des architectures de systèmes intelligents au service de la santé.

CONCLUSION GÉNÉRALE

Ce projet académique et expérimental avait pour vocation première de jauger, sous un prisme strictement qualitatif et quantitatif orienté vers la clinique, les performances respectives de trois piliers fondamentaux de l'apprentissage automatique supervisé (la modélisation par Vecteurs de Support SVM, la construction ensembliste des Forêts Aléatoires et l'optimisation par Descente de Gradient Extrême XGBoost) dans le cadre redoutable de la prédiction systémique précoce du diabète de type 2. Cette analyse a pris pour fondation exclusive la base de données de référence Pima Indians Diabetes Database.

Synthèse des contributions et approfondissements théoriques

La **Partie I** de l'ouvrage s'est attelée à bâtir l'infrastructure théorique requise pour saisir les subtilités mécaniques présidant aux déductions des algorithmes choisis. Au sujet des SVM, nous avons déployé rigoureusement le corpus mathématique gérant les hyperplans à marge maximale, conjugué à la résolution du problème dual de Lagrange et à l'astuce de projection spatiale (noyau), en expliquant par la théorie les défaillances inhérentes de la méthode face aux densités tabulaires limitées. Concernant les Forêts Aléatoires, l'examen s'est focalisé sur la germination des arbres de classification, magnifiée par les lois de la sélection stochastique garantissant une inestimable robustesse face au surapprentissage. Pour finir, le spectre de l'algorithme XGBoost a été exploré en décortiquant minutieusement l'approche d'approximation du second ordre de la fonction de perte (la formule de Taylor) qui, lorsqu'elle est assortie à la répression structurelle des nœuds, garantit un apprentissage virtuellement inattaquable.

L'étude liminaire (chapitre 4) a de surcroît mis en évidence la cacophonie méthodologique régnant au sein des publications antérieures, dénonçant avec vigueur l'hégémonie de métriques trompeuses (comme la précision globale prise isolément) et les graves insuffisances touchant tant à l'explicabilité du modèle qu'à sa propension à se généraliser en dehors de son contexte initial.

La **Partie II** a, pour sa part, matérialisé un protocole expérimental à la fois souverain et intolérant aux approximations, s'illustrant par les accomplissements suivants :

1. **Un assainissement chirurgical de la matrice d'origine**, recourant à une substitution par la médiane segmentée selon la classe cible, secondée par la neutralisation des valeurs aberrantes aux percentiles asymétriques extrêmes, ainsi qu'une normalisation mathématique profonde (Yeo-Johnson) imposée par la nature distordue des données médicales.
2. **Une ingénierie biomathématique de très haut vol**, donnant naissance à 8 indicateurs synthétiques greffés sur le socle originel. L'incidence du paramètre **Risk_Score** (corrélation de Pearson atteignant +0.535) et de la collusion **Glucose_BMI** (+0.526) certifie la nécessité absolue de sceller l'alliance entre pragmatisme médical et modélisation algorithmique, portant l'architecture finale à 16 facteurs d'intérêts.
3. **Une riposte structurelle au déficit des diagnostics pathologiques certifiés**, s'incarnant par l'implémentation du protocole Borderline-SMOTE, permettant de symétriser numériquement les profils simulés (400 face à 400 dans le lot d'apprentissage) sans perturber fondamentalement la topologie de l'espace de décision.

4. **Une traversée d'optimisation probabiliste orchestrée par Optuna** (englobant 200 évaluations massives concernant XGBoost), traçant la voie vers des configurations paramétriques d'exception hors de portée d'une simple exploration naïve.

Bilan chiffré des investigations

Les expérimentations attestent catégoriquement de l'effondrement des architectures isolées au bénéfice absolu des procédés de modélisation ensembliste. Au faîte de la hiérarchie technique, **XGBoost** et **Random Forest** coiffent conjointement les sommets prédictifs avec une exactitude figée à 89,0% associée à un indice F1 de 0.844. Sur le versant évaluant l'homogénéité de discrimination, ils brisent les plafonds avec des aires colossales respectives fixées à **0.9496** et **0.9453**. L'écart béant instauré par rapport aux manipulations sans relief observées ordinairement (+20,9 points d'ascension sur l'indice F1-Score comparativement à l'état originel des données) entérine solennellement le succès de l'expérimentation.

Malgré des paramétrages poussés dans ses retranchements optimaux, l'hyperplan vectoriel (SVM) ne hissera son bouclier qu'à 0.859 d'aire discriminatoire, accablé par un index de rappel dramatiquement insuffisant. Cette asphyxie mécanique prouve son inadaptation foncière pour s'accommoder des intrications masquées nichées dans des tableaux cliniques moyennement denses.

En outre, il est établi que la surabondance systémique (méta-modèles ou coalitions de votes) s'est avérée stérile pour extirper plus de sens que le parangon de la session (XGBoost), bloquée par l'inévitable corrélation partagée par les pronostics des modèles de premier plan.

Carences intrinsèques et desseins futurs

Si le triomphe de l'expérimentation impressionne, il convient de ne pas se méprendre sur ses assises périlleuses. La déduction algorithmique restreinte de manière claustrale aux seules amérindiennes Pimas ne saurait octroyer de sauf-conduit universel. D'autre part, la reconstruction spéculative frôlant les 48,7% de l'attribut majeur (Insuline) instaure indéniablement un artéfact statistique lourd de conséquences potentielles. Enfin, le silence opaque et imperturbable entourant les ramifications décisionnelles intimes de l'algorithme (manque d'explicabilité par profil individuel) reste pénalisant d'un point de vue médical.

Surgissent alors des futurs chantiers de recherche majeurs orientés vers l'adhésion d'architectures tabulaires d'explicabilité (à l'instar des protocoles mathématiques préconisés par Shapley) pour légitimer la sentence prédictive aux yeux du praticien humain. Ils appelleront de surcroît à sonder un pan entier de biométries non intrusives, esquissant l'horizon d'un pronostic de masse indolore et accessible techniquement à l'échelle transcontinentale.

Dernière observation algorithmique

L'investigation vient de sceller sans équivoque un postulat majeur de la science de la donnée contemporaine. L'élection fastueuse d'un solveur de dernière génération importe intrinsèquement beaucoup moins que l'acuité et le ciselage investis à métamorphoser la substance primitive en vecteurs clairs, balancés et cliniquement chargés d'instructions. Au carrefour exact de la médecine interne et des statistiques matricielles rigoureuses, cet ouvrage a démontré qu'une intelligence prédictive infaillible exige avant tout des données rigoureusement respectées et modélisées avec la plus haute méticulosité scientifique.

BIBLIOGRAPHIE

- Bertsekas, D. (2009). *Convex optimization theory*, volume 1. Athena Scientific.
- Boser, B. E., Guyon, I. M., and Vapnik, V. N. (1992). A training algorithm for optimal margin classifiers. In *Proceedings of the fifth annual workshop on Computational learning theory*, pages 144–152.
- Chen, T. and Guestrin, C. (2016). Xgboost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Devroye, L., Györfi, L., and Lugosi, G. (1996). Vapnik-chervonenkis theory. In *A probabilistic theory of pattern recognition*, pages 187–213. Springer.
- Gowthami, S., Venkata Siva Reddy, R., and Riyaz Ahmed, M. (2024). Exploring the effectiveness of machine learning algorithms for early detection of type-2 diabetes mellitus. *Measurement : Sensors*, 31 :100983.
- Gündoğdu, S. (2023). Efficient prediction of early-stage diabetes using XGBoost classifier with random forest feature selection technique. *Multimedia Tools and Applications*, 82 :34163–34181. PMC Open Access Subset.
- Iparraguirre-Villanueva, O., Espinola-Linares, K., Flores Castañeda, R. O., and Cabanillas-Carbonell, M. (2023a). Application of machine learning models for early detection and accurate classification of Type 2 Diabetes. *Diagnostics*, 13(14) :2383. Open Access — CC BY.
- Iparraguirre-Villanueva, O., Espinola-Linares, K., Flores Castañeda, R., and Cabanillas-Carbonell, M. (2023b). Application of machine learning models for early detection and accurate classification of type 2 diabetes. *Diagnostics*, 13(14) :2383.
- Juwono, F., Wong, W., Verma, S., and Shee, N. (2024). Machine learning and deep learning for diabetes detection : A comprehensive review of techniques, datasets, and preprocessing. *Multimedia Tools and Applications*.
- Kavakiotis, I., Tsave, O., Salifoglou, A., Maglaveras, N., Vlahavas, I., and Chouvarda, I. (2017). Machine learning and data mining methods in diabetes research. *Computational and Structural Biotechnology Journal*, 15 :104–116. Open Access — CC BY.
- Khanam, J. J. and Foo, S. Y. (2021). A comparison of machine learning algorithms for diabetes prediction. *ICT Express*, 7(4) :432–439. Open Access — CC BY-NC-ND.
- Lv, K., Cui, C., Fan, R., Zha, X., Wang, P., Zhang, J., Zhang, L., Ke, J., Zhao, D., Cui, Q., and Yang, L. (2023). Detection of diabetic patients in people with normal fasting glucose using machine learning. *BMC Medicine*, 21(1) :342.

- Saihood, Q. and Sonuç, E. (2023). A practical framework for early detection of diabetes using ensemble machine learning models. *Turkish Journal of Electrical Engineering and Computer Sciences*, 31(4) :722–740.
- Sisodia, D. and Sisodia, D. S. (2018). Prediction of diabetes using classification algorithms. *Procedia Computer Science*, 132 :1578–1585. Open Access — CC BY-NC-ND.
- Wee, B., Sivakumar, S., Lim, K., Wong, W., and Juwono, F. (2024). Diabetes detection based on machine learning and deep learning approaches. *Multimedia Tools and Applications*, 83 :24153–24185. Open Access via PMC.
- Zou, Q., Qu, K., Luo, Y., Yin, D., Ju, Y., and Tang, H. (2018). Predicting diabetes mellitus with machine learning techniques. *Frontiers in Genetics*, 9 :515. Open Access — CC BY.

ANNEXE

Ressources du Projet

Dans un souci de transparence et de reproductibilité, l'intégralité des ressources techniques produites dans le cadre de ce projet a été rendue accessible publiquement.

Vous trouverez ci-dessous les liens directs vers les codes sources des modèles implémentés (Notebooks Python) ainsi que vers le dépôt contenant le code source LaTeX de ce rapport.

Code Source des Modèles (Notebooks)

Les expérimentations, incluant le prétraitement des données, l'entraînement des modèles (SVM, Random Forest, XGBoost) et l'optimisation via Optuna, sont disponibles sur les plateformes suivantes :

- **Google Colab** : <https://colab.research.google.com/drive/1cDUPJdSarfPoQwNRBohoSpVlFusp=sharing>
- **Kaggle** : <https://www.kaggle.com/code/vergezlekanekenfack/diabetes-ultra-optimized>

Code Source du Rapport (LaTeX)

L'ensemble des fichiers sources nécessaires à la compilation de ce document est hébergé sur GitHub :

- **Dépôt GitHub** : <https://github.com/YAxelY/arch-sys-int-rapport>