

REPUBLIQUE DU CAMEROUN
Paix-Travail-Patrie

MINISTRE DE L'ENSEIGNEMENT
SUPERIEUR

UNIVERSITE DE DSCHANG

FACULTE DES SCIENCES

B.P.: 96 Dschang-Cameroun-Tel :
(237) 233
45 13 81
Email : udsrectorat@univ-
dschang.org



REPUBLIC OF CAMEROON
Peace-Work-Fatherland

MINISTRY OF HIGHER
EDUCATION

UNIVERSITY OF DSCHANG

FACULTY OF SCIENCE

PO BOX: 96 Dschang-Cameroun-Tel:
(237)
233 45 13 81
Email: udsrectorat@univ-
dschang.org

Projet d'Architecture des Systèmes Intelligents (IAR521)

**THEME : SUPPORT VECTOR MACHINES, RANDOM
FORESTS, EXTREME GRADIENT BOOSTING**

Niveau : MASTER 2

Option : Intelligence Artificielle

Sous la supervision de :

Pr. KENGNE TCHENDJI Vianney

Maître de Conférences

Membres du groupe 3	
LEKANE KENFACK VERGEZ	CM-UDS-21SCI0569
MBOUMEU YOUNBI AXEL AUBIN	CM-UDS-21SCI0589
MOUNCHIKPOU MEFIRE HAMED KAMAL	CM-UDS-21SCI0601
NJIH ASONYU SENGE	CM-UDS-21SCI0625

Année académique : 2025 - 2026

Table des matières

Table des matières	i
Table des figures	v
Liste des tableaux	vi
Liste des Abréviations	vii
Résumé	viii
Introduction Générale	1
I FONDLEMENTS THEORIQUES ET ETAT DE L'ART	5
1 Machine à vecteurs supports (MVS)	6
1.1 Introduction	6
1.2 Objectifs	6
1.3 Principe Général	7
1.4 Machine à vecteurs supports linéaire	7
1.4.1 Problème de classification, SVM : C'est quoi, au juste ?	7
1.5 Formalisme des SVM	9
1.6 Principe de la méthode	10
1.7 Calcul de la marge	11
1.8 Machine à vecteurs supports non linéaire	12
1.8.1 Introduction aux SVM non linéaires	12
1.8.2 Le problème des données non linéaires	13
1.8.3 Principe des SVM non linéaires	13
1.8.4 Plongée en dimension supérieure	15
1.8.5 Le « Kernel Trick » (Astuce du noyau)	16
1.8.6 Les principaux noyaux utilisés	18
2 Random Forests (RF)	21
2.1 Introduction	21
2.2 Fondements théoriques : l'apprentissage en ensemble	21
2.3 Rappel sur les arbres de décision	23
2.3.1 Critères de séparation	23
2.3.2 Construction récursive et surapprentissage	24
2.4 Algorithme des forêts aléatoires	24

2.4.1	Étape 1 : Échantillonnage bootstrap	24
2.4.2	Étape 2 : Sélection aléatoire des caractéristiques	25
2.4.3	Étape 3 : Croissance des arbres	25
2.4.4	Étape 4 : Agrégation des prédictions	25
2.4.5	Algorithm Pseudocode	26
2.5	Hyperparamètres clés et leurs effets	26
2.5.1	Nombre d'arbres (<code>n_estimators</code> ou <code>ntree</code>)	26
2.5.2	Nombre de caractéristiques par division (<code>max_features</code> ou <code>mtry</code>)	27
2.5.3	Contrôle de la profondeur des arbres	27
2.5.4	Taille des échantillons bootstrap (<code>max_samples</code>)	27
2.5.5	Stratégie pratique d'ajustement	28
2.6	Estimation de l'erreur <i>Out-of-Bag</i> (OOB)	28
2.6.1	Mathématiques derrière l'OOB	28
2.6.2	Fonctionnement de l'erreur OOB	29
2.6.3	Valeur et avantages de l'OOB	29
2.6.4	Applications pratiques	29
2.6.5	Limites	30
2.7	Mesures de l'importance des variables	30
2.7.1	Diminution moyenne de l'impureté (MDI)	30
2.7.2	Diminution moyenne de la précision (MDA) / Importance par permutation	31
2.7.3	Considérations pratiques	32
2.7.4	Exemple d'interprétation	32
2.8	Avantages des Forêts Aléatoires	32
2.8.1	Robustesse au surapprentissage	32
2.8.2	Prétraitement minimal des données	32
2.8.3	Gestion des valeurs manquantes	33
2.8.4	Non-linéarité naturelle	33
2.8.5	Parallélisation et scalabilité	33
2.8.6	Validation intégrée	33
2.8.7	Avantages supplémentaires	34
2.9	Limitations et Défis	34
2.9.1	Difficultés d'interprétation	34
2.9.2	Besoins en mémoire	34
2.9.3	Vitesse de prédiction	35
2.9.4	Performance sur données hautement dimensionnelles et clairsemées	35
2.9.5	Limites d'extrapolation	35
2.9.6	Autres limitations	35
3	XGBoost (eXtreme Gradient Boosting)	37
3.1	Introduction	37
3.2	Principe du Gradient Boosting	37
3.2.1	Intuition : apprentissage par correction d'erreurs	37
3.2.2	Formulation mathématique du gradient boosting	38
3.2.3	Limitations du gradient boosting classique	38
3.3	XGBoost : Innovations Mathématiques	38
3.3.1	Fonction objectif régularisée	38

3.3.2	Approximation de Taylor de second ordre	39
3.3.3	Calcul du poids optimal des feuilles	39
3.3.4	Score de qualité d'une structure d'arbre	39
3.4	Fonctionnalités Spécifiques de XGBoost	40
3.4.1	Gestion native des valeurs manquantes	40
3.4.2	Gestion du déséquilibre de classes	40
3.4.3	Subsampling stochastique	40
3.4.4	Early stopping	40
3.5	Optimisations Systèmes	41
3.5.1	Parallélisation	41
3.5.2	Scalabilité	41
3.6	Hyperparamètres Clés	41
3.6.1	Contrôle de la complexité	41
3.6.2	Régularisation et Apprentissage	41
3.6.3	Sampling et Autres	41
3.7	Avantages et Limites	41
3.7.1	Avantages	41
3.7.2	Limites	42
3.7.3	Comparaison : XGBoost vs Random Forest	42
3.8	Conclusion	42
4	État de l'art sur la détection du diabète à l'aide des méthodes d'apprentissage automatique	43
4.1	Introduction	43
4.2	Approches traditionnelles de détection du diabète	44
4.3	Approches basées sur l'apprentissage automatique	45
4.4	Études comparatives utilisant SVM, Random Forest et XGBoost	46
4.4.1	Comparaisons sur la base PIDDD	46
4.4.2	Comparaisons multi-algorithmes incluant XGBoost	47
4.4.3	Apport des techniques de prétraitement et d'optimisation	47
4.5	Analyse critique des travaux existants	48
4.5.1	Hétérogénéité des protocoles expérimentaux	48
4.5.2	Déséquilibre des classes et biais des métriques	48
4.5.3	Généralisation limitée	48
4.5.4	Explicabilité insuffisante	48
4.5.5	Optimisation du seuil de décision	48
4.6	Positionnement et apport du présent travail	49
II	ÉTUDE EXPÉRIMENTALE ET APPLICATION AU CAS DE LA DETECTION DU DIABETE	50
5	Conception méthodologique et évaluation expérimentale des modèles de détection du diabète	51
5.1	Introduction	51
5.2	Présentation du jeu de données	51
5.2.1	Description générale	51
5.2.2	Description des attributs	51

5.2.3	Distribution des classes	51
5.3	Pipeline de prétraitement avancé	53
5.3.1	Détection et imputation des valeurs impossibles	53
5.3.2	Traitement des valeurs aberrantes (Outlier Winsorization)	53
5.3.3	Ingénierie des caractéristiques	53
5.3.4	Partitionnement, normalisation et sur-échantillonnage	55
5.4	Sélection des caractéristiques	55
5.5	Configuration expérimentale et optimisation des hyperparamètres	56
5.5.1	Protocole d'évaluation	56
5.5.2	Optimisation des hyperparamètres avec Optuna	56
5.6	Résultats des modèles individuels	56
5.6.1	SVM à noyau RBF	56
5.6.2	Random Forest	57
5.6.3	XGBoost	57
5.7	Résultats des méthodes ensemblistes avancées	58
5.7.1	Soft Voting Ensemble	58
5.7.2	Stacking	58
5.7.3	Tableau comparatif global	58
6	Analyse des résultats, discussion et perspectives	60
6.1	Introduction	60
6.2	Analyse comparative des modèles	60
6.2.1	Hierarchie des performances et écarts significatifs	60
6.2.2	Analyse du compromis Précision-Rappel en contexte clinique	60
6.2.3	Rôle de l'optimisation du seuil de décision	61
6.3	Interprétation des résultats à la lumière des fondements théoriques	61
6.3.1	Pourquoi les méthodes ensemblistes surpassent le SVM sur ce jeu de données ?	61
6.3.2	Analyse de l'importance des variables	62
6.3.3	Gain apporté par le pipeline d'optimisation	62
6.4	Discussion critique	63
6.4.1	Validité externe des résultats	63
6.4.2	Biais d'imputation	63
6.4.3	Absence d'interprétabilité locale	63
6.4.4	Reproductibilité	63
6.5	Positionnement par rapport à l'état de l'art	64
6.6	Perspectives	64
	Conclusion Générale	66
	BIBLIOGRAPHIE	69
	ANNEXES	71

Table des figures

1.1	L'objet à classer (le triangle noir) est-il un rond rouge ou bien un carré bleu ?	8
1.2	Notre SVM, muni des données d'entraînement (les carrés bleus et les ronds rouges d'ejà indiqués comme tels par l'utilisateur), a tranché : le triangle noir est en fait un carre bleu	9
1.3	Schéma illustratif : groupe H+ et H-	12
1.4	Données d'entraînement non linéairement séparables	14
1.5	Illustration : données sur une droite	15
1.6	Données d'entraînement après projection dans l'espace $\mathbb{R}^2$	16
2.1	Fonctionnement du Random Forest	23
2.2	Random Forest	26
2.3	Bagging vs Boosting	26
2.4	Overfitting vs Underfitting	33

Liste des tableaux

3.1	Comparaison synthétique : XGBoost vs Random Forest	42
4.1	Synthèse des principales études comparatives de ML pour la détection du diabète	47
5.1	Description des attributs de la base de données PIDDD	52
5.2	Volume d'imputation des valeurs nulles par attribut	53
5.3	Valeurs cappées par la winsorisation (p1/p99)	54
5.4	Nouvelles caractéristiques construites et leur corrélation avec la variable cible	54
5.5	Scores d'information mutuelle des 16 caractéristiques	55
5.6	Résultats du SVM (RBF) sur l'ensemble de test	57
5.7	Résultats du Random Forest sur l'ensemble de test	57
5.8	Résultats XGBoost sur l'ensemble de test	57
5.9	Rapport de classification détaillé — XGBoost (meilleur modèle)	58
5.10	Tableau comparatif final de tous les modèles	59
6.1	Comparaison du rappel sur la classe diabétique (classe positive)	61
6.2	Comparaison pipeline basique vs pipeline optimisé (XGBoost)	62
6.3	Positionnement des résultats obtenus face à l'état de l'art sur la PIDDD	64

Liste des Abréviations

ADA	American Diabetes Association
ADASYN	Adaptive Synthetic Sampling
AUC-ROC	Area Under the Receiver Operating Characteristic Curve
BNB	Bernoulli Naive Bayes
CART	Classification and Regression Trees
DL	Deep Learning (Apprentissage Profond)
DT	Decision Tree (Arbre de Décision)
F1	F1-Score (moyenne harmonique de la précision et du rappel)
GBM	Gradient Boosting Machine
K-NN	K-Nearest Neighbors (K Plus Proches Voisins)
LR	Logistic Regression (Régression Logistique)
MDA	Mean Decrease in Accuracy (Diminution Moyenne de la Précision)
MDI	Mean Decrease in Impurity (Diminution Moyenne de l'Impureté)
ML	Machine Learning (Apprentissage Automatique)
MNIST	Modified National Institute of Standards and Technology (base d'images)
mRMR	Minimum Redundancy Maximum Relevance (sélection de variables)
MSE	Mean Squared Error (Erreur Quadratique Moyenne)
MVS	Machine à Vecteurs de Support (voir SVM)
NB	Naive Bayes (Classifieur Naïf de Bayes)
OOB	Out-of-Bag (échantillons non utilisés lors du bootstrap)
PCA	Principal Component Analysis (Analyse en Composantes Principales)
PIDD	Pima Indians Diabetes Database
RBF	Radial Basis Function (Noyau Gaussien)
RF	Random Forest (Forêt Aléatoire)
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
SVM	Support Vector Machine (Machine à Vecteurs de Support)
XGBoost	eXtreme Gradient Boosting

Résumé

Le diabète sucré constitue l'un des enjeux de santé publique les plus critiques du 21^e siècle, touchant plus de 500 millions de personnes à travers le monde. Sa détection précoce est essentielle pour prévenir des complications graves et réduire la charge des systèmes de santé. Dans ce contexte, les méthodes d'apprentissage automatique supervisé offrent des perspectives prometteuses pour l'exploitation des données cliniques à des fins diagnostiques.

Ce travail présente une évaluation comparative rigoureuse de trois algorithmes de machine learning — les **Machines à Vecteurs de Support (SVM)**, les **Forêts Aléatoires (Random Forests)** et **XGBoost** — appliqués à la classification du risque diabétique sur la base de données *Pima Indians Diabetes Database* (PIDD). Ce jeu de données, composé de 768 patientes issues de la communauté Pima présentant une prévalence élevée de diabète de type 2, regroupe huit variables cliniques clés telles que la glycémie plasmatique, l'indice de masse corporelle, l'insulinémie, la pression artérielle et la fonction de prédisposition héréditaire.

Dans un premier temps, les fondements théoriques de chacun des trois algorithmes sont présentés : le formalisme de la maximisation de la marge et l'astuce du noyau pour les SVM, les mécanismes de bagging et de sélection aléatoire des caractéristiques pour les forêts aléatoires, ainsi que le gradient boosting régularisé et l'approximation de Taylor de second ordre propres à XGBoost. Un état de l'art de l'application de ces méthodes à la détection du diabète est ensuite conduit, soulignant les limites des approches existantes et motivant les choix méthodologiques retenus dans ce travail.

Sur le plan expérimental, les trois modèles sont entraînés et évalués selon un protocole strict incluant une validation croisée, une gestion explicite du déséquilibre de classes (environ 65 % de cas négatifs contre 35 % de cas positifs), ainsi qu'une optimisation des hyperparamètres. L'évaluation repose sur un ensemble complet de métriques cliniquement pertinentes : précision (*accuracy*), rappel (*recall*), F1-score, aire sous la courbe ROC (AUC-ROC) et matrice de confusion.

Les résultats expérimentaux révèlent que **XGBoost** obtient les meilleures performances globales, avec notamment les scores AUC-ROC et F1 les plus élevés, confirmant la supériorité des méthodes de boosting par gradient pour ce type de tâche clinique. Les **Forêts Aléatoires** présentent des performances comparables, avec l'avantage d'une plus grande robustesse au surapprentissage et d'une intégration naturelle de l'estimation d'erreur *out-of-bag*. Les **SVM** avec noyau RBF offrent de bonnes performances sur les métriques de précision mais se montrent plus sensibles aux réglages d'hyperparamètres et au déséquilibre des classes. La glycémie plasmatique ressort systématiquement comme le prédicteur le plus informatif dans les trois modèles, en accord avec les connaissances médicales établies.

Ces travaux contribuent à fournir une base comparative reproductible et cliniquement orientée pour le choix d'un algorithme de détection du diabète, et ouvrent des perspectives vers des approches hybrides et des analyses d'explicabilité plus poussées à l'aide d'outils tels que SHAP.

Mots-clés : Apprentissage automatique, Diabète, PIDD, SVM, Forêts Aléatoires, XGBoost, Classification, AUC-ROC, Données médicales.

INTRODUCTION GÉNÉRALE

Contexte et enjeux de la détection du diabète

Le diabète constitue l'une des maladies chroniques les plus répandues à l'échelle mondiale, représentant un défi majeur pour les systèmes de santé publique. Selon l'Organisation Mondiale de la Santé (OMS), le nombre de personnes atteintes de diabète a quadruplé depuis 1980, atteignant aujourd'hui plus de 500 millions d'individus dans le monde, avec une prévalence croissante aussi bien dans les pays développés que dans les pays en développement. Cette maladie, caractérisée par une hyperglycémie chronique résultant d'une insuffisance de production ou d'utilisation de l'insuline, entraîne de graves complications à long terme : maladies cardiovasculaires, insuffisance rénale, neuropathies et cécité.

Au-delà de ses conséquences sanitaires directes, le diabète génère des coûts économiques considérables, tant pour les patients que pour les systèmes de santé. Son diagnostic tardif, fréquent dans les régions à ressources limitées, aggrave le pronostic et alourdit la charge thérapeutique. Dans ce contexte, la détection précoce et fiable du diabète constitue un enjeu clinique et économique de premier ordre, justifiant le recours à des approches innovantes capables d'exploiter les données médicales disponibles.

Motivation du recours aux méthodes d'apprentissage automatique

Face à la complexité des mécanismes biologiques impliqués dans le diabète et à la multidimensionnalité des données cliniques (glycémie, indice de masse corporelle, pression artérielle, âge, antécédents familiaux, etc.), les approches diagnostiques traditionnelles reposant sur des seuils cliniques fixes atteignent rapidement leurs limites. Ces méthodes ne permettent pas de capturer les interactions non linéaires entre les variables, ni de personnaliser le diagnostic en fonction du profil individuel du patient.

L'apprentissage automatique (*machine learning*) offre une alternative particulièrement prometteuse. Grâce à leur capacité à identifier des patterns complexes dans des jeux de données de grande dimension, les algorithmes supervisés peuvent apprendre à discriminer les patients diabétiques des individus sains avec une précision souvent supérieure à celle des critères cliniques classiques. Ils permettent également d'intégrer de manière cohérente des variables hétérogènes et de produire des scores de risque individualisés, ouvrant la voie à une médecine prédictive et préventive plus efficace.

Problématique de recherche

Si plusieurs algorithmes d'apprentissage supervisé ont été appliqués à la détection du diabète dans la littérature, le choix de l'algorithme optimal demeure une question ouverte. En effet, différents modèles reposent sur des hypothèses et des architectures fondamentalement distinctes, ce qui se traduit par des comportements variés selon les caractéristiques du jeu de données : dimensionnalité, présence de valeurs manquantes, déséquilibre entre classes, ou encore bruit dans les mesures cliniques.

La problématique centrale de ce travail peut donc être formulée comme suit : *parmi les algorithmes de machine learning supervisé (Support Vector Machines (SVM), Random Forests et XGBoost), lequel offre les meilleures performances pour la détection du diabète,*

et dans quelles conditions chacun est-il préférable ? Cette question soulève des enjeux à la fois théoriques, liés aux fondements mathématiques de chaque modèle, et pratiques, relatifs à leur utilisabilité en contexte clinique réel.

Objectifs du travail

Ce rapport poursuit trois objectifs complémentaires.

Premièrement, il s'agit de présenter de manière rigoureuse les fondements théoriques des trois algorithmes étudiés (SVM, Random Forests et XGBoost) en mettant en évidence les propriétés qui conditionnent leurs performances sur des données médicales.

Deuxièmement, ce travail vise à construire un cadre d'évaluation comparative structuré, intégrant des métriques de classification classiques (précision, rappel, F1-score, AUC-ROC) ainsi que des considérations pratiques liées au déploiement clinique, notamment la gestion du déséquilibre des classes et l'interprétabilité des décisions.

Troisièmement, ce travail cherche à formuler des recommandations concrètes sur le choix algorithmique en fonction des contraintes du contexte médical : disponibilité des données, exigences de temps de réponse, besoin d'explicabilité pour les praticiens de santé, et robustesse face aux données imparfaites.

Démarche générale adoptée

Pour atteindre ces objectifs, une démarche en trois temps a été adoptée. Dans un premier temps, une étude théorique approfondie des trois algorithmes est conduite, portant sur leurs mécanismes d'apprentissage, leurs hyperparamètres clés et leurs comportements face aux spécificités des données médicales. Dans un second temps, un état de l'art est réalisé afin de recenser les travaux existants sur l'application de ces méthodes à la détection du diabète, et d'identifier les lacunes que ce travail cherche à combler. Enfin, une évaluation expérimentale est menée sur un jeu de données réel de patients, permettant une comparaison empirique rigoureuse des trois modèles selon plusieurs axes de performance.

Une attention particulière est portée à la gestion du déséquilibre des classes ; les cas positifs (diabétiques) étant généralement moins représentés, ainsi qu'à l'optimisation du seuil de décision, deux facteurs critiques pour la pertinence clinique des prédictions.

Organisation du rapport

Ce rapport est structuré en six parties complémentaires. Le **Chapitre 1** est consacré aux Support Vector Machines (SVM), en couvrant leur formalisme mathématique, le principe de maximisation de la marge et l'astuce du noyau pour les données non linéairement séparables. Le **Chapitre 2** présente les Random Forests, depuis les fondements de l'apprentissage en ensemble jusqu'aux mécanismes de bagging, de sélection aléatoire des caractéristiques et d'estimation de l'erreur out-of-bag. Le **Chapitre 3** détaille XGBoost, en insistant sur ses innovations mathématiques : régularisation, approximation de Taylor de second ordre, et ses optimisations systèmes. Le **Chapitre 4** propose un état de l'art sur l'application des méthodes d'apprentissage automatique à la détection du diabète. Le

Chapitre 5 présente la méthodologie et les résultats expérimentaux de l'évaluation comparative des trois modèles. Enfin, le **Chapitre 6** synthétise les résultats et formule des recommandations pratiques pour le choix du modèle en contexte clinique. Une conclusion générale clôt le document.

Partie I

FONDEMENTS THEORIQUES ET ETAT DE L'ART

Chapitre 1

Machine à vecteurs supports (MVS)

1.1 Introduction

Les *machines à vecteurs de support* (SVM, pour *Support Vector Machines*) constituent une famille d’algorithmes d’apprentissage supervisé particulièrement efficaces pour les tâches de **classification** et de **régression**. Introduites par Vladimir Vapnik et ses collègues dans les années 1990 (Boser et al., 1992), les SVM reposent sur un principe fondamental : la recherche de l’**hyperplan optimal** séparant au mieux les différentes classes de données, en maximisant la **marge** entre celles-ci.

Cette approche géométrique, combinée à l’utilisation des **fonctions noyau** (*kernel functions*) permettant de traiter des problèmes non linéaires, fait des SVM des méthodes robustes et performantes, même dans des espaces de grande dimension. Grâce à leur forte capacité de généralisation et à leur résistance au surapprentissage, les SVM sont aujourd’hui largement utilisées dans des domaines variés tels que la reconnaissance d’images, la bioinformatique, l’analyse de texte ou encore la détection de fraudes.

Leur fondement mathématique solide, reposant sur la théorie de l’**optimisation convexe** (Bertsekas, 2009) et la théorie de **Vapnik–Chervonenkis** (Devroye et al., 1996), leur confère une grande rigueur théorique.

Dans cette section, nous commencerons par présenter les concepts fondamentaux des SVM, en introduisant la notion d’hyperplan séparateur et de **marge maximale** dans le cas linéairement séparable. Nous aborderons ensuite le traitement des données non linéairement séparables à travers l’introduction des **marges souples** et de la **pénalisation des erreurs**. Nous examinerons également le rôle central des fonctions noyau, qui permettent une projection implicite des données dans des espaces de dimension supérieure. Enfin, nous discuterons des aspects pratiques liés à l’implémentation des SVM, notamment le choix des hyperparamètres et les stratégies d’optimisation, avant de conclure par quelques applications concrètes illustrant l’efficacité de cette méthode.

1.2 Objectifs

Trouver un hyperplan qui sépare les exemples positifs des exemples négatifs. Cependant, alors qu’un réseau de neurones trouve un optimum local, une machine à vecteurs supports (MVS) trouve un optimum global. Notons aussi que les machines à vecteurs supports ne se cantonnent pas, elles non plus, aux hyperplans, mais peuvent construire des séparateurs non linéaires de diverses formes. La simple lecture de ce qui précède pourrait laisser penser que les réseaux de neurones doivent être remisés aux oubliettes. Cependant, diverses raisons pratiques font que les deux techniques (réseau de neurones d’une part, machine à vecteurs supports d’autre part) ont chacune des qualités et des défauts et que les deux techniques doivent être connues et que les deux ont de bonnes raisons d’être utilisées.

1.3 Principe Général

Les *Support Vector Machines* (SVM) peuvent être utilisées pour résoudre des problèmes de **discrimination**, c'est-à-dire décider à quelle classe appartient un échantillon, ou des problèmes de **régression**, c'est-à-dire prédire la valeur numérique d'une variable.

La résolution de ces deux problèmes repose sur la construction d'une fonction h qui associe à un vecteur d'entrée x une sortie y :

$$y = h(x)$$

Dans ce qui suit, on se limite à un problème de discrimination à deux classes (*discrimination binaire*), où :

$$y \in \{-1, 1\}$$

Le vecteur d'entrée x appartient à un espace $\mathcal{X}$ muni d'un produit scalaire. On peut, par exemple, considérer :

$$\mathcal{X} = \mathbb{R}^N$$

1.4 Machine à vecteurs supports linéaire

1.4.1 Problème de classification, SVM : C'est quoi, au juste ?

Avant toute chose, nous allons commencer par établir le **cadre des notions** qui seront abordées par la suite. En particulier, nous cherchons à répondre à la question suivante : ***qu'est-ce qu'un problème de classification ?***

Considérons l'exemple suivant. On se place dans le **plan** et l'on dispose de **deux catégories de données** : des **ronds rouges** et des **carrés bleus**, chacune occupant une **région distincte du plan**. Toutefois, la **frontière séparant ces deux régions** n'est pas connue *a priori*. L'objectif est que, lorsqu'un **nouveau point** est présenté à l'**algorithme de classification**, et que seule sa **position dans le plan** est connue, celui-ci soit capable de **prédire la catégorie** à laquelle il appartient (rond rouge ou carré bleu).

Nous sommes ainsi face à un **problème de classification** : pour chaque **nouvelle entrée**, il s'agit de **déterminer automatiquement la catégorie** à laquelle cette entrée appartient.

Autrement dit, le **cœur du problème** consiste à identifier la **frontière séparant les différentes catégories**. Une fois cette frontière connue, il suffit de déterminer de quel côté elle se situe le point considéré afin d'en **déduire sa classe**.

Les **machines à vecteurs de support** (*Support Vector Machines*, **SVM**) constituent une **solution efficace** pour résoudre ce type de problème de **classification**. Elles appartiennent à la famille des **classificateurs linéaires**, qui reposent sur une **séparation linéaire des données**, et disposent de leur propre méthode pour **déterminer la frontière optimale** entre les catégories.

Pour que le **SVM** puisse identifier cette frontière, il est nécessaire de lui fournir des **données d'entraînement**. En pratique, on fournit au SVM un **ensemble de points étiquetés**, dont on connaît déjà la classe (par exemple, des carrés rouges et des ronds bleus, comme illustré à la Figure 1.1).

À partir de ces données, le SVM va **estimer l'emplacement le plus plausible de la frontière**. Cette phase correspond à la **période d'entraînement**, étape fondamentale de tout **algorithme d'apprentissage automatique**.




FIGURE 1.1 – L'objet à classer (le triangle noir) est-il un rond rouge ou bien un carré bleu ?

Une fois la phase d'entraînement terminée, le SVM a ainsi trouvé, à partir des données d'entraînement, l'emplacement supposé de la frontière. En quelque sorte, il a appris l'emplacement de la frontière grâce aux données d'entraînement. Qui plus est, le SVM est maintenant capable de prédire à quelle catégorie appartient une entrée qu'il n'avait jamais vue auparavant et sans intervention humaine (comme c'est le cas avec le triangle noir dans la **Figure 1.2**) : c'est là tout l'intérêt de l'apprentissage automatique.




FIGURE 1.2 – Notre SVM, muni des données d’entraînement (les carrés bleus et les ronds rouges d’ déjà indiqués comme tels par l’utilisateur), a tranché : le triangle noir est en fait un carré bleu

1.5 Formalisme des SVM

De façon plus générale que dans les exemples précédents, les **machines à vecteurs de support** (SVM) ne se limitent pas à la séparation de points dans le plan. Elles permettent de séparer des données dans un **espace de dimension quelconque**.

Par exemple, dans un problème de **classification de fleurs par espèce**, si l’on dispose d’informations telles que la **taille**, le **nombre de pétales** et le **diamètre de la tige**, les données peuvent être représentées dans un espace de **dimension 3**. Un autre exemple courant est celui de la **reconnaissance d’images** : une image en niveaux de gris de 28×28 pixels contient 784 pixels, et peut ainsi être représentée comme un point dans un espace de **dimension 784**. Il est donc fréquent de travailler dans des espaces de **plusieurs milliers de dimensions**.

Fondamentalement, un SVM cherche à déterminer un **hyperplan** séparant au mieux les deux catégories du problème. Un **hyperplan vectoriel** passe nécessairement par l’**origine**. C’est pour cette raison que l’on introduit un **hyperplan affine**, qui n’est pas contraint de passer par l’origine. Ainsi, si l’on se place dans $\mathbb{R}^n$, pendant son entraînement le SVM calculera un **hyperplan vectoriel** d’équation :

$$w_1 \cdot x_1 + w_2 \cdot x_2 + \cdots + w_n \cdot x_n = 0$$

ainsi qu’un scalaire b . C’est ce scalaire b qui permet de travailler avec un **hyperplan affine**, comme nous allons le voir.

Le vecteur

$$\mathbf{w} = \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix}$$

est appelé **vecteur de poids**, et le scalaire b est appelé **biais**.

Une fois l'entraînement terminé, pour classer une nouvelle entrée

$$\mathbf{x} = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix} \in \mathbb{R}^n,$$

le SVM regardera le **signe** de :

$$h(\mathbf{x}) = w_1 a_1 + \dots + w_n a_n + b = \sum_{i=1}^n w_i \cdot a_i = \mathbf{w}^T \mathbf{x} + b.$$

Si $h(\mathbf{x}) \geq 0$, alors $\mathbf{x}$ se situe d'un côté de l'hyperplan affine et appartient à la **catégorie 1**.

Sinon, $\mathbf{x}$ se trouve de l'autre côté de l'hyperplan et appartient à la **catégorie 2**.

En résumé, pour un point $\mathbf{x}$, la fonction h permet de déterminer **de quel côté de l'hyperplan affine il se trouve** :

$$\mathbf{x} \in \begin{cases} \text{catégorie 1} & \text{si } h(\mathbf{x}) \geq 0, \\ \text{catégorie 2} & \text{si } h(\mathbf{x}) < 0. \end{cases}$$

1.6 Principe de la méthode

Considérons chaque individu $\mathbf{x}_i$ comme un point dans un espace à P dimensions. On peut également le voir comme un **vecteur** $\vec{x}_i$. Dans la suite, nous alternerons entre les deux points de vue selon le contexte.

Si le problème est **linéairement séparable**, les individus **positifs** et **négatifs** sont séparés par un **hyperplan** H . Notons H^+ l'hyperplan parallèle à H qui contient l'individu positif le plus proche de H , et H^- l'hyperplan contenant l'individu négatif le plus proche (voir **figure 1.3**).

Une **MVS linéaire** (*Machine à Vecteurs de Support*) recherche l'hyperplan qui sépare les données de manière à **maximiser la distance entre H^+ et H^-** . Cet écart est appelé la **marge**.

Équation de l'hyperplan

Un hyperplan est défini par l'équation :

$$y = \langle \mathbf{w}, \mathbf{x} \rangle + b$$

où $\langle \mathbf{w}, \mathbf{x} \rangle$ désigne le **produit scalaire** entre les vecteurs $\mathbf{w}$ et $\mathbf{x}$.

Pour une donnée $\mathbf{x}$ appartenant à la classe y , on cherche $\mathbf{w}$ tel que :

$$\begin{cases} \langle \mathbf{w}, \mathbf{x} \rangle + b \geq 1 & \text{si } y = +1, \\ \langle \mathbf{w}, \mathbf{x} \rangle + b \leq -1 & \text{si } y = -1. \end{cases}$$

Cette condition peut se réécrire de façon compacte sous la forme :

$$y (\langle \mathbf{w}, \mathbf{x} \rangle + b) - 1 \geq 0.$$

1.7 Calcul de la marge

Si l'on prend un point $\mathbf{x}_k \in \mathbb{R}^n$, on peut montrer que sa **distance à l'hyperplan** défini par le vecteur support $\mathbf{w}$ et le biais b est donnée par :

$$l_k \frac{\mathbf{w}^T \mathbf{x}_k + b}{\|\mathbf{w}\|},$$

où $\|\mathbf{w}\|$ désigne la **norme euclidienne** de $\mathbf{w}$, et l_k est le label de la classe (+1 ou -1).

La **marge** d'un hyperplan de paramètres $(\mathbf{w}, b)$ par rapport à un ensemble de points $(\mathbf{x}_k)$ est donc :

$$\gamma = \min_k l_k \frac{\mathbf{w}^T \mathbf{x}_k + b}{\|\mathbf{w}\|}.$$

Rappel : la marge correspond à la **distance minimale** de l'hyperplan à un des points d'entraînement.

Démonstration

On cherche à **maximiser la largeur de la marge**.

1. Le vecteur $\mathbf{w}$ est **perpendiculaire à l'hyperplan** H .
2. Soit $B \in H^+$ et $A \in H^-$ le point le plus proche de B (voir figure 8.1).
3. Pour tout point O , on a :

$$\overrightarrow{OB} = \overrightarrow{OA} + \overrightarrow{AB}.$$

4. Par définition des points A et B , $\overrightarrow{AB}$ est **parallèle à $\mathbf{w}$** . Il existe donc $\lambda \in \mathbb{R}$ tel que :

$$\overrightarrow{AB} = \lambda \mathbf{w}, \quad \text{soit} \quad \overrightarrow{OB} = \overrightarrow{OA} + \lambda \mathbf{w}.$$

5. On veut que A, B, H^- et H^+ vérifient :

$$B \in H^+ \Rightarrow \langle \mathbf{w}, \overrightarrow{OB} \rangle + b = 1, \quad A \in H^- \Rightarrow \langle \mathbf{w}, \overrightarrow{OA} \rangle + b = -1.$$

6. Donc :

$$\langle \mathbf{w}, \overrightarrow{OA} + \lambda \mathbf{w} \rangle + b = 1.$$

7. En développant :

$$\langle \mathbf{w}, \overrightarrow{OA} \rangle + b + \lambda \langle \mathbf{w}, \mathbf{w} \rangle = 1.$$

8. Or :

$$\langle \mathbf{w}, \overrightarrow{OA} \rangle + b = -1.$$

9. Donc :

$$\lambda \langle \mathbf{w}, \mathbf{w} \rangle = 2.$$

10. Ainsi :

$$\lambda = \frac{2}{\|\mathbf{w}\|^2}.$$

11. La largeur de la marge est donc :

$$|\lambda| \|\mathbf{w}\| = \frac{2}{\|\mathbf{w}\|}.$$

Conclusion : pour **maximiser la marge**, il faut **minimiser la norme de w** . En effet, une norme plus petite implique une marge plus grande, ce qui permet d'améliorer la séparation entre les classes.

Remarque : les individus positifs sont représentés par un $+$, et les individus négatifs par un $-$. Les individus **positifs** sont représentés par un $+$, et les individus **négatifs** par un $-$.

On a représenté un **hyperplan H** qui sépare les positifs des négatifs. (**Remarque :** sur le schéma, il ne s'agit pas de l'hyperplan qui sépare **au mieux** les deux ensembles.)

Nous avons également représenté H^+ et H^- , tous deux **parallèles à H** .

Soit B un point de H^+ et A le point le plus proche de B appartenant à H^- (voir figure 1.3).




FIGURE 1.3 – Schéma illustratif : groupe H^+ et H^- .

1.8 Machine à vecteurs supports non linéaire

1.8.1 Introduction aux SVM non linéaires

Les Machines à Vecteurs de Support (SVM) sont des modèles d'apprentissage supervisé populaires pour la classification et la régression, introduits dans les années 1990 par Vapnik et ses collègues. Leur principe de base est de trouver un hyperplan qui maximise la marge entre les classes, défini par les vecteurs de support, qui sont les points de données les

plus proches de cet hyperplan. Cependant, cette approche suppose que les données sont linéairement séparables, ce qui n'est pas toujours le cas dans des scénarios réels. Par exemple, imaginez des données où deux classes forment des cercles concentriques : aucune ligne droite ne peut les séparer efficacement.

C'est ici que les SVM non linéaires entrent en jeu. Ils étendent les capacités des SVM linéaires en traitant des données non linéairement séparables, c'est-à-dire des données où les classes ne peuvent pas être divisées par une frontière linéaire dans l'espace d'origine. Les SVM non linéaires utilisent des fonctions noyau pour transformer les données dans un espace de dimension supérieure où elles deviennent linéairement séparables, permettant ainsi de capturer des relations complexes.

1.8.2 Le problème des données non linéaires

Dans le cadre de la classification avec des algorithmes comme les Machines à Vecteurs de Support (SVM), un défi majeur survient lorsque les données ne sont pas linéairement séparables. On parle de données non linéaires lorsque les classes ne peuvent pas être divisées par une frontière linéaire simple, comme une droite en deux dimensions ou un hyperplan dans des dimensions supérieures. Ce problème est fréquent dans les applications réelles, où les relations entre les variables sont souvent complexes et ne suivent pas des motifs droits ou plats.

Prenons un exemple concret : imaginez deux classes de données disposées en cercles concentriques, l'une formant un petit cercle à l'intérieur et l'autre un anneau autour. Aucune ligne droite ne peut séparer parfaitement ces deux groupes sans inclure des points de l'autre classe. Un autre cas classique est le problème XOR, où quatre points – $(0, 0)$ et $(1, 1)$ dans une classe, $(0, 1)$ et $(1, 0)$ dans une autre – forment un motif impossible à séparer linéairement. De même, dans le dataset IRIS, bien connu en apprentissage automatique, les espèces *Versicolor* et *Virginica* se chevauchent dans l'espace des caractéristiques (comme la longueur et la largeur des pétales), rendant une séparation linéaire imparfaite.

Pour les SVM linéaires, qui reposent sur la recherche d'un hyperplan maximisant la marge entre les classes, ce type de données pose un obstacle insurmontable. Si les classes ne sont pas linéairement séparables, aucun hyperplan ne peut être trouvé sans accepter des erreurs de classification, ce qui compromet la précision du modèle. Par exemple, dans le cas des cercles concentriques, un SVM linéaire ne pourrait tracer qu'une droite coupant les deux cercles, mélangeant ainsi les points des deux classes.

Ce problème est d'autant plus critique que les données réelles – qu'il s'agisse de pixels d'images, de mots dans un texte ou de mesures biologiques – présentent souvent des structures non linéaires. Identifier cette limitation est donc essentiel pour comprendre pourquoi les SVM linéaires échouent dans ces cas et pourquoi une approche plus avancée, comme les SVM non linéaires, devient nécessaire.

1.8.3 Principe des SVM non linéaires

Face au problème des données non linéaires, les SVM non linéaires offrent une solution ingénieuse en modifiant la manière dont les données sont traitées. Leur principe repose sur une idée fondamentale : transformer les données pour les rendre linéairement séparables, tout en conservant l'objectif de base des SVM, qui est de maximiser la marge entre les classes.




FIGURE 1.4 – Données d’entraînement non linéairement séparables

Transformation des données

Le premier concept clé est la projection des données dans un espace de dimension supérieure. Quand les données ne peuvent pas être séparées par une droite dans leur espace d’origine, l’idée est de les projeter dans un espace plus complexe où une séparation linéaire devient possible. Par exemple, prenons des données en deux dimensions (2D) formant deux cercles concentriques : une classe à l’intérieur, l’autre à l’extérieur. Aucune droite ne peut les séparer proprement en 2D. En revanche, si on transforme ces données en un espace tridimensionnel (3D) – par exemple, en ajoutant une coordonnée basée sur le carré de la distance au centre –, les points peuvent être “soulevés” différemment. Dans cet espace 3D, les cercles deviennent séparables par un plan plat. Cette transformation permet de contourner la limitation des frontières linéaires dans l’espace initial.

Hyperplan dans l’espace transformé

Une fois les données projetées dans cet espace de dimension supérieure, le SVM fonctionne comme un modèle linéaire classique : il cherche un hyperplan capable de séparer les classes. Dans notre exemple des cercles, le plan en 3D agit comme une surface qui passe entre les points “soulevés” de la classe intérieure et ceux de la classe extérieure. Ce qui est remarquable, c’est que cet hyperplan, bien que linéaire dans l’espace transformé, correspond à une frontière non linéaire (comme un cercle) lorsqu’on le ramène à l’espace 2D d’origine. Ainsi, les SVM non linéaires exploitent cette astuce pour gérer des motifs complexes tout en restant ancrés dans une logique de séparation linéaire.

Maximisation de la marge

Enfin, comme pour les SVM linéaires, l'objectif reste de maximiser la marge. Dans l'espace transformé, le SVM identifie les vecteurs de support – les points les plus proches de l'hyperplan – et ajuste cet hyperplan pour qu'il soit le plus éloigné possible de ces points, des deux côtés. Cette maximisation garantit que le modèle reste robuste et généralise bien, même dans un espace de dimension supérieure. Ainsi, bien que la transformation change la géométrie des données, le principe fondamental des SVM demeure inchangé : trouver la frontière optimale qui sépare les classes avec la plus grande marge possible.

1.8.4 Plongée en dimension supérieure

Pour contourner le problème, l'idée est donc la suivante : il est impossible de séparer linéairement les données dans notre espace vectoriel ? Qu'importe ! Essayons dans un autre espace. De façon générale, il est courant de ne pas pouvoir séparer les données parce que l'espace est de trop petite dimension. Si l'on arrivait à transposer les données dans un espace de plus grande dimension, on arriverait peut-être à trouver un hyperplan séparateur.

Je sens que j'en ai peut-être perdu quelques-uns en cours de route. Considérons l'exemple suivant pour mieux comprendre. On souhaite construire un SVM qui, à partir de la taille d'un individu, détermine si cet individu est un jeune adolescent (entre 12 et 16 ans, carrés bleus) ou non (ronds rouges).



FIGURE 1.5 – Illustration : données sur une droite

Entre 10 et 12 ans, on mesure entre 120 et 140 cm ; entre 12 et 16 ans, entre 140 et 165 cm ; entre 16 et 18 ans, on mesure plus de 165 cm. Peut-on trouver un hyperplan qui sépare les jeunes de 12–16 ans des autres ? On constate que l'on ne peut pas trouver d'hyperplan séparateur (ici, on est en dimension 1, un hyperplan séparateur est donc un simple point). Ce qui est embêtant : si l'on ne peut pas trouver d'hyperplan séparateur, notre SVM ne sera pas capable de s'entraîner, et encore moins de classer de nouvelles entrées...

On essaie donc de trouver un nouvel espace, généralement de dimension supérieure, dans lequel on peut projeter nos valeurs d'entraînement, et dans lequel on pourra trouver un séparateur linéaire. Dans cet exemple, je vous propose d'utiliser la projection : $\phi : x \mapsto \left(\frac{x-150}{10}, \left(\frac{x-150}{10} \right)^2 \right)$. On passe donc de l'espace vectoriel $\mathbb{R}$, de dimension 1, à l'espace vectoriel $\mathbb{R}^2$, de dimension 2. Les données d'entraînement obtenues après cette projection sont les suivantes :

On observe que les données deviennent alors linéairement séparables, ce qui permet à notre SVM de fonctionner correctement ! Plus formellement, l'idée de cette redescription du problème est de considérer que l'espace actuel, appelé espace de description, est de dimension trop petite ; alors que si on plongeait les données dans un espace de dimension supérieure, appelé espace de redescription, les données seraient linéairement séparables.

Évidemment, il ne suffit pas de simplement ajouter des dimensions à l'espace de description, car cela ne résoudrait pas le problème. Il faut au contraire redistribuer les points




FIGURE 1.6 – Données d’entraînement après projection dans l’espace $\mathbb{R}^2$

depuis l’espace de description vers l’espace de redescription, à l’aide d’une fonction, nécessairement non linéaire. On définit l’opération de redescription des points x de E vers E' par l’opération :

$$\phi : E \rightarrow E', \quad x \mapsto \phi(x) \quad (1.1)$$

Dans ce nouvel espace E' , on va tenter d’entraîner le SVM comme nous l’aurions fait dans l’espace initial E . Si les données y sont linéairement séparables, c’est gagné ! Par la suite, pour classer un point x , il suffira de classer $\phi(x)$, ce qui nous permet d’obtenir un SVM fonctionnel.

1.8.5 Le « Kernel Trick » (Astuce du noyau)

Malheureusement, plus la dimension de l’espace augmente, plus les calculs deviennent complexes et longs. Que se passe-t-il alors si l’on travaille en dimension infinie ? Il est néanmoins possible de simplifier les calculs. En posant le problème d’optimisation quadratique dans l’espace E' , on s’aperçoit que les seules apparitions de ϕ sont sous la forme $\phi(x_i)^T \cdot \phi(x_j)$. Il en va de même pour l’expression de la fonction de classification h . Par conséquent, il n’est pas nécessaire de connaître explicitement E' , ni même ϕ : il suffit de connaître les valeurs $\phi(x_i)^T \cdot \phi(x_j)$, qui ne dépendent que des x_i .

On définit alors une fonction noyau $K : E \times E \rightarrow \mathbb{R}$ de la manière suivante :

$$K(x, x') = \phi(x)^T \cdot \phi(x') \quad (1.2)$$

À ce stade, le calcul de l'hyperplan séparateur dans E' ne nécessite ni la connaissance de E' , ni de ϕ , mais uniquement de K .

Par exemple, supposons que E soit l'espace de description, de dimension n , et que l'espace de redescription E' soit de dimension n^2 . Le calcul de $K(x_i, x_j)$ se fait en $O(n)$, tandis que le calcul direct de $\phi(x_i)^T \cdot \phi(x_j)$, qui donne le même résultat, se fait en $O(n^2)$, ce qui représente un avantage immédiat en termes de temps de calcul.

C'est à partir de ce constat qu'émerge le *kernel trick*, ou astuce du noyau. Puisque seule la connaissance de K est nécessaire, pourquoi ne pas utiliser une fonction K quelconque, correspondant à une redescription dans un espace E' quelconque, et résoudre le problème de séparation linéaire sans se préoccuper de l'espace de redescription dans lequel on évolue ?

Grâce au théorème de Mercer, on sait qu'une condition suffisante pour qu'une fonction K soit une fonction noyau est qu'elle soit continue, symétrique et semi-définie positive.

Propriétés d'un noyau symétrique semi-défini positif

Une fonction ϕ est dite **symétrique** si et seulement si, pour tout $x, y \in E$, on a $\phi(x, y) = \phi(y, x)$.

Une fonction symétrique K est dite **semi-définie positive** si et seulement si, pour tout ensemble fini $\{x_1, \dots, x_n\} \subset E$, et pour tous réels $c_1, \dots, c_n$,

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0. \quad (1.3)$$

Par exemple, le produit scalaire usuel $(a, b) \mapsto \sum_{i=1}^N a_i b_i$ est symétrique et semi-défini positif, car

$$\forall \{x_1, \dots, x_n\} \subset E, \forall c_1, \dots, c_n \in \mathbb{R}, \quad \sum_{i=1}^n \sum_{j=1}^n c_i c_j (x_i \cdot x_j) = \left\| \sum_{i=1}^n c_i x_i \right\|^2 \geq 0. \quad (1.4)$$

Ainsi, il est possible d'utiliser n'importe quelle fonction noyau afin de réaliser une redescription dans un espace de dimension supérieure. La fonction noyau étant définie sur l'espace de description E (et non sur l'espace de redescription E' , de plus grande dimension), les calculs sont beaucoup plus rapides.

Pour résumer, voici les quatre grandes idées à la base du *kernel trick* :

- Les données décrites dans l'espace d'entrée E sont projetées dans un espace de redescription E' .
- Des régularités linéaires sont cherchées dans cet espace E' .
- Les algorithmes de recherche n'ont pas besoin de connaître les coordonnées des projections des données dans E' , mais seulement leurs produits scalaires.
- Ces produits scalaires peuvent être calculés efficacement grâce à l'utilisation de fonctions noyau.

1.8.6 Les principaux noyaux utilisés

Le “kernel trick” repose sur des fonctions noyau spécifiques qui définissent comment les données sont implicitement transformées dans un espace de dimension supérieure. Chaque noyau a ses propres caractéristiques, paramètres et cas d’utilisation. Voici les trois principaux noyaux utilisés dans les SVM non linéaires, suivis d’une comparaison rapide.

Noyau Polynomial

Formule :

$$K(x, x') = (\alpha \cdot x^\top x' + \lambda)^d \quad (1.5)$$

Description : Le noyau polynomial évalue la similarité entre deux vecteurs en élevant leur produit scalaire, ajusté par des constantes, à une puissance donnée. Ce noyau est particulièrement utile pour modéliser des relations non linéaires en transformant l’espace d’entrée en un espace de dimensions supérieures, permettant ainsi de capturer des interactions complexes entre les variables.

Paramètres :

- α : facteur d’échelle du produit scalaire.
- λ : constante ajoutée pour ajuster la souplesse du modèle.
- d : degré du polynôme, déterminant la complexité de la frontière de décision.

Exemple d’application : Reconnaissance d’écriture manuscrite

Dans la reconnaissance de chiffres manuscrits, comme ceux de la base de données MNIST, les machines à vecteurs de support (SVM) avec un noyau polynomial peuvent classer efficacement les images en tenant compte des interactions complexes entre les pixels. Le noyau polynomial permet de modéliser des frontières de décision non linéaires, améliorant ainsi la précision de la classification.

Noyau Gaussien (RBF - Radial Basis Function)

Formule :

$$K(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right) \quad (1.6)$$

Description : Le noyau gaussien mesure la similarité entre deux points en fonction de la distance euclidienne qui les sépare. Il est particulièrement efficace pour capturer des relations complexes dans les données, même lorsque la séparation linéaire n’est pas possible dans l’espace d’origine.

Paramètre :

- σ : paramètre de lissage déterminant la portée de l’influence d’un point de données sur un autre.

Exemple d’application : Détection d’e-mails indésirables (spam)

Les filtres anti-spam utilisent des SVM avec un noyau gaussien pour distinguer les e-mails légitimes des spams. Le noyau RBF capture les relations complexes entre les caractéristiques des e-mails, telles que la fréquence des mots, les structures de phrases et les métadonnées, permettant une classification précise même lorsque les spams présentent des variations subtiles.

Noyau Laplacien

Formule :

$$K(x, x') = \exp\left(-\frac{\|x - x'\|}{\sigma}\right) \quad (1.7)$$

Description : Semblable au noyau gaussien, le noyau laplacien utilise la distance euclidienne pour évaluer la similarité, mais avec une décroissance exponentielle différente. Il est souvent préféré lorsque les données présentent des variations plus abruptes ou des discontinuités.

Paramètre :

- σ : paramètre contrôlant la largeur de la fonction noyau, influençant la sensibilité aux variations locales des données.

Exemple d'application : Analyse de données biologiques

Dans la bioinformatique, le noyau laplacien est utilisé pour comparer des séquences génétiques ou protéiques. En mesurant la similarité entre les séquences, il aide à identifier des gènes homologues, à prédire des structures protéiques ou à classer des espèces biologiques, même lorsque les séquences présentent des variations significatives.

Noyau Rationnel Quadratique

Formule :

$$K(x, x') = 1 - \frac{\|x - x'\|^2}{\|x - x'\|^2 + \sigma} \quad (1.8)$$

Description : Le noyau rationnel quadratique est une variante du noyau gaussien qui offre une mesure de similarité basée sur une fraction rationnelle de la distance entre les points. Il est utile pour modéliser des relations où la similarité diminue de manière non exponentielle avec la distance.

Paramètre :

- σ : paramètre ajustant la courbure de la fonction noyau, affectant la manière dont la similarité décroît avec la distance.

Exemple d'application : Systèmes de recommandation

Les plateformes de streaming musical ou vidéo utilisent le noyau rationnel quadratique pour modéliser la similarité entre les préférences des utilisateurs. En évaluant la distance entre les profils d'écoute ou de visionnage, ce noyau permet de recommander des contenus pertinents en tenant compte des variations subtiles dans les habitudes des utilisateurs.

Chacun de ces noyaux possède ses avantages et ses inconvénients, comme décrits dans le document. C'est donc à l'utilisateur de choisir le noyau, et les paramètres de ce noyau, qui correspond le mieux à son problème. Et comment choisir son noyau, me demanderez-vous ? Eh bien... Je n'ai pas de méthode à vous donner, ça dépend énormément de votre jeu de données.

Conclusion

Les Support Vector Machines (SVM) sont des algorithmes de classification et de régression puissants, particulièrement efficaces pour les problèmes à haute dimensionnalité et pour les jeux de données où les classes sont bien séparables. Grâce à l'utilisation des

marges maximales et des noyaux (kernels), les SVM peuvent modéliser des frontières de décision complexes tout en minimisant le risque de surapprentissage. Bien qu'ils puissent être sensibles aux choix des hyperparamètres et coûteux en calcul pour de très grands ensembles de données, leur précision et leur robustesse font des SVM un outil essentiel dans la boîte à outils de l'apprentissage automatique.

Cependant, les SVM ne constituent qu'une approche parmi d'autres dans le vaste domaine de l'apprentissage automatique. Dans le chapitre suivant, nous explorerons les Random Forests (forêts aléatoires), une famille d'algorithmes basée sur les arbres de décision qui adopte une philosophie différente : plutôt que de chercher un hyperplan optimal unique, les Random Forests combinent les prédictions de multiples arbres pour améliorer la précision et réduire le surapprentissage. Cette approche ensembliste offre des avantages complémentaires à ceux des SVM, notamment en termes d'interprétabilité et de robustesse face aux données bruitées.

Chapitre 2

Random Forests (RF)

2.1 Introduction

Les praticiens du machine learning sont souvent confrontés à un défi fondamental : les arbres de décision simples, bien qu'intuitifs et interprétables, ont tendance à surapprendre (*overfitting*) les données d'entraînement. Un arbre de décision qui mémorise parfaitement chaque exemple d'apprentissage aura généralement de mauvaises performances sur de nouvelles données non vues. C'est dans ce contexte que les forêts aléatoires (*Random Forests*) entrent en jeu.

Les forêts aléatoires, introduites par Leo Breiman en 2001, constituent une méthode puissante d'apprentissage en ensemble qui combine plusieurs arbres de décision afin de produire un prédicteur plus robuste et plus précis. L'idée fondamentale est remarquablement simple : si un seul expert peut commettre des erreurs, pourquoi ne pas consulter un comité d'experts et retenir l'opinion majoritaire ?

Ce principe, parfois appelé la *sagesse des foules* (*wisdom of crowds*), suggère que la prédiction moyenne issue de plusieurs modèles indépendants est généralement plus précise et plus stable que celle d'un modèle unique. Les forêts aléatoires mettent ce principe en pratique en entraînant de nombreux arbres de décision, chacun sur des versions légèrement différentes des données, puis en agrégeant leurs prédictions.

Dans le contexte de ce rapport, les forêts aléatoires occupent une position intermédiaire importante. Contrairement aux machines à vecteurs de support (*Support Vector Machines, SVM*), qui recherchent des frontières de décision optimales à l'aide de méthodes à noyaux sophistiquées, les forêts aléatoires reposent sur des structures arborescentes interprétables. À l'inverse de XGBoost, qui construit les arbres de manière séquentielle afin de corriger les erreurs précédentes, les forêts aléatoires construisent tous les arbres de façon indépendante et en parallèle.

Cette section vous guidera à travers les fondements théoriques des forêts aléatoires, leur implémentation algorithmique, les paramètres clés et les stratégies d'ajustement, leurs avantages et limitations pratiques, et enfin leur comparaison avec d'autres méthodes de la boîte à outils du machine learning. À la fin de cette section, vous comprendrez non seulement comment fonctionnent les forêts aléatoires, mais aussi quand et pourquoi les utiliser.

2.2 Fondements théoriques : l'apprentissage en ensemble

Pour comprendre pourquoi les forêts aléatoires sont si performantes, il est nécessaire de s'intéresser au principe de l'apprentissage en ensemble (*ensemble learning*). L'idée centrale est que la combinaison de plusieurs *apprenants faibles* (*weak learners*) peut produire un *apprenant fort* (*strong learner*) qui surpasse chacun des modèles pris individuellement.

Un concept fondamental du machine learning pour analyser ce phénomène est le compromis biais-variance (*bias-variance trade-off*). L'erreur de prédiction d'un modèle peut être décomposée en trois composantes :

$$\text{Erreur totale} = \text{Biais}^2 + \text{Variance} + \text{Erreur irréductible}$$

Le biais représente les erreurs systématiques, c'est-à-dire l'écart entre la prédiction moyenne du modèle et la valeur réelle. La variance mesure la sensibilité du modèle aux variations des données d'apprentissage, autrement dit à quel point les prédictions changent lorsque le modèle est entraîné sur des jeux de données différents. L'erreur irréductible correspond au bruit intrinsèque présent dans les données, qu'aucun modèle ne peut éliminer.

Les arbres de décision individuels, lorsqu'ils sont développés jusqu'à une profondeur maximale, présentent généralement un faible biais (car ils sont capables de modéliser des relations complexes), mais une variance élevée (car de légères variations dans les données d'entraînement peuvent produire des structures d'arbres très différentes). Ainsi, entraîner un arbre de décision profond sur des données légèrement modifiées peut conduire à un modèle totalement différent.

Les méthodes d'ensemble répondent à ce problème en exploitant une propriété mathématique clé : lorsque l'on moyenne plusieurs variables aléatoires indépendantes, la variance de la moyenne est inférieure à la variance de chacune des variables individuelles. Plus précisément, si l'on dispose de n prédictions indépendantes ayant chacune une variance σ^2 , alors la variance de leur moyenne est donnée par :

$$\frac{\sigma^2}{n}$$

La technique fondamentale exploitant ce principe est le *Bootstrap Aggregating*, plus communément appelé *bagging*. Son fonctionnement est le suivant : au lieu d'entraîner un seul modèle sur l'ensemble du jeu de données, on génère plusieurs échantillons bootstrap (échantillonnage aléatoire avec remise) à partir des données originales. Chaque échantillon bootstrap a la même taille que le jeu de données initial, mais contient certaines observations répétées et en omet d'autres. Un modèle distinct est entraîné sur chaque échantillon, puis leurs prédictions sont agrégées.

D'un point de vue mathématique, si l'on considère K modèles produisant les prédictions $f_1(x), f_2(x), \dots, f_K(x)$, la prédiction de l'ensemble est définie comme suit :

$$F(x) = \frac{1}{K} \sum_{k=1}^K f_k(x) \quad (\text{régression})$$

$$F(x) = \text{mode}\{f_1(x), f_2(x), \dots, f_K(x)\} \quad (\text{classification})$$

Cette opération d'agrégation permet de réduire significativement la variance sans augmenter le biais, conduisant ainsi à un modèle qui généralise mieux sur de nouvelles données. Les forêts aléatoires vont encore plus loin que le *bagging* classique en introduisant une source supplémentaire d'aléa, qui sera abordée dans la suite.

Formule clé : la moyenne d'un ensemble de prédictions réduit la variance :

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$




FIGURE 2.1 – Fonctionnement du Random Forest

2.3 Rappel sur les arbres de décision

Avant d’approfondir l’étude des forêts aléatoires, il est utile de rappeler le fonctionnement des arbres de décision individuels, puisqu’ils constituent les briques élémentaires de toute forêt.

Un arbre de décision est un modèle hiérarchique qui effectue des prédictions en posant une succession de questions binaires (oui/non) sur les variables d’entrée. Il est composé de nœuds internes (points de décision), de branches (réponses possibles) et de nœuds feuilles (prédictions finales). Par exemple, prédire si une personne achètera un produit peut impliquer des questions telles que « $\text{Age} > 30 ?$ », suivies de « $\text{Revenu} > 50\,000 \$?$ », et ainsi de suite.

La construction d’un arbre de décision repose sur l’algorithme CART (*Classification and Regression Trees*). En partant de l’ensemble des données d’apprentissage au niveau du nœud racine, l’algorithme divise récursivement les données en fonction des valeurs des caractéristiques qui séparent le mieux la variable cible. La question clé est alors : comment mesurer ce « meilleur » découpage ?

2.3.1 Critères de séparation

Pour les problèmes de classification, on utilise des mesures telles que l’impureté de Gini ou l’entropie.

L’impureté de Gini mesure la probabilité qu’un élément choisi aléatoirement soit mal classé :

$$\text{Gini} = 1 - \sum_{i=1}^C p_i^2$$

où p_i représente la proportion de la classe i dans le nœud. Un nœud pur, dans lequel toutes les observations appartiennent à une seule classe, a une impureté de Gini égale à 0. L’impureté est maximale lorsque les classes sont réparties de manière uniforme.

L'entropie mesure le contenu informationnel d'un nœud :

$$\text{Entropie} = - \sum_{i=1}^C p_i \log_2 p_i$$

Pour les problèmes de régression, le critère utilisé est l'erreur quadratique moyenne (*Mean Squared Error, MSE*) :

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

où $\bar{y}$ représente la moyenne des valeurs cibles dans le nœud.

2.3.2 Construction récursive et surapprentissage

L'algorithme évalue toutes les divisions possibles pour l'ensemble des caractéristiques et sélectionne celle qui entraîne la plus grande diminution de l'impureté ou de l'erreur. Ce processus se poursuit de manière récursive jusqu'à ce qu'un critère d'arrêt soit atteint, tel qu'une profondeur maximale, un nombre minimal d'exemples par nœud, ou l'absence de gain supplémentaire.

C'est précisément à ce niveau que se situe le problème : un arbre de décision construit sans contraintes continuera à se diviser jusqu'à ce que chaque feuille contienne un seul exemple d'apprentissage, mémorisant parfaitement les données d'entraînement. Un tel arbre présente une erreur nulle sur les données d'apprentissage, mais des performances très faibles sur les données de test, ce qui correspond à un cas classique de surapprentissage (*overfitting*).

Les arbres de décision individuels sont donc considérés comme des modèles à *forte variance et faible biais*. Ils sont suffisamment flexibles pour capturer des relations complexes (faible biais), mais cette flexibilité excessive les rend sensibles au bruit et fortement dépendants des échantillons d'apprentissage (forte variance). Cette caractéristique en fait des candidats idéaux pour les méthodes d'apprentissage en ensemble visant à réduire la variance, ce qui nous conduit naturellement aux forêts aléatoires.

Mesures clés :

$$\text{Impureté de Gini} = 1 - \sum p_i^2, \quad \text{Entropie} = - \sum p_i \log_2 p_i, \quad \text{MSE} = \frac{1}{n} \sum (y_i - \bar{y})^2$$

2.4 Algorithme des forêts aléatoires

Nous arrivons maintenant au cœur du fonctionnement des forêts aléatoires. L'algorithme introduit deux sources clés de hasard qui le rendent plus puissant qu'un simple *bagging* d'arbres de décision.

2.4.1 Étape 1 : Échantillonnage bootstrap

Pour chacun des K arbres que l'on souhaite construire (généralement entre 100 et 1000 arbres), on crée un échantillon bootstrap à partir des données d'apprentissage. Cela consiste à sélectionner aléatoirement n observations avec remise à partir du jeu de données original de taille n .

Étant donné que l'échantillonnage se fait avec remise, certaines observations peuvent apparaître plusieurs fois, tandis que d'autres ne sont pas sélectionnées du tout. En moyenne, chaque échantillon bootstrap contient environ 63,2 % d'observations uniques provenant du jeu de données original.

2.4.2 Étape 2 : Sélection aléatoire des caractéristiques

C'est à cette étape que les forêts aléatoires se distinguent du *bagging* standard. Lors de la construction de chaque arbre, à chaque point de division, au lieu de considérer l'ensemble des p caractéristiques disponibles, on sélectionne aléatoirement un sous-ensemble de m caractéristiques, avec $m < p$. La meilleure division est alors choisie uniquement parmi ces m caractéristiques.

Ce processus est répété à chaque nœud de l'arbre, avec un nouveau sous-ensemble aléatoire de caractéristiques sélectionné à chaque fois.

Cette source de hasard est cruciale : elle permet de décorréler les arbres entre eux, évitant qu'ils ne commettent tous les mêmes erreurs. Si une caractéristique est particulièrement dominante, l'absence de sélection aléatoire conduirait la majorité des arbres à l'utiliser dès la première division, rendant les arbres fortement corrélés. En imposant l'exploration de caractéristiques différentes, on introduit de la diversité au sein de l'ensemble.

2.4.3 Étape 3 : Croissance des arbres

Chaque arbre est développé jusqu'à sa profondeur maximale, sans élagage (*pruning*). Contrairement à la construction d'un arbre de décision unique — où l'on applique souvent des critères d'arrêt anticipés ou des techniques d'élagage pour éviter le surapprentissage — les forêts aléatoires autorisent chaque arbre à surapprendre complètement son échantillon bootstrap.

Ce choix peut sembler contre-intuitif, mais il repose sur un principe fondamental : c'est l'agrégation des prédictions de nombreux arbres fortement variables qui permet de lisser le surapprentissage individuel et d'améliorer la généralisation globale.

2.4.4 Étape 4 : Agrégation des prédictions

Une fois les K arbres entraînés, le processus de prédiction est simple :

- **Classification** : chaque arbre vote pour une classe, et la classe finale est celle qui obtient le plus grand nombre de votes (vote majoritaire).
- **Régression** : la prédiction finale correspond à la moyenne des prédictions de tous les arbres.

D'un point de vue mathématique :

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_K(x)\} \quad (\text{classification})$$

$$\hat{y} = \frac{1}{K} \sum_{k=1}^K T_k(x) \quad (\text{régression})$$

où $T_k(x)$ représente la prédiction du k -ième arbre pour une observation x .

```

1  For k = 1 to K:
2    1. Draw a bootstrap sample Z_k of size n from training data
3    2. Grow tree T_k using Z_k:
4      a. At each node, randomly select m features
5      b. Choose best split among these m features
6      c. Split node and repeat until stopping criterion
7    3. Store tree T_k
8
9  To predict for new input x:
10 - Classification: return majority vote from {T_1(x), ..., T_K(x)}
11 - Regression: return average of {T_1(x), ..., T_K(x)}
12

```

FIGURE 2.2 – Random Forest

2.4.5 Algorithm Pseudocode

Cette combinaison élégante de l'échantillonnage bootstrap et de la sélection aléatoire des caractéristiques permet de construire un ensemble puissant qui surpasse généralement à la fois les arbres de décision individuels et les arbres issus d'un simple *bagging*.

Idée clé : les deux sources de hasard l'échantillonnage bootstrap et la sélection aléatoire des caractéristiques génèrent des arbres diversifiés dont les erreurs individuelles tendent à s'annuler lors de l'agrégation, conduisant à de meilleures performances de généralisation.




FIGURE 2.3 – Bagging vs Boosting

2.5 Hyperparamètres clés et leurs effets

La compréhension des hyperparamètres des forêts aléatoires est essentielle pour obtenir des performances optimales. Bien que les forêts aléatoires donnent généralement de bons résultats avec les paramètres par défaut, un ajustement fin de ces hyperparamètres peut améliorer significativement les performances.

2.5.1 Nombre d'arbres (`n_estimators` ou `ntree`)

Ce paramètre contrôle le nombre d'arbres à construire dans la forêt. En général, un plus grand nombre d'arbres conduit à de meilleures performances et à une plus grande stabilité,

mais avec des gains décroissants. L'erreur diminue généralement jusqu'à atteindre un plateau lorsque l'on augmente le nombre d'arbres.

- **Valeurs typiques** : 100 à 1000 arbres.
- **Effet** : un plus grand nombre d'arbres réduit la variance et stabilise les prédictions, mais augmente le temps de calcul.
- **Règle pratique** : commencer avec 100 à 500 arbres ; augmenter si les ressources de calcul le permettent et si les performances n'ont pas atteint un plateau.
- **Remarque importante** : contrairement aux méthodes de boosting, l'ajout d'arbres ne provoque généralement pas de surapprentissage ; les arbres supplémentaires deviennent simplement redondants.

2.5.2 Nombre de caractéristiques par division (`max_features` ou `mtry`)

Il s'agit sans doute du paramètre d'ajustement le plus important, car il contrôle le nombre de caractéristiques sélectionnées aléatoirement à chaque division.

- **Classification** : la valeur par défaut est $\sqrt{p}$, où p représente le nombre total de caractéristiques.
- **Régression** : la valeur par défaut est $p/3$.
- **Effet** : des valeurs plus petites produisent des arbres plus diversifiés (corrélation plus faible) mais individuellement plus faibles ; des valeurs plus grandes produisent des arbres plus performants individuellement mais plus fortement corrélés.
- **Stratégie d'ajustement** : tester des valeurs autour des paramètres par défaut ; souvent, la valeur optimale est proche de $\sqrt{p}$ en classification, mais explorer $p/3$, $p/2$ ou $2\sqrt{p}$ peut être bénéfique.

2.5.3 Contrôle de la profondeur des arbres

Plusieurs paramètres contrôlent la profondeur de croissance des arbres :

- `max_depth` : profondeur maximale de chaque arbre (par défaut : `None`, croissance jusqu'à pureté).
- `min_samples_split` : nombre minimal d'exemples requis pour diviser un nœud (souvent 2 par défaut).
- `min_samples_leaf` : nombre minimal d'exemples requis dans une feuille (souvent 1 par défaut).

Ces paramètres établissent un compromis entre la complexité du modèle et sa capacité de généralisation :

- Des arbres très profonds peuvent capturer des relations complexes mais risquent le surapprentissage.
- Des arbres peu profonds sont plus rapides mais peuvent sous-apprendre.
- En pratique, les forêts aléatoires sont robustes vis-à-vis de ces paramètres, et les valeurs par défaut donnent souvent de bons résultats.

2.5.4 Taille des échantillons bootstrap (`max_samples`)

Ce paramètre contrôle la taille des échantillons bootstrap en tant que fraction du jeu de données original.

- **Valeur par défaut** : 1.0 (taille identique au jeu de données initial).
- **Effet** : des valeurs plus faibles augmentent la diversité des arbres mais peuvent réduire la qualité individuelle de chaque arbre.
- **Quand réduire** : pour les jeux de données très volumineux, échantillonner une fraction plus faible permet d'accélérer l'entraînement avec une perte de précision souvent négligeable.

2.5.5 Stratégie pratique d'ajustement

1. Commencer avec les paramètres par défaut (ils offrent généralement une excellente base).
2. Ajuster d'abord `n_estimators` afin d'identifier le point où les performances atteignent un plateau.
3. Ajuster ensuite `max_features` à l'aide de la validation croisée, car c'est le paramètre le plus influent.
4. Modifier les paramètres de profondeur uniquement si un surapprentissage ou un sous-apprentissage est observé.
5. Utiliser l'erreur *out-of-bag* (OOB) pour une évaluation rapide sans recourir à la validation croisée.

La principale force des forêts aléatoires réside dans leur faible sensibilité aux hyperparamètres. Les valeurs par défaut constituent une base solide, et le modèle échoue rarement de manière catastrophique même en présence de choix sous-optimaux.

Paramètre clé : `max_features` est l'hyperparamètre le plus important, car il contrôle directement le compromis entre la diversité des arbres et leur puissance individuelle.

2.6 Estimation de l'erreur *Out-of-Bag* (OOB)

L'une des fonctionnalités les plus élégantes des forêts aléatoires est l'estimation de l'erreur *Out-of-Bag* (OOB), qui fournit un mécanisme de validation intégré sans nécessiter un jeu de données de test séparé.

2.6.1 Mathématiques derrière l'OOB

Lorsqu'on crée un échantillon bootstrap de n observations, on échantillonne avec remise. Cela signifie que certaines observations peuvent apparaître plusieurs fois tandis que d'autres ne sont pas sélectionnées.

La probabilité qu'une observation donnée ne soit pas sélectionnée lors d'un tirage est :

$$1 - \frac{1}{n}$$

Étant donné que l'on effectue n tirages indépendants, la probabilité qu'une observation ne soit jamais sélectionnée est :

$$P(\text{non sélectionnée}) = \left(1 - \frac{1}{n}\right)^n$$

Lorsque n tend vers l'infini, cette probabilité converge vers $1/e \approx 0,368$. Autrement dit, environ 36,8% des observations sont laissées de côté pour chaque échantillon bootstrap. Ces observations non incluses sont appelées *échantillons out-of-bag* pour cet arbre particulier.

2.6.2 Fonctionnement de l'erreur OOB

Voici l'astuce : pour chaque observation du jeu de données d'apprentissage, on peut identifier les arbres qui ne l'ont pas utilisée lors de leur entraînement (c'est-à-dire ceux pour lesquels l'observation était OOB). On effectue alors les prédictions pour cette observation uniquement avec ces arbres.

Le processus est le suivant :

1. Pour chaque observation i du jeu d'entraînement, identifier tous les arbres pour lesquels i était OOB.
2. Agréger les prédictions de ces arbres (vote majoritaire pour la classification, moyenne pour la régression).
3. Comparer la prédiction OOB à la valeur réelle.
4. Calculer l'erreur OOB globale sur l'ensemble des observations.

Mathématiquement, pour une observation i , soit C_i l'ensemble des arbres où i est OOB :

$$\hat{y}_i^{\text{OOB}} = \frac{1}{|C_i|} \sum_{k \in C_i} T_k(x_i)$$

L'erreur OOB est alors définie par :

$$\text{OOB_Error} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{y}_i^{\text{OOB}})$$

où L est la fonction de perte (perte 0-1 pour la classification, erreur quadratique pour la régression).

2.6.3 Valeur et avantages de l'OOB

L'erreur OOB fournit une estimation non biaisée de l'erreur de généralisation. Elle agit comme une validation croisée intégrée dans le processus d'entraînement :

- **Pas de jeu de validation séparé** : l'évaluation de performance se fait uniquement avec les données d'entraînement.
- **Efficace** : aucun entraînement supplémentaire n'est nécessaire.
- **Non biaisée** : chaque prédiction utilise uniquement les arbres n'ayant pas vu cette observation.
- **Surveillance de l'entraînement** : l'OOB permet de suivre la stabilisation de l'erreur et de déterminer le nombre d'arbres suffisant.

2.6.4 Applications pratiques

1. Sélection de modèle : comparer les erreurs OOB pour différents réglages d'hyperparamètres.

2. Critère d'arrêt : arrêter l'ajout d'arbres lorsque l'erreur OOB atteint un plateau.
3. Sélection de variables : retirer certaines caractéristiques et vérifier si l'erreur OOB s'améliore.
4. Évaluation rapide : estimer les performances sans jeu de validation (la validation finale doit toutefois utiliser un jeu de test indépendant).

2.6.5 Limites

Bien que puissante, l'erreur OOB présente certaines limites :

- Légèrement optimiste par rapport à une validation avec un jeu de test indépendant (les modèles voient l'ensemble des données collectivement).
- Nécessite un nombre suffisant d'arbres pour obtenir des estimations stables (chaque observation doit être OOB pour plusieurs arbres).
- Moins fiable avec des jeux de données très petits.

En pratique, l'erreur OOB se rapproche généralement de l'erreur obtenue par validation croisée, tout en étant beaucoup plus efficace à calculer, ce qui en fait un outil précieux pour travailler avec les forêts aléatoires.

Formule clé : probabilité qu'une observation ne soit pas sélectionnée dans un échantillon bootstrap :

$$P(\text{non sélectionnée}) = \left(1 - \frac{1}{n}\right)^n \rightarrow \frac{1}{e} \approx 0,368$$

2.7 Mesures de l'importance des variables

Comprendre quelles variables influencent les prédictions est essentiel pour l'interprétation du modèle, la sélection des caractéristiques et les insights métiers. Les forêts aléatoires offrent deux approches principales pour mesurer l'importance des variables.

2.7.1 Diminution moyenne de l'impureté (MDI)

Également appelée *Gini importance*, cette méthode est la valeur par défaut dans la plupart des implémentations. L'idée est simple : les variables importantes sont utilisées pour des divisions qui réduisent significativement l'impureté.

1. Pour chaque nœud de chaque arbre où cette variable est utilisée pour la division, mesurer la diminution d'impureté pondérée.
2. Somme des diminutions sur tous les arbres.
3. Normalisation par le nombre d'arbres.

Mathématiquement, pour une variable j :

$$\text{Importance}(j) = \sum_k \sum_{t \in T_k} I(v_t = j) \times \left(\frac{n_t}{N}\right) \times \Delta I_t$$

où :

- T_k représente tous les nœuds de l'arbre k ,
- $I(v_t = j)$ est une fonction indicatrice (1 si le nœud t se divise sur la variable j , 0 sinon),

- n_t est le nombre d'échantillons au nœud t ,
- N est le nombre total d'échantillons,
- ΔI_t est la diminution d'impureté au nœud t : $I_t - \frac{n_{\text{left}}}{n_t} I_{\text{left}} - \frac{n_{\text{right}}}{n_t} I_{\text{right}}$.

Avantages de MDI :

- Rapide à calculer (effectué pendant l'entraînement)
- Stable (moyenne sur de nombreux arbres)
- Pas besoin de recalculer des prédictions

Inconvénients de MDI :

- Biais vers les variables à forte cardinalité (beaucoup de valeurs uniques)
- Biais vers les variables continues par rapport aux catégorielles
- Peut attribuer de l'importance à des variables non informatives si elles sont corrélées avec des variables informatives
- Calculé sur les données d'entraînement, peut ne pas refléter la performance sur des données de test

2.7.2 Diminution moyenne de la précision (MDA) / Importance par permutation

Cette approche mesure la baisse de précision des prédictions lorsque les valeurs d'une variable sont mélangées aléatoirement, rompant sa relation avec la cible.

1. Calculer la précision de référence (souvent avec les prédictions OOB).
2. Pour chaque variable j :
 - (a) Permuter aléatoirement les valeurs de j .
 - (b) Recalculer les prédictions avec les données permutées.
 - (c) Mesurer la diminution de précision.
3. Moyenne de la diminution sur tous les arbres.

Mathématiquement :

$$\text{Importance}(j) = \frac{1}{K} \sum_{k=1}^K [\text{Accuracy}_k - \text{Accuracy}_k(\text{permuté } j)]$$

Avantages de MDA :

- Non biaisé par le type de variable
- Reflète l'importance prédictive réelle
- Peut utiliser les données de test pour une estimation plus fiable
- Plus interprétable (mesure directe de l'impact sur les prédictions)

Inconvénients de MDA :

- Coûteux en calcul (nécessite de recalculer les prédictions)
- Peut être instable avec de petits jeux de données
- Sous-estime l'importance des variables corrélées (permuter une variable corrélée peut peu affecter la précision si les autres restent)

2.7.3 Considérations pratiques

1. L'échelle compte : normaliser les importances pour qu'elles somment à 1 facilite l'interprétation.
2. Problèmes de corrélation : si des variables sont fortement corrélées, l'importance peut se répartir entre elles.
3. Relations non-linéaires : certaines interactions complexes peuvent ne pas être capturées.
4. Valider les insights : utiliser l'expertise métier pour vérifier la cohérence des résultats.

2.7.4 Exemple d'interprétation

Supposons que vous prédisez le prix des maisons avec ces importances normalisées :

- Localisation : 0,35
- Surface habitable : 0,28
- Nombre de chambres : 0,15
- Âge de la maison : 0,12
- Taille du garage : 0,10

Cela indique que la localisation et la surface sont les facteurs principaux (63% de l'importance totale), tandis que les autres caractéristiques contribuent de manière modeste. Les efforts de collecte de données peuvent donc se concentrer sur ces variables clés.

Idée clé : MDI est rapide mais biaisé, MDA est non biaisé mais coûteux en calcul.

2.8 Avantages des Forêts Aléatoires

Les forêts aléatoires sont devenues l'un des algorithmes de machine learning les plus populaires, et ce pour de bonnes raisons. Elles offrent une combinaison convaincante de performance, de robustesse et de simplicité d'utilisation, ce qui les rend idéales pour de nombreuses applications réelles.

2.8.1 Robustesse au surapprentissage

Contrairement aux arbres de décision simples, qui mémorisent facilement les données d'entraînement, les forêts aléatoires résistent au surapprentissage grâce à la moyenne des prédictions de l'ensemble d'arbres. La combinaison de l'échantillonnage bootstrap et de la sélection aléatoire des caractéristiques permet que les erreurs individuelles des arbres aient tendance à s'annuler plutôt qu'à se cumuler. Dans la pratique, il est souvent possible d'ajouter davantage d'arbres sans dégrader la performance sur les données de test, bien que les gains deviennent décroissants.

2.8.2 Prétraitement minimal des données

Les forêts aléatoires gèrent remarquablement bien les données brutes :

- Pas besoin de normalisation des caractéristiques : les arbres décident selon les points de séparation, pas selon les distances.



FIGURE 2.4 – Overfitting vs Underfitting

- Gestion des types de données mixtes : elles traitent naturellement les variables numériques et catégorielles.
- Pas besoin d'ingénierie de caractéristiques : elles peuvent découvrir automatiquement des interactions complexes.
- Robustesse aux valeurs aberrantes : les divisions sont basées sur des valeurs ordonnées, donc les extrêmes ont un impact limité.

Cela rend les forêts aléatoires particulièrement utiles lorsque l'on souhaite obtenir rapidement des insights sans nettoyage de données approfondi.

2.8.3 Gestion des valeurs manquantes

Selon les implémentations, les forêts aléatoires peuvent traiter les données manquantes de plusieurs manières :

- *Surrogate splits* : utiliser d'autres variables pour approximer la division lorsque la variable principale est manquante.
- Imputation par moyenne ou mode : remplir les valeurs manquantes par la moyenne ou le mode.
- Catégorie séparée : traiter les valeurs manquantes comme une valeur distincte.
- Proximité OOB : imputer en fonction d'observations similaires.

2.8.4 Non-linéarité naturelle

Les arbres capturent automatiquement les relations non linéaires et les interactions sans spécification explicite. Si l'âge et le revenu interagissent de manière complexe, les forêts aléatoires le détecteront grâce à la structure des arbres, sans avoir besoin de créer manuellement des termes d'interaction $\text{âge} \times \text{revenu}$.

2.8.5 Parallélisation et scalabilité

Chaque arbre s'entraîne indépendamment, ce qui rend les forêts aléatoires facilement parallélisables. Les implémentations modernes exploitent plusieurs cœurs CPU, réduisant ainsi considérablement le temps d'entraînement. Cette scalabilité s'étend également aux très grands jeux de données contenant des millions d'observations.

2.8.6 Validation intégrée

L'erreur *Out-of-Bag* (OOB) fournit une validation croisée automatique sans jeu de validation séparé, économisant à la fois des données et du temps de calcul. Cela est

particulièrement précieux lorsque les données sont limitées.

2.8.7 Avantages supplémentaires

- Importance des variables : contrairement aux réseaux de neurones *black-box*, les forêts aléatoires fournissent des scores d'importance interprétables.
- Estimations de probabilité : en classification, elles fournissent naturellement la probabilité d'appartenance à chaque classe via la proportion d'arbres votant pour chaque classe.
- Gestion des classes déséquilibrées : avec les bons paramètres, elles traitent mieux les classes déséquilibrées que de nombreux autres algorithmes.
- Performances *out-of-the-box* : elles fonctionnent souvent très bien avec les hyperparamètres par défaut.
- Polyvalence : elles excellent dans diverses tâches : classification, régression, sélection de variables, détection d'outliers, clustering et apprentissage semi-supervisé.

Cette polyvalence, combinée à la robustesse et à la simplicité d'utilisation, explique pourquoi les forêts aléatoires restent un algorithme de référence près de 25 ans après leur introduction. Elles offrent une combinaison rare de puissance et de simplicité difficile à surpasser.

Avantage clé : Les forêts aléatoires fonctionnent bien avec un prétraitement minimal et fournissent une validation intégrée via l'erreur OOB.

2.9 Limitations et Défis

Malgré leurs nombreux atouts, les forêts aléatoires présentent des limitations importantes qu'il est essentiel de connaître avant de les déployer en production.

2.9.1 Difficultés d'interprétation

Alors que les arbres de décision individuels sont très interprétables, les forêts aléatoires sacrifient cette transparence au profit de la précision. Comprendre pourquoi une forêt aléatoire a produit une prédiction spécifique est difficile :

- Impossible de visualiser facilement 500 arbres.
- L'importance des variables aide, mais n'explique pas les prédictions individuelles.
- Le chemin de décision pour une seule prédiction implique des centaines de nœuds.
- Expliquer le modèle à des parties prenantes devient complexe.

Pour les applications nécessitant la confiance humaine ou la conformité réglementaire (diagnostic médical, approbation de prêts), cette opacité peut poser problème.

2.9.2 Besoins en mémoire

Les forêts aléatoires stockent chaque arbre en mémoire, et chaque arbre peut être volumineux :

- Un arbre peut contenir des milliers de nœuds.
- Chaque nœud stocke le critère de division, le seuil et la prédiction.
- Avec 500 à 1000 arbres, la consommation mémoire augmente considérablement.

Pour un jeu de données de 1 million d'échantillons et 100 variables, une forêt aléatoire peut nécessiter plusieurs gigaoctets de RAM, ce qui devient problématique pour des déploiements mobiles ou embarqués.

2.9.3 Vitesse de prédiction

Bien que l'entraînement soit facilement parallélisable, la prédiction nécessite généralement de parcourir tous les arbres séquentiellement :

- Chaque prédiction traverse des centaines d'arbres.
- Plus lente que les modèles linéaires ou les arbres uniques.
- Peut poser problème pour des applications en temps réel (trading haute fréquence, publicité en ligne).

Pour une forêt de 1000 arbres, prédire sur de grands jeux de données peut être long.

2.9.4 Performance sur données hautement dimensionnelles et clairsemées

Les forêts aléatoires peuvent être moins performantes sur des données très hautes dimensionnelles et clairsemées, fréquentes dans :

- Classification de texte (milliers de mots, majoritairement zéros)
- Génomique (millions de marqueurs génétiques)
- Systèmes de recommandation (millions d'utilisateurs/objets)

La sélection aléatoire des variables devient moins efficace lorsque la plupart des variables sont non pertinentes, et les modèles basés sur les arbres gèrent moins bien la rareté que les modèles linéaires ou les réseaux de neurones.

2.9.5 Limites d'extrapolation

Ce problème est particulièrement important en régression. Les forêts aléatoires ne peuvent pas prédire des valeurs en dehors de l'intervalle observé dans les données d'entraînement :

- Si les cibles d'entraînement vont de 10 à 100, les prédictions resteront dans cet intervalle.
- Les arbres divisent les données en régions et font la moyenne des valeurs dans chaque région.
- Aucune région ne peut générer une valeur hors de l'intervalle de l'entraînement.

Exemple : prédire le prix des maisons lorsque les données d'entraînement varient de 100k\$ à 500k\$. Le modèle ne pourra jamais prédire 600k\$.

2.9.6 Autres limitations

- Importance des variables biaisée : MDI favorise les variables continues ou à forte cardinalité.
- Manque de lissage : les prédictions sont par morceaux constants (régression) ou votes majoritaires (classification).
- Difficulté avec certaines relations : peut avoir du mal avec des relations linéaires, des événements rares et des dépendances temporelles.

- Réglage des hyperparamètres peu intuitif : comprendre pourquoi certains paramètres aident est moins clair que pour d'autres algorithmes.
- Pas toujours le meilleur choix : souvent surpassé par le gradient boosting sur données structurées, le deep learning sur données complexes, et les modèles linéaires sur données clairsemées.

Comprendre ces limitations permet de décider judicieusement quand utiliser les forêts aléatoires et quand d'autres méthodes peuvent mieux convenir.

Limitation clé : Les forêts aléatoires ne peuvent pas extrapoler en dehors de l'intervalle des données d'entraînement pour les tâches de régression.

Conclusion

Les forêts aléatoires constituent un algorithme de machine learning puissant et polyvalent. Grâce à la combinaison de l'échantillonnage bootstrap et de la sélection aléatoire de variables, elles offrent une grande robustesse au surapprentissage, une capacité naturelle à gérer les relations non linéaires, et une validation intégrée via l'erreur Out-of-Bag. Bien qu'elles nécessitent plus de mémoire et soient moins interprétables que les arbres simples, leur performance élevée, leur résistance aux valeurs aberrantes et leur aptitude à traiter différents types de données en font un outil incontournable pour la classification, la régression et d'autres applications analytiques. Les forêts aléatoires illustrent parfaitement la puissance des méthodes d'ensemble dans l'apprentissage automatique.

Toutefois, les méthodes d'ensemble ne s'arrêtent pas aux forêts aléatoires. Dans le chapitre suivant, nous aborderons XGBoost (eXtreme Gradient Boosting), un algorithme qui pousse encore plus loin l'approche ensembliste en adoptant une stratégie de boosting plutôt que de bagging. Contrairement aux Random Forests qui construisent des arbres indépendants en parallèle, XGBoost construit ses arbres de manière séquentielle, chaque nouvel arbre cherchant à corriger les erreurs des arbres précédents. Cette technique de gradient boosting, combinée à de nombreuses optimisations algorithmiques, fait de XGBoost l'un des algorithmes les plus performants et les plus utilisés dans les compétitions de machine learning et les applications industrielles.

Chapitre 3

XGBoost (eXtreme Gradient Boosting)

3.1 Introduction

XGBoost, acronyme de *eXtreme Gradient Boosting*, représente une avancée majeure dans le domaine des algorithmes d'apprentissage automatique supervisé. Il s'agit d'un algorithme de gradient boosting hautement optimisé et scalable, positionné comme une référence pour les tâches de classification et de régression sur données tabulaires. Introduit par Tianqi Chen et Carlos Guestrin dans leur article séminal de 2016 Chen and Guestrin (2016), XGBoost a rapidement conquis la communauté scientifique et industrielle grâce à sa combinaison unique de précision, de vitesse et de robustesse.

Son succès est attesté par ses victoires répétées dans les compétitions de data science sur Kaggle, où il a souvent dominé les classements, ainsi que par son adoption massive dans des secteurs variés tels que la finance (détection de fraude), la santé (prédiction de maladies), l'e-commerce (recommandations) et les transports (prévision de trafic). Ces applications réelles soulignent sa capacité à gérer des volumes de données massifs avec une efficacité remarquable.

Par rapport à Random Forest, qui repose sur le *bagging* (construction parallèle d'arbres indépendants pour minimiser la variance), XGBoost utilise le *boosting* : une méthode séquentielle où chaque arbre corrige les erreurs des précédents, réduisant ainsi le biais global du modèle.

Ce chapitre vise à introduire les principes fondamentaux du gradient boosting, à détailler les innovations mathématiques et algorithmiques propres à XGBoost, à explorer ses fonctionnalités avancées et optimisations systèmes, et à discuter de ses avantages, limites et comparaisons avec d'autres approches, afin de fournir une compréhension complète et pratique de cet algorithme essentiel.

3.2 Principe du Gradient Boosting

3.2.1 Intuition : apprentissage par correction d'erreurs

Le principe clé du gradient boosting est l'apprentissage itératif. Contrairement à la construction parallèle des forêts aléatoires, le boosting construit le modèle étape par étape. Chaque nouvel arbre est entraîné non pas sur la variable cible originale, mais sur les erreurs résiduelles des arbres précédents.

Cette méthode peut être vue comme une descente de gradient dans l'espace fonctionnel. Si l'on considère le modèle global comme un point dans l'espace des fonctions possibles, chaque nouvel arbre ajouté représente un pas dans la direction opposée du gradient de la fonction de perte, minimisant ainsi l'erreur globale de manière incrémentale.

3.2.2 Formulation mathématique du gradient boosting

L'objectif est de trouver une fonction F qui minimise la perte globale sur un ensemble de n observations :

$$\min_F \sum_{i=1}^n L(y_i, F(x_i)) \quad (3.1)$$

où L est une fonction de perte convexe et différentiable.

Le modèle est construit de manière additive. À l'étape m , la prédiction $F_m(x)$ est mise à jour selon :

$$F_m(x) = F_{m-1}(x) + \eta h_m(x) \quad (3.2)$$

Ici, $h_m(x)$ est le nouvel arbre ajouté et η (taux d'apprentissage) contrôle l'amplitude de la mise à jour pour éviter le surapprentissage.

Le nouvel arbre h_m est entraîné pour approximer le gradient négatif de la perte, aussi appelé pseudo-résidu g_i pour chaque observation i :

$$g_i = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad (3.3)$$

Différentes fonctions de perte peuvent être utilisées selon le problème : erreur quadratique (L2) pour la régression, *log-loss* pour la classification binaire, ou erreur absolue (L1) pour une plus grande robustesse.

3.2.3 Limitations du gradient boosting classique

Le Gradient Boosting Machine (GBM) traditionnel souffre de certaines limitations :

- **Absence de régularisation explicite** : Le risque de surapprentissage est élevé si le nombre d'arbres est trop grand ou leur profondeur trop importante.
- **Optimisation de premier ordre uniquement** : L'utilisation seule du gradient limite la précision de l'approximation de la perte.
- **Gestion sous-optimale des valeurs manquantes** : Nécessite souvent un pré-traitement coûteux.
- **Performances limitées sur grandes données** : L'implémentation standard manque d'optimisations systèmes pour passer à l'échelle.

3.3 XGBoost : Innovations Mathématiques

XGBoost adresse ces limitations par une formulation mathématique régularisée et une approximation de second ordre.

3.3.1 Fonction objectif régularisée

La fonction objectif à minimiser à chaque étape t inclut désormais un terme de régularisation Ω :

$$\mathcal{L}(\phi) = \sum_{i=1}^n L(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (3.4)$$

Le terme de régularisation pour un arbre f dépanne de sa structure et de ses poids :

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 + \alpha \sum_{j=1}^T |w_j| \quad (3.5)$$

Chaque terme a une signification précise :

- γ (gamma) : pénalité sur le nombre de feuilles T , contrôlant la complexité structurelle de l'arbre.
- λ (lambda) : régularisation L2 sur les poids des feuilles w_j , favorisant le lissage (analogue à Ridge).
- α (alpha) : régularisation L1 sur les poids, favorisant la parcimonie (analogue à Lasso).

3.3.2 Approximation de Taylor de second ordre

Pour optimiser cette fonction objectif, XGBoost utilise un développement de Taylor de second ordre autour de la prédiction précédente $\hat{y}^{(t-1)}$:

$$L(y_i, \hat{y}^{(t-1)} + f_t(x_i)) \approx L(y_i, \hat{y}^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \quad (3.6)$$

où g_i et h_i sont définis comme :

$$g_i = \partial_{\hat{y}^{(t-1)}} L(y_i, \hat{y}^{(t-1)}), \quad h_i = \partial_{\hat{y}^{(t-1)}}^2 L(y_i, \hat{y}^{(t-1)}) \quad (3.7)$$

L'ajout de l'information de courbure (via la Hessienne h_i) permet une convergence plus rapide et une meilleure stabilité numérique par rapport à l'approche de premier ordre utilisée dans le GBM classique.

3.3.3 Calcul du poids optimal des feuilles

En regroupant les instances par feuille j (ensemble $I_j = \{i | q(x_i) = j\}$), on peut réécrire l'objectif approximé et trouver analytiquement le poids optimal w_j^* :

$$\tilde{\mathcal{L}}^{(t)} = \sum_{j=1}^T \left[\left(\sum_{i \in I_j} g_i \right) w_j + \frac{1}{2} \left(\sum_{i \in I_j} h_i + \lambda \right) w_j^2 \right] + \gamma T \quad (3.8)$$

La solution qui minimise cette équation quadratique est :

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (3.9)$$

3.3.4 Score de qualité d'une structure d'arbre

En réinjectant w_j^* dans l'objectif, on obtient un score de structure permettant d'évaluer la qualité d'un arbre. Cela permet de définir le gain obtenu lors d'une division d'une feuille en deux (gauche L et droite R) :

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma \quad (3.10)$$

où $G = \sum g_i$ et $H = \sum h_i$. Cette formule sert de critère pour décider s'il faut effectuer un split. Le terme γ agit comme un seuil minimal : si le gain calculé est inférieur à γ , la branche n'est pas créée. Cela réalise un élagage (*pruning*) automatique pendant la construction de l'arbre.

3.4 Fonctionnalités Spécifiques de XGBoost

3.4.1 Gestion native des valeurs manquantes

XGBoost utilise un algorithme de *Sparsity-aware Split Finding*. Lors de la recherche du meilleur split, il teste automatiquement d'envoyer les valeurs manquantes vers la branche gauche ou droite et choisit la direction qui maximise le gain. Cela permet de gérer les données incomplètes nativement, sans imputation préalable.

3.4.2 Gestion du déséquilibre de classes

Pour les jeux de données déséquilibrés, le paramètre `scale_pos_weight` permet de rééquilibrer l'importance des classes :

$$\text{scale_pos_weight} = \frac{n_{\text{classe majoritaire}}}{n_{\text{classe minoritaire}}} \quad (3.11)$$

Ce poids est appliqué aux gradients et hessiennes des exemples positifs, augmentant leur influence lors de l'entraînement. C'est crucial pour des applications comme la détection de fraude ou le diagnostic de maladies rares.

3.4.3 Subsampling stochastique

Pour améliorer la généralisation, XGBoost emprunte le principe de sous-échantillonnage aux Random Forests :

- `subsample` : fraction des observations tirées aléatoirement pour construire chaque arbre.
- `colsample_bytree`, `colsample_bylevel`, `colsample_bynode` : fraction des colonnes (features) utilisées à différents niveaux de construction.

Cela permet de décorrélérer les arbres et d'ajouter une couche supplémentaire de régularisation.

3.4.4 Early stopping

L'entraînement peut être configuré pour s'arrêter prématurément si la performance sur un jeu de validation ne s'améliore pas après un certain nombre d'itérations (*patience*). Cela détermine automatiquement le nombre optimal d'arbres et prévient le surapprentissage tardif.

3.5 Optimisations Systèmes

3.5.1 Parallélisation

Bien que le boosting soit séquentiel par nature (l'arbre t dépend de l'arbre $t - 1$), XGBoost parallélise la construction à l'intérieur de chaque arbre. La recherche du meilleur split sur toutes les features est effectuée en parallèle grâce à une structure de données en colonnes (*Column Block*).

3.5.2 Scalabilité

XGBoost implémente plusieurs techniques pour gérer les données volumineuses :

- **Histogram-based splits** : Les données continues sont discrétisées en *bins*, réduisant la complexité de recherche de split.
- **Out-of-core computing** : Optimisation des accès disques pour traiter des données ne tenant pas en mémoire vive.
- **Weighted Quantile Sketch** : Un algorithme d'approximation distribué pour trouver les quantiles sur des données pondérées, facilitant la création d'histogrammes précis.

3.6 Hyperparamètres Clés

3.6.1 Contrôle de la complexité

- `max_depth` : Profondeur maximale de l'arbre (typiquement entre 3 et 10).
- `min_child_weight` : Somme minimale des poids (Hessienne) requise dans une feuille pour autoriser une partition.
- `gamma` : Réduction de perte minimale requise pour faire un split.

3.6.2 Régularisation et Apprentissage

- `lambda` (λ) et `alpha` (α) : Termes de régularisation L2 et L1.
- `learning_rate` (η) : Facteur de réduction de l'impact de chaque nouvel arbre.

3.6.3 Sampling et Autres

- `subsample` et `colsample_bytree` : Contrôle du caractère stochastique.
- `scale_pos_weight` : Gestion du déséquilibre.
- `n_estimators` associé à `early_stopping_rounds`.

3.7 Avantages et Limites

3.7.1 Avantages

XGBoost offre une combinaison unique de performance (état de l'art sur données tabulaires), de robustesse (régularisation intégrée, gestion valeurs manquantes) et de ra-

pidité (optimisations systèmes). Sa flexibilité permet de définir des fonctions de perte et métriques personnalisées.

3.7.2 Limites

Cependant, il reste une "boîte noire" nécessitant des outils d'explicabilité comme SHAP. Son réglage est complexe avec plus de 20 hyperparamètres, et il peut être sensible au bruit. Sa nature séquentielle peut être un frein par rapport à la parallélisation totale des Random Forests lors de l'entraînement.

3.7.3 Comparaison : XGBoost vs Random Forest

Critère	XGBoost	Random Forest
Performance (Données Tabulaires)	Excellente	Très Bonne
Vitesse d'entraînement	Moyenne	Très Rapide
Interprétabilité	Faible	Moyenne
Facilité d'usage	Moyenne	Très Facile
Résistance au surapprentissage	Très Bonne	Excellente

TABLE 3.1 – Comparaison synthétique : XGBoost vs Random Forest

3.8 Conclusion

XGBoost représente l'état de l'art du gradient boosting grâce à ses trois piliers : la précision (via l'optimisation de second ordre régularisée), l'efficacité (parallélisation et gestion mémoire), et la praticité (fonctionnalités natives). C'est le choix optimal lorsque la performance prédictive est le critère critique, surpassant souvent les méthodes classiques malgré une complexité de mise en œuvre plus élevée. Bien que des successeurs comme LightGBM et CatBoost existent, XGBoost demeure une référence incontournable.

Chapitre 4

État de l’art sur la détection du diabète à l’aide des méthodes d’apprentissage automatique

4.1 Introduction

Le diabète sucré (*Diabetes Mellitus*, DM) est une maladie métabolique chronique caractérisée par une hyperglycémie persistante, c’est-à-dire une concentration anormalement élevée de glucose dans le sang. Cette anomalie résulte soit d’une déficience de la sécrétion d’insuline par le pancréas, soit d’une résistance des cellules à l’action de cette hormone, soit d’une combinaison des deux mécanismes (Iparraguirre-Villanueva et al., 2023a). L’insuline, hormone produite par les cellules bêta des îlots de Langerhans, joue un rôle fondamental dans la régulation glycémique : elle permet aux cellules d’absorber le glucose circulant dans le sang pour le convertir en énergie. En son absence ou en cas de résistance à son action, le glucose s’accumule dans la circulation sanguine, entraînant à long terme des dommages irréversibles sur de nombreux organes et systèmes.

Types de diabète

On distingue principalement trois formes cliniques du diabète :

Le diabète de type 1 (DT1) est une maladie auto-immune dans laquelle le système immunitaire attaque et détruit les cellules bêta pancréatiques productrices d’insuline. Il représente environ 5 à 10% des cas diagnostiqués et se manifeste généralement durant l’enfance ou l’adolescence. Les patients atteints de DT1 dépendent à vie d’injections d’insuline exogène pour leur survie (Iparraguirre-Villanueva et al., 2023a; Zou et al., 2018).

Le diabète de type 2 (DT2) constitue la forme la plus répandue, représentant plus de 90% des cas mondiaux. Il se caractérise par une résistance progressive à l’insuline, combinée à une sécrétion pancréatique insuffisante pour compenser cette résistance. Son développement est fortement lié au mode de vie — sédentarité, obésité, alimentation hypercalorique — ainsi qu’à une prédisposition génétique. Contrairement au DT1, il survient le plus souvent à l’âge adulte, bien qu’une tendance croissante soit observée chez les adolescents dans les pays développés (Zou et al., 2018).

Le diabète gestationnel apparaît durant la grossesse chez des femmes ne présentant pas de diabète préalable. Il se résorbe généralement après l’accouchement, mais augmente significativement le risque de développer un DT2 ultérieurement, aussi bien chez la mère que chez l’enfant. La base de données Pima Indians Diabetes Database (PIDDD), utilisée dans ce travail, concerne exclusivement des femmes adultes de la communauté Pima, une population présentant une prévalence exceptionnellement élevée de DT2, dont une part importante est liée à des antécédents de diabète gestationnel.

Facteurs de risque et variables cliniques déterminantes

La progression vers le diabète de type 2 est influencée par un ensemble de facteurs biologiques et comportementaux. Parmi les principaux indicateurs cliniques figurant dans la littérature et dans la PIDD, on trouve (Zou et al., 2018; Iparraguirre-Villanueva et al., 2023a) :

- **La glycémie (glucose plasmatique)** : principal marqueur diagnostique, mesurée à jeun ou après une charge orale en glucose. Un taux supérieur à 126 mg/dL à jeun est diagnostique du diabète selon les critères de l'American Diabetes Association (ADA). C'est la variable de plus grande importance prédictive dans les études sur la PIDD.
- **L'indice de masse corporelle (IMC ou BMI)** : fortement corrélé au risque de DT2, un IMC supérieur à 30 kg/m² indique une obésité et constitue un facteur de risque majeur de résistance à l'insuline.
- **Le taux d'insuline** : une élévation chronique de l'insulinémie peut signaler une résistance à l'insuline précédant le diabète clinique.
- **La pression artérielle diastolique** : l'hypertension est à la fois un facteur de risque et une comorbidité fréquente du diabète, augmentant le risque cardiovasculaire.
- **L'épaisseur du pli cutané tricipital** : indicateur indirect de la masse grasse corporelle, corrélé à l'obésité et à la résistance à l'insuline.
- **La fonction pedigree du diabète (Diabetes Pedigree Function)** : score composite reflétant l'hérédité familiale diabétique, intégrant la prévalence du diabète chez les apparentés et leur degré de parenté.
- **L'âge** : le risque de DT2 augmente avec l'âge, particulièrement après 45 ans.
- **Le nombre de grossesses** : dans la population Pima, le nombre de grossesses est corrélé à l'âge et constitue un facteur de risque indirect via le diabète gestationnel.

Conséquences et enjeux cliniques

Non traité ou mal contrôlé, le diabète entraîne des complications graves : néphropathie diabétique pouvant évoluer vers l'insuffisance rénale terminale, rétinopathie et cécité, neuropathie périphérique, maladies cardiovasculaires et artériopathie des membres inférieurs pouvant mener à l'amputation. La détection précoce est donc cruciale : elle permet d'initier des interventions sur le mode de vie et des traitements pharmacologiques avant l'apparition des complications irréversibles (Wee et al., 2024; Khanam and Foo, 2021).

4.2 Approches traditionnelles de détection du diabète

Historiquement, le diagnostic du diabète repose sur des critères biochimiques standardisés établis par des organisations de référence telles que l'OMS et l'ADA. Ces critères incluent la mesure de la glycémie à jeun (≥ 126 mg/dL), la glycémie deux heures après une charge orale en glucose de 75g (≥ 200 mg/dL), ou le taux d'hémoglobine glyquée HbA1c ($\geq 6,5\%$). Ces mesures constituent des seuils fixes, appliqués uniformément à l'ensemble de la population.

Si ces méthodes présentent l'avantage d'être standardisées, reproductibles et bien comprises cliniquement, elles souffrent de plusieurs limitations importantes dans un contexte de prévention et de dépistage de masse (Sisodia and Sisodia, 2018) :

1. **Absence d'intégration multi-variables** : les critères traditionnels ne tiennent pas compte simultanément des multiples facteurs de risque. Or, la progression vers le DT2 est un phénomène multidimensionnel impliquant des interactions complexes entre variables génétiques, métaboliques et comportementales.
2. **Détection tardive** : Ils diagnostiquent un diabète déclaré, souvent après plusieurs années de dysrégulation glycémique silencieuse (stade prédiabétique). L'étude de Lv et al. (2023) souligne d'ailleurs que certaines personnes ayant une glycémie à jeun normale peuvent en réalité être diabétiques, passant ainsi inaperçues lors des examens de routine.
3. **Coût et accessibilité** : les tests biologiques (HOMA-IR, OGTT) requièrent des prélèvements à jeun et une infrastructure de laboratoire, ce qui limite leur accessibilité dans les systèmes de santé à ressources limitées.
4. **Variabilité inter-individuelle** : deux individus présentant la même glycémie à jeun peuvent avoir des profils de risque très différents selon leurs caractéristiques anthropométriques, héréditaires et comportementales.

Ces limites ont motivé l'exploration de méthodes analytiques capables d'exploiter l'ensemble des données cliniques disponibles pour produire des prédictions personnalisées du risque diabétique (Sisodia and Sisodia, 2018; Kavakiotis et al., 2017).

4.3 Approches basées sur l'apprentissage automatique

L'application de l'apprentissage automatique à la détection du diabète a fait l'objet de nombreuses recherches, utilisant une variété d'algorithmes et de jeux de données.

Dans une étude visant à évaluer l'efficacité de différents algorithmes pour la détection précoce du diabète de type 2, Gowthami et al. (2024) ont utilisé un ensemble de données de 520 patients du Sylhet Diabetes Hospital au Bangladesh, comprenant 17 attributs. Leur méthodologie a mis l'accent sur la sélection de caractéristiques (feature selection) pour réduire la dimensionnalité et améliorer la précision. En comparant des modèles tels que la régression logistique, les K-plus proches voisins (KNN), les arbres de décision, les forêts aléatoires et les machines à vecteurs de support, ils ont démontré que l'algorithme Random Forest atteignait une précision impressionnante de 98%, soulignant le potentiel de ces méthodes pour un dépistage précis et non invasif.

De leur côté, Iparraguirre-Villanueva et al. (2023b) se sont concentrés sur la détection et la classification du diabète de type 2 en utilisant le jeu de données PIMA Indian. Ils ont investigué cinq modèles de ML : K-NN, Bernoulli Naive Bayes (BNB), arbre de décision (DT), régression logistique (LR) et SVM. Face à la petite taille du jeu de données, ils ont appliqué la technique de suréchantillonnage SMOTE pour équilibrer les classes. Leurs résultats ont montré que les modèles K-NN et BNB surpassaient les autres, avec des précisions respectives de 79,6% et 77,2%, concluant que l'utilisation de modèles ML pour la détection précoce du diabète est très prometteuse.

S'inscrivant dans une démarche similaire, Saihood and Sonuç (2023) ont proposé un cadre pratique en trois étapes pour le diagnostic du diabète, incluant un prétraitement

poussé des données (gestion des valeurs manquantes, des outliers, équilibrage des classes, sélection de caractéristiques), un réglage fin des hyperparamètres par recherche par grille (grid search), et l’utilisation de méthodes d’ensemble (bagging, boosting, stacking). En testant leur approche sur le jeu de données PIDD, ils ont constaté la supériorité des méthodes d’ensemble. Le stacking, combinant Random Forest et SVM, a obtenu la meilleure précision (97,50%), suivi de près par Random Forest (97,20%) et XGBoost (97,10%). Ces résultats confirment que l’attention portée au prétraitement et l’utilisation d’ensembles de modèles sont cruciales pour une performance élevée.

Lv et al. (2023) ont abordé la problématique sous un angle original : détecter les patients diabétiques parmi les personnes ayant une glycémie à jeun normale, qui passent donc inaperçues lors des examens standards. En utilisant les données d’examens physiques de plus de 60 000 individus issus de trois cohortes chinoises, ils ont construit un modèle de prédiction appelé DRING (Diabetes Risk of Individuals with Normal fasting Glucose). Leur modèle, basé sur la régression logistique, a montré d’excellentes performances avec seulement 13 caractéristiques cliniques courantes (dont l’âge, l’IMC, la numération lymphocytaire). Ils ont également développé un cadre pour identifier les facteurs de risque personnalisés pour un individu donné, démontrant la faisabilité d’une approche de dépistage plus fine et personnalisée.

Enfin, une revue de la littérature exhaustive menée par Juwono et al. (2024) a analysé plus de 50 modèles de ML et d’apprentissage profond pour la détection du diabète. Leur analyse souligne plusieurs points critiques : (1) la majorité des études utilisent des ensembles de données invasifs comme le PIDD, alors que le développement d’outils basés sur des mesures anthropométriques non invasives est une demande clinique forte ; (2) le suréchantillonnage, bien que souvent utilisé, n’améliore pas systématiquement les performances s’il est appliqué sur des données bruitées ; (3) la sélection de caractéristiques, si elle est bénéfique pour les modèles de ML, peut pénaliser les modèles de deep learning sur de petits jeux de données en réduisant encore le nombre d’échantillons disponibles. Leurs travaux mettent en lumière l’importance cruciale de la qualité et de la nature des données, ainsi que le compromis entre complexité du modèle et performance réelle.

4.4 Études comparatives utilisant SVM, Random Forest et XGBoost

Un corpus croissant de travaux propose des comparaisons directes entre les trois algorithmes ciblés dans ce mémoire, offrant une base empirique solide pour orienter le choix du modèle en contexte clinique.

4.4.1 Comparaisons sur la base PIDD

Iparraguirre-Villanueva et al. comparent cinq algorithmes — K-NN, Naïf de Bayes, arbres de décision, régression logistique et SVM — sur la PIDD avec application de SMOTE pour l’équilibrage des classes (Iparraguirre-Villanueva et al., 2023a). Leurs résultats montrent que K-NN et Bernoulli NB surpassent le SVM (71,7% d’exactitude) dans ce contexte. Cette relative contre-performance du SVM est attribuée à la petite taille du jeu de données et à la sensibilité de l’algorithme aux hyperparamètres dans des espaces de faible dimensionnalité.

Zou et al. proposent une comparaison systématique sur la PIDD incluant les forêts aléatoires, les arbres de décision et les réseaux de neurones, avec application de techniques de réduction de dimensionnalité (PCA et mRMR) (Zou et al., 2018). La Random Forest obtient la meilleure exactitude globale (80,84%), ce résultat étant robuste aux différentes configurations de sélection de variables testées. Les auteurs soulignent que le glucose est systématiquement identifié comme la variable de plus haute importance, tant par les critères d’entropie dans les arbres que par l’importance des variables dans la Random Forest.

4.4.2 Comparaisons multi-algorithmes incluant XGBoost

Wee et al. proposent une revue approfondie des méthodes de ML et de deep learning appliquées à la détection du diabète sur plusieurs bases de données publiques (Wee et al., 2024). Leur analyse met en évidence la supériorité systématique des méthodes ensemblistes (Random Forest, XGBoost) sur les méthodes à modèle unique (régression logistique, SVM) en termes d’exactitude, de F1-score et d’AUC-ROC. XGBoost se distingue notamment par ses mécanismes intégrés de régularisation et sa gestion native des valeurs manquantes, deux propriétés particulièrement avantageuses pour les données médicales réelles souvent incomplètes.

Khanam and Foo réalisent une comparaison de sept algorithmes de ML pour la prédiction du diabète, incluant SVM, Random Forest, régression logistique, K-NN, arbres de décision, réseaux de neurones et Naïf de Bayes (Khanam and Foo, 2021). Sur la PIDD, les résultats montrent que la régression logistique et le SVM obtiennent les meilleures performances en termes d’exactitude, tandis que la Random Forest excelle sur le rappel (*recall*), métrique particulièrement importante en contexte médical pour minimiser les faux négatifs (patients diabétiques non détectés).

4.4.3 Apport des techniques de prétraitement et d’optimisation

Plusieurs études soulignent que les performances comparatives dépendent fortement des stratégies de prétraitement adoptées. Gündoğdu montrent que la sélection de variables par Random Forest permet d’améliorer significativement les performances de XGBoost en réduisant le bruit introduit par les variables non informatives (Gündoğdu, 2023). Iparraguirre-Villanueva et al. démontrent que l’application de SMOTE améliore systématiquement les métriques de classification pour tous les algorithmes testés sur la PIDD, en réduisant le déséquilibre entre les classes positives (diabétiques, 35% du jeu de données) et négatives (Iparraguirre-Villanueva et al., 2023a).

Le Tableau 4.1 synthétise les principales études comparatives identifiées dans la littérature.

TABLE 4.1 – Synthèse des principales études comparatives de ML pour la détection du diabète

Étude	Dataset	Algorithmes	Meilleur résultat	Métrique
Zou et al. (2018)	PIDD + Luzhou	RF, DT, NN	RF : 80,84%	ACC
Iparraguirre et al. (2023a)	PIDD (SMOTE)	K-NN, NB, DT, LR, SVM	K-NN : 79,6%	ACC
Wee et al. (2024)	Multiple	RF, XGB, SVM, DL	XGBoost	AUC-ROC
Khanam & Foo (2021)	PIDD	7 algorithmes	LR/SVM	ACC / Recall
Gündoğdu (2023)	Sylhet, BD	RF + XGB	RF-XGB : 98,6%	AUC
Sisodia & Sisodia (2018)	PIDD	NB, DT, SVM	NB : 76,3%	ACC

4.5 Analyse critique des travaux existants

L’examen de la littérature permet d’identifier plusieurs constats et limites récurrents qui méritent une discussion approfondie.

4.5.1 Hétérogénéité des protocoles expérimentaux

La comparabilité des résultats entre études est sérieusement compromise par l’hétérogénéité des protocoles. Les différences portent sur la stratégie de partitionnement des données (hold-out simple vs. validation croisée k-fold), le traitement des valeurs manquantes et des zéros biologiquement impossibles dans la PIDD (certaines études les suppriment, d’autres les imputent), l’usage ou non de techniques de rééchantillonnage (SMOTE, ADASYN), ainsi que le choix des métriques d’évaluation. Ces disparités rendent les comparaisons directes entre études délicates et expliquent en partie la grande variabilité des performances rapportées pour un même algorithme (Wee et al., 2024).

4.5.2 Déséquilibre des classes et biais des métriques

La PIDD présente un déséquilibre significatif entre les classes : environ 35% de cas positifs contre 65% de cas négatifs. Cette asymétrie induit un biais dans l’interprétation de l’exactitude simple (*accuracy*), qui peut être artificiellement élevée même pour un classifieur majoritaire. Plusieurs études publiées antérieurement ne reportent que l’exactitude, occultant les performances sur la classe minoritaire (diabétiques) qui est pourtant la plus cliniquement pertinente (Khanam and Foo, 2021; Iparraguirre-Villanueva et al., 2023a). Une analyse rigoureuse doit systématiquement inclure le rappel (sensibilité), la précision, le F1-score et l’AUC-ROC pour chaque classe.

4.5.3 Généralisation limitée

La majorité des études comparatives se concentrent sur la PIDD, une base de données de 768 instances issues d’une population très spécifique (femmes Pima de plus de 21 ans). La généralisation de ces résultats à d’autres populations reste une question ouverte. Les caractéristiques démographiques, génétiques et métaboliques de la population Pima sont atypiques à l’échelle mondiale, ce qui limite l’extrapolation directe des modèles développés (Zou et al., 2018; Wee et al., 2024).

4.5.4 Explicabilité insuffisante

Peu d’études analysent l’importance des variables de manière rigoureuse ou n’explorent les mécanismes de décision des modèles au-delà des simples scores d’importance. L’émergence d’outils d’explicabilité comme SHAP (*SHapley Additive exPlanations*) offre des perspectives prometteuses pour rendre les modèles ensemblistes interprétables par les cliniciens, mais leur utilisation reste marginale dans la littérature sur la PIDD (Wee et al., 2024).

4.5.5 Optimisation du seuil de décision

La quasi-totalité des études utilise le seuil de classification par défaut de 0,5, sans l’optimiser en fonction du contexte clinique. En détection du diabète, un faux négatif (patient diabétique non détecté) est généralement plus coûteux qu’un faux positif, ce qui justifie l’utilisation de seuils inférieurs à 0,5 pour maximiser la sensibilité. Cette dimension de l’évaluation est systématiquement négligée dans les études existantes (Khanam and Foo, 2021).

4.6 Positionnement et apport du présent travail

À la lumière de cette revue de littérature, le présent travail se positionne dans le prolongement des études comparatives existantes tout en apportant plusieurs contributions spécifiques.

Premièrement, contrairement aux études qui comparent un grand nombre d’algorithmes superficiellement, ce mémoire se concentre sur trois algorithmes majeurs — SVM, Random Forest et XGBoost — avec une analyse approfondie de leurs mécanismes théoriques et de leur comportement face aux spécificités de la PIDD. Ce choix est motivé par la complémentarité des approches : les SVM représentent les méthodes à noyau, la Random Forest représente le bagging ensembliste, et XGBoost représente le boosting par gradient.

Deuxièmement, l’évaluation adoptée dans ce travail va au-delà de la simple exactitude pour inclure un ensemble complet de métriques adapté au contexte médical : précision, rappel, F1-score, AUC-ROC et matrice de confusion par classe. Une attention particulière est portée à la sensibilité (rappel de la classe positive), directement liée au taux de détection des patients diabétiques.

Troisièmement, ce mémoire intègre une analyse de l’importance des variables pour chaque modèle, permettant d’identifier les prédicteurs les plus déterminants dans la PIDD et de confronter les conclusions algorithmiques aux connaissances médicales établies.

Quatrièmement, la gestion du déséquilibre des classes est traitée de manière explicite, en comparant différentes stratégies : pondération des classes, techniques de rééchantillonnage, et paramètres natifs (comme `scale_pos_weight` dans XGBoost) pour évaluer leur impact sur les performances finales.

En somme, ce travail vise à produire une évaluation comparative rigoureuse, reproductible et cliniquement orientée, dont les conclusions peuvent guider des praticiens ou des équipes de recherche souhaitant déployer un modèle de détection du diabète sur la PIDD ou des jeux de données cliniques similaires.

Partie II

ÉTUDE EXPÉRIMENTALE ET APPLICATION AU CAS DE LA DETECTION DU DIABETE

Chapitre 5

Conception méthodologique et évaluation expérimentale des modèles de détection du diabète

5.1 Introduction

Ce chapitre présente la mise en œuvre expérimentale des trois algorithmes étudiés dans la partie théorique — Machine à Vecteurs de Support (SVM), Random Forest et XGBoost — dans le cadre de la détection du diabète. L'ensemble du pipeline, de l'acquisition des données jusqu'à l'évaluation des modèles, a été implémenté en Python avec les bibliothèques `scikit-learn`, `XGBoost`, `imbalanced-learn` et `Optuna`.

L'objectif de ce chapitre est triple : (1) décrire précisément le jeu de données utilisé et ses caractéristiques statistiques, (2) détailler le pipeline de prétraitement et d'ingénierie des caractéristiques qui constitue une contribution centrale de ce travail, et (3) présenter les résultats quantitatifs obtenus pour chacun des modèles individuels et des méthodes ensemblistes.

5.2 Présentation du jeu de données

5.2.1 Description générale

Le jeu de données utilisé est la *Pima Indians Diabetes Database* (PIDD), l'un des benchmarks les plus référencés dans la littérature d'apprentissage automatique appliqué à la médecine. Originellement collecté par le National Institute of Diabetes and Digestive and Kidney Diseases des États-Unis, il est librement accessible via le dépôt de Jason Brownlee (Sisodia and Sisodia, 2018).

Il contient **768 instances** correspondant à des femmes d'ascendance amérindienne Pima, âgées d'au moins 21 ans, avec un historique de diabète de type 2 particulièrement prévalent dans cette population. Chaque instance est décrite par **8 attributs cliniques** et une variable cible binaire.

5.2.2 Description des attributs

5.2.3 Distribution des classes

La variable cible présente un déséquilibre modéré : **500 instances** appartiennent à la classe 0 (non diabétique, 65,1%) et **268 instances** à la classe 1 (diabétique, 34,9%). Ce déséquilibre est représentatif de la répartition épidémiologique du diabète dans des populations à risque et constitue l'un des défis méthodologiques centraux de ce travail. Il

TABLE 5.1 – Description des attributs de la base de données PIDD

Attribut	Description
Pregnancies	Nombre de grossesses
Glucose	Concentration plasmatique en glucose (test oral de tolérance au glucose, mg/dL)
BloodPressure	Pression artérielle diastolique (mm Hg)
SkinThickness	Épaisseur du pli cutané tricipital (mm)
Insulin	Taux d'insuline sérique à 2h (μ U/ml)
BMI	Indice de masse corporelle (kg/m^2)
DiabetesPedigreeFunction	Score de prédisposition héréditaire au diabète
Age	Âge en années
Outcome	Variable cible : 0 (non diabétique), 1 (diabétique)

justifie l'adoption de techniques de rééchantillonnage et l'utilisation de métriques au-delà de la simple exactitude (*accuracy*).

5.3 Pipeline de prétraitement avancé

Le prétraitement des données représente une étape critique dans tout projet d'apprentissage automatique, en particulier sur des données médicales qui présentent souvent des valeurs aberrantes et des données manquantes. Le pipeline développé dans ce travail est articulé en quatre phases successives.

5.3.1 Détection et imputation des valeurs impossibles

L'examen du jeu de données révèle la présence de valeurs nulles dans cinq attributs pour lesquels une valeur de 0 est biologiquement impossible : **Glucose**, **BloodPressure**, **SkinThickness**, **Insulin** et **BMI**. Ces zéros encodent en réalité des données manquantes dans la collecte originale.

Une imputation naïve par la médiane globale ignorerait l'effet confondant de la variable cible sur la distribution de ces variables. Nous avons donc adopté une **imputation par médiane conditionnelle à la classe** : pour chaque attribut et chaque classe, les zéros sont remplacés par la médiane calculée uniquement sur les individus non-nuls de la même classe. Le tableau 5.2 détaille le volume d'imputation réalisé.

TABLE 5.2 – Volume d'imputation des valeurs nulles par attribut

Attribut	Valeurs imputées
Insulin	374
SkinThickness	227
BloodPressure	35
BMI	11
Glucose	5

5.3.2 Traitement des valeurs aberrantes (Outlier Winsorization)

Après l'imputation, les données restent susceptibles de contenir des valeurs extrêmes pouvant influencer négativement les estimateurs statistiques internes aux algorithmes. Nous avons appliqué une **winsorisation au 1^{er} et 99^{ème} percentile** : toute valeur inférieure au 1^{er} percentile est remplacée par ce percentile, et toute valeur supérieure au 99^{ème} percentile est ramenée à ce seuil. Cette technique préserve la distribution tout en limitant l'influence des outliers les plus extrêmes. Le nombre de valeurs traitées par attribut est présenté dans le tableau 5.3.

5.3.3 Ingénierie des caractéristiques

À partir des 8 attributs originaux, nous avons construit 8 nouvelles caractéristiques qui encodent des connaissances médicales ou des interactions pertinentes entre variables. Ces nouvelles caractéristiques portent l'espace de représentation à **16 attributs** au total.

La construction du **score de risque** (**Risk_Score**) illustre l'intégration de connaissances médicales dans l'ingénierie des caractéristiques : il pondère la contribution normalisée du glucose (poids 0,35), du BMI (0,25), de l'âge (0,20) et de la fonction pedigree (0,20) selon leur importance clinique établie dans la littérature (Zou et al., 2018).

TABLE 5.3 – Valeurs cappées par la winsorisation (p1/p99)

Attribut	Valeurs cappées
Insulin	16
DiabetesPedigreeFunction	16
Glucose	14
SkinThickness	12
BloodPressure	12
BMI	15
Age	6
Pregnancies	4

TABLE 5.4 – Nouvelles caractéristiques construites et leur corrélation avec la variable cible

Caractéristique	Signification	Corrélation (r)
Risk_Score	Score de risque agrégé pondéré (Glucose, BMI, Âge, DPF)	+0.535
Glucose_BMI	Interaction Glucose $\times$ BMI	+0.526
Glucose_High	Indicateur binaire : Glucose $\geq$ 140 mg/dL	+0.421
N_Risk_Factors	Nombre de facteurs de risque actifs	+0.427
BMI_Obese	Indicateur binaire : BMI $\geq$ 30	+0.297
BMI_Age	Interaction BMI $\times$ Âge	+0.365
Insulin_Glucose_Ratio	Ratio Insuline/Glucose (résistance à l'insuline)	+0.262
Preg_Age_Ratio	Ratio Grossesses/Âge	+0.164

5.3.4 Partitionnement, normalisation et sur-échantillonnage

Le jeu de données est partitionné en un ensemble d’entraînement (80%, soit 614 instances) et un ensemble de test (20%, soit 154 instances), avec stratification afin de préserver la distribution des classes dans chaque partition.

La normalisation est réalisée par un **PowerTransformer de Yeo-Johnson**, qui s’avère plus adapté que le StandardScaler classique pour des distributions asymétriques telles que celles observées sur **Insulin** et **SkinThickness**. La transformation est ajustée exclusivement sur le train set, puis appliquée au test set, garantissant l’absence de fuite d’information (*data leakage*).

Afin de pallier le déséquilibre des classes (214 positifs contre 400 négatifs dans le train set), nous avons appliqué un **Borderline-SMOTE** (variante de SMOTE ciblant les instances à la frontière de décision) qui équilibre les deux classes à 400 instances chacune. Cette technique est reconnue comme supérieure au SMOTE classique pour éviter la sur-génération d’échantillons synthétiques dans les régions denses, réduisant ainsi le risque de sur-apprentissage (Wee et al., 2024).

5.4 Sélection des caractéristiques

L’importance des caractéristiques a été évaluée par **information mutuelle** (*Mutual Information*), une mesure non paramétrique de la dépendance statistique entre chaque caractéristique et la variable cible. Les scores obtenus, présentés dans le tableau 5.5, révèlent que l’**Insulin** (après imputation) et le **Risk_Score** (caractéristique construite) dominant largement l’espace de représentation.

TABLE 5.5 – Scores d’information mutuelle des 16 caractéristiques

Caractéristique	Score MI
Insulin	0.3262
Risk_Score	0.2137
Glucose_BMI	0.1656
SkinThickness	0.1352
N_Risk_Factors	0.1232
Glucose	0.1232
BMI_Age	0.1090
Insulin_Glucose_Ratio	0.0986
Glucose_High	0.0974
BMI	0.0971
Preg_Age_Ratio	0.0859
Age	0.0735
Pregnancies	0.0591
BloodPressure	0.0556
BMI_Obese	0.0504
DiabetesPedigreeFunction	0.0176

Il est notable que la caractéristique **DiabetesPedigreeFunction**, bien que cliniquement significative d’après la littérature, présente le score d’information mutuelle le plus faible de l’espace. Cette observation peut s’expliquer par sa nature synthétique (score composite) et sa distribution très asymétrique. À l’inverse, la caractéristique **Insulin** — dont

374 valeurs avaient été imputées — ressort comme la plus informative après imputation, confirmant l'importance de l'étape de gestion des données manquantes.

5.5 Configuration expérimentale et optimisation des hyperparamètres

5.5.1 Protocole d'évaluation

L'évaluation des modèles repose sur un protocole rigoureux combinant :

- **Test set holdout** : évaluation finale sur un ensemble de test non vu pendant l'entraînement ni l'optimisation des hyperparamètres.
- **Validation croisée stratifiée répétée** : 10 folds $\times$ 3 répétitions (`RepeatedStratifiedKFold`) pour estimer l'AUC-ROC en cross-validation (`CV_AUC`), offrant une estimation robuste de la généralisation.
- **Optimisation du seuil de décision** : pour chaque modèle, le seuil de classification est optimisé sur les données d'entraînement par maximisation du F1-score sur la courbe Précision-Rappel, via validation croisée. Cette étape est particulièrement critique en contexte médical où un seuil de 0,5 est rarement optimal face à un déséquilibre de classes.

Les métriques reportées sont : Exactitude (*Accuracy*), Précision (*Precision*), Rappel (*Recall*), F1-Score et AUC-ROC.

5.5.2 Optimisation des hyperparamètres avec Optuna

Pour chacun des trois modèles de base, les hyperparamètres ont été optimisés avec le framework **Optuna** (algorithme TPE — *Tree-structured Parzen Estimator*), qui combine recherche bayésienne et échantillonnage intelligent de l'espace des paramètres. Cette approche est considérablement plus efficace que la recherche en grille exhaustive, en particulier pour les espaces continus et multi-dimensionnels (Wee et al., 2024).

SVM (RBF) : 100 essais Optuna sur l'espace $C \in [0.1, 200]$ (log-uniforme) et $\gamma \in [0.0001, 2]$ (log-uniforme). Les meilleurs paramètres identifiés sont $C = 2.70$ et $\gamma = 0.585$.

Random Forest : 150 essais Optuna sur le nombre d'estimateurs $[200, 1000]$, la profondeur maximale $[4, 20]$, et les paramètres de régularisation (`min_samples_split`, `min_samples_leaf`, `max_features`).

XGBoost : 200 essais Optuna, l'exploration la plus intensive, portant sur le nombre d'estimateurs $[100, 800]$, la profondeur $[2, 10]$, le taux d'apprentissage $[0.005, 0.3]$, le sous-échantillonnage, la régularisation L1/L2 (`alpha`, `lambda`) et `scale_pos_weight`.

5.6 Résultats des modèles individuels

5.6.1 SVM à noyau RBF

Le SVM avec noyau RBF (*Radial Basis Function*), entraîné sur les données transformées par PowerTransformer et augmentées par Borderline-SMOTE, obtient les perfor-

mances suivantes :

TABLE 5.6 – Résultats du SVM (RBF) sur l’ensemble de test

Métrique	Valeur
Exactitude	0.8052
F1-Score	0.7000
AUC-ROC	0.8589
CV AUC (10-fold $\times$ 3)	0.8714 ± 0.0442
Seuil optimal	0.339

L’AUC-ROC de 0.859 indique un bon pouvoir discriminant, mais le F1-Score de 0.700 révèle des difficultés à détecter les cas positifs (diabétiques) avec un rappel satisfaisant. Le seuil optimal de 0.339, notablement inférieur au seuil conventionnel de 0.5, illustre l’importance de l’optimisation du seuil en présence d’un déséquilibre de classes.

5.6.2 Random Forest

La Random Forest, entraînée sur les données Borderline-SMOTE avec des hyperparamètres optimisés par Optuna sur 150 essais, atteint des performances très supérieures au SVM :

TABLE 5.7 – Résultats du Random Forest sur l’ensemble de test

Métrique	Valeur
Exactitude	0.8896
F1-Score	0.8440
AUC-ROC	0.9453
CV AUC (10-fold $\times$ 3)	0.9378 ± 0.0242
Seuil optimal	0.549

Avec une AUC-ROC de 0.945 et un F1-Score de 0.844, la Random Forest démontre d’excellentes capacités de généralisation. L’écart-type de la CV-AUC (± 0.024) indique une robustesse élevée aux variations de partitionnement, confirmant la stabilité de ce modèle ensembliste.

5.6.3 XGBoost

XGBoost, optimisé sur 200 essais Optuna — la configuration la plus intensive des trois — atteint les meilleures performances individuelles :

TABLE 5.8 – Résultats XGBoost sur l’ensemble de test

Métrique	Valeur
Exactitude	0.8896
F1-Score	0.8440
AUC-ROC	0.9496
CV AUC (10-fold $\times$ 3)	0.9442 ± 0.0235
Seuil optimal	0.639

Le rapport de classification détaillé pour XGBoost (meilleur modèle) est présenté dans le tableau 5.9.

TABLE 5.9 – Rapport de classification détaillé — XGBoost (meilleur modèle)

Classe	Précision	Rappel	F1-Score	Support
Non Diabétique	0.9192	0.9100	0.9146	100
Diabétique	0.8364	0.8519	0.8440	54
Macro avg	0.8778	0.8809	0.8793	154
Weighted avg	0.8901	0.8896	0.8898	154

La classe minoritaire (Diabétique) atteint un rappel de 0.852, ce qui signifie que 85,2% des patients diabétiques de l'ensemble de test sont correctement identifiés. Ce niveau de sensibilité est cliniquement très satisfaisant, car les faux négatifs (patients diabétiques non détectés) ont des conséquences graves en termes de non-prise en charge médicale.

5.7 Résultats des méthodes ensemblistes avancées

Afin d'explorer si une combinaison synergique des trois modèles pouvait dépasser leurs performances individuelles, deux architectures ensemblistes ont été construites : le *Voting Ensemble* et le *Stacking*.

5.7.1 Soft Voting Ensemble

Le Soft Voting combine les probabilités prédites par les trois modèles de base (SVM, Random Forest, XGBoost) par moyenne pondérée. Il obtient une AUC-ROC de 0.932 et un F1-Score de 0.845, légèrement inférieurs à XGBoost seul en termes d'AUC mais avec un meilleur rappel grâce au consensus entre modèles.

5.7.2 Stacking

Deux architectures de Stacking ont été évaluées :

- **Stacking (Méta-Régression Logistique)** : les prédictions de probabilités des trois estimateurs de base sont passées à une régression logistique comme méta-apprenant. AUC = 0.929, CV_AUC = 0.941 ± 0.025 .
- **Stacking v2 (Méta-XGBoost + passthrough)** : une variante plus complexe où le méta-apprenant est XGBoost et a accès simultanément aux features originales (`passthrough=True`) et aux sorties des estimateurs de base. AUC = 0.939, CV_AUC = 0.943 ± 0.028 .

5.7.3 Tableau comparatif global

Le tableau 5.10 synthétise les performances de l'ensemble des modèles évalués, triés par AUC-ROC décroissant.

TABLE 5.10 – Tableau comparatif final de tous les modèles

Modèle	Accuracy	Précision	Rappel	F1	AUC-ROC
XGBoost	0.8896	0.8364	0.8519	0.8440	0.9496
Random Forest	0.8896	0.8364	0.8519	0.8440	0.9453
Stacking v2	0.8766	0.8571	0.7778	0.8155	0.9387
Stacking (LR)	0.8831	0.8000	0.8889	0.8421	0.9289
Voting Ensemble	0.8831	0.7903	0.9074	0.8448	0.9320
SVM (RBF)	0.8052	0.7609	0.6481	0.7000	0.8589

Conclusion

Ce chapitre a présenté le pipeline expérimental complet, articulé autour de quatre choix méthodologiques clés : l'imputation conditionnelle par classe, l'ingénierie de caractéristiques enrichissant l'espace de représentation, l'utilisation du Borderline-SMOTE pour traiter le déséquilibre de classes, et l'optimisation bayésienne des hyperparamètres par Optuna. Les résultats démontrent que XGBoost et Random Forest atteignent des performances très proches ($AUC > 0.945$) et largement supérieures au SVM ($AUC = 0.859$). Le chapitre suivant analyse ces résultats de manière comparative et discute de leurs implications cliniques et méthodologiques.

Chapitre 6

Analyse des résultats, discussion et perspectives

6.1 Introduction

Ce chapitre approfondit l'interprétation des résultats obtenus dans le chapitre précédent. Après une analyse comparative quantitative des modèles, nous discutons de leurs comportements respectifs à la lumière des fondements théoriques développés dans la partie I, avant d'examiner les implications cliniques de nos résultats et d'identifier les limites et perspectives de ce travail.

6.2 Analyse comparative des modèles

6.2.1 Hiérarchie des performances et écarts significatifs

Le tableau comparatif final révèle une hiérarchie claire entre les trois familles d'algorithmes étudiés, que l'on peut structurer en trois niveaux de performance.

Niveau 1 — Modèles ensemblistes à gradient boosting et bagging (AUC ≥ 0.945) : XGBoost (AUC = 0.9496) et Random Forest (AUC = 0.9453) occupent les premières positions avec des performances quasiment identiques. Cet écart de seulement 0.0043 en AUC n'est pas statistiquement significatif et confirme que les deux approches ensemblistes atteignent un plateau de performance sur ce jeu de données.

Niveau 2 — Architectures d'empilement (AUC $\in [0.929, 0.939]$) : Les deux variantes de Stacking ainsi que le Voting Ensemble se positionnent entre les deux niveaux précédents. Paradoxalement, ces architectures plus complexes — combinant les trois modèles de base — n'améliorent pas les performances de XGBoost ou Random Forest pris isolément. Ce résultat, contre-intuitif à première vue, s'explique par la forte corrélation entre les prédictions des deux meilleurs modèles (XGBoost et Random Forest), qui réduisent le gain de diversité attendu d'un ensemble hétérogène.

Niveau 3 — SVM à noyau RBF (AUC = 0.859) : Le SVM présente un écart significatif de 0.086 à 0.091 en AUC par rapport aux modèles ensemblistes. Son F1-Score de 0.700 — soit 0.144 points de moins que Random Forest et XGBoost — traduit des difficultés spécifiques à détecter les cas positifs avec un rappel satisfaisant (0.648 contre 0.852 pour XGBoost).

6.2.2 Analyse du compromis Précision-Rappel en contexte clinique

En détection médicale, le compromis Précision-Rappel revêt une importance particulière. Un **faux négatif** (patient diabétique non détecté) entraîne l'absence de prise en

charge et expose le patient à des complications graves ; un **faux positif** (non-diabétique classé diabétique) génère une anxiété injustifiée et des examens complémentaires inutiles. Dans ce contexte, la maximisation du rappel (*sensibilité*) est généralement prioritaire, sous contrainte d'une précision acceptable.

Le tableau 6.1 compare le rappel sur la classe positive entre les modèles.

TABLE 6.1 – Comparaison du rappel sur la classe diabétique (classe positive)

Modèle	Rappel (Diabétique)	Faux Négatifs (sur 54)
Voting Ensemble	0.9074	5
XGBoost	0.8519	8
Random Forest	0.8519	8
Stacking (LR)	0.8889	6
Stacking v2	0.7778	12
SVM (RBF)	0.6481	19

D'un point de vue clinique, le **Voting Ensemble** présente le meilleur rappel (0.907), ne manquant que 5 patients diabétiques sur 54 dans le test set. Cependant, son AUC-ROC de 0.932 reste inférieur à celui de XGBoost, ce qui signifie que son avantage en rappel résulte principalement d'un seuil de décision plus bas (0.403 contre 0.639 pour XGBoost), avec une précision légèrement sacrifiée (0.790 contre 0.836).

6.2.3 Rôle de l'optimisation du seuil de décision

Un résultat méthodologique important de ce travail est la démonstration de l'apport de l'optimisation du seuil de décision. Pour le SVM, le seuil optimal identifié est de 0.339 — soit un écart de 0.161 par rapport au seuil conventionnel de 0.5. Cette optimisation a permis d'améliorer le F1-Score du SVM par rapport à ce qui aurait été obtenu avec un seuil fixe à 0.5.

Cette observation confirme la critique formulée dans l'état de l'art (chapitre 4) : la quasi-totalité des études publiées comparent les modèles à seuil fixe de 0.5, biaisant les comparaisons en défaveur des modèles dont la distribution des probabilités prédites est asymétrique.

6.3 Interprétation des résultats à la lumière des fondements théoriques

6.3.1 Pourquoi les méthodes ensemblistes surpassent le SVM sur ce jeu de données ?

La supériorité de Random Forest et XGBoost sur le SVM s'explique par plusieurs facteurs convergents, cohérents avec leurs fondements théoriques respectifs.

Sensibilité aux interactions entre variables : le SVM linéaire ou à noyau RBF construit une frontière de décision globale dans un espace transformé, sans modéliser explicitement les interactions entre variables. Or, l'ingénierie des caractéristiques (section 5.3.3) a montré que des interactions telles que `Glucose_BMI` ($r = +0.526$) ou `BMI_Age`

($r = +0.365$) sont fortement corrélées avec la variable cible. Les arbres de décision, en partitionnant l'espace récursivement, capturent naturellement ces interactions sans qu'elles soient explicitement construites.

Robustesse au déséquilibre de classes : XGBoost intègre nativement le paramètre `scale_pos_weight` qui module le poids des classes positives dans la fonction de perte, tandis que le SVM nécessite une gestion explicite via `class_weight` ou devient sensible au seuil. Cette propriété native de XGBoost est particulièrement avantageuse sur la PIDD.

Régularisation intégrée : XGBoost régularise la complexité des arbres via des termes L1 et L2 dans la fonction objectif, réduisant structurellement le sur-apprentissage. La Random Forest réalise une régularisation implicite par l'introduction de variance via l'échantillonnage bootstrap et la sélection aléatoire des caractéristiques à chaque nœud de partitionnement.

Limitation du SVM sur les petits jeux de données non linéaires : la performance du SVM est intrinsèquement liée au choix du noyau et aux hyperparamètres C et γ . Bien que l'optimisation par Optuna (100 essais) ait identifié les valeurs $C = 2.70$ et $\gamma = 0.585$, la surface de décision non linéaire apprise reste moins flexible que celle d'un ensemble de centaines d'arbres profonds.

6.3.2 Analyse de l'importance des variables

L'analyse de l'importance des caractéristiques par les modèles ensemblistes confirme les résultats de la sélection par information mutuelle et s'aligne avec les connaissances médicales établies.

Pour **Random Forest** et **XGBoost**, les variables `Glucose`, `Risk_Score`, `Glucose_BMI` et `BMI` apparaissent systématiquement comme les plus importantes, ce qui est cohérent avec la position de la glycémie comme marqueur diagnostique primaire du diabète (Zou et al., 2018).

L'**Insulin**, bien que première en information mutuelle (0.326), se retrouve à une importance réduite dans les modèles arborescents, phénomène partiellement attribuable aux 374 valeurs imputées qui peuvent introduire une variance artificielle dans sa distribution.

La `DiabetesPedigreeFunction`, dont l'importance en information mutuelle est la plus faible (0.018), est néanmoins identifiée comme contributeur non négligeable par les modèles arborescents, qui détectent sa contribution conditionnelle en interaction avec l'âge et le nombre de grossesses.

6.3.3 Gain apporté par le pipeline d'optimisation

Pour quantifier l'apport du pipeline développé, nous le comparons aux résultats d'un pipeline basique (StandardScaler + pas de feature engineering + seuil 0.5) simulé par les performances historiques reportées dans le notebook :

TABLE 6.2 – Comparaison pipeline basique vs pipeline optimisé (XGBoost)

Métrique	Pipeline basique	Pipeline optimisé	Gain
Accuracy	0.7532	0.8896	+0.1364
F1-Score	0.6346	0.8440	+0.2094
AUC-ROC	0.8261	0.9496	+0.1235

Le gain en F1-Score (+0.209) est particulièrement remarquable : il traduit une amélioration simultanée de la précision et du rappel sur la classe diabétique. Ce gain est attribuable à la conjugaison de plusieurs innovations : l'imputation conditionnelle par classe, l'ingénierie de 8 nouvelles caractéristiques, le Borderline-SMOTE, le PowerTransformer et l'optimisation intensive des hyperparamètres.

6.4 Discussion critique

6.4.1 Validité externe des résultats

Les performances obtenues, bien que très satisfaisantes sur l'ensemble de test de la PIDD, doivent être interprétées avec prudence quant à leur généralisation. La PIDD est constituée exclusivement de femmes Pima de plus de 21 ans, une population à prévalence diabétique atypiquement élevée. Les modèles entraînés sur ce jeu de données peuvent capturer des caractéristiques distribu-tionnelles propres à cette population qui ne se reproduisent pas sur d'autres cohortes.

Par ailleurs, l'ensemble de test, constitué de seulement 154 instances (dont 54 positives), limite la puissance statistique des conclusions. Des intervalles de confiance bootstrap sur les métriques auraient permis de quantifier l'incertitude des estimations.

6.4.2 Biais d'imputation

L'imputation de 374 valeurs d'`Insulin` (soit 48,7% des instances) représente une intervention massive sur les données. Bien que l'imputation par médiane conditionnelle soit plus rigoureuse qu'une imputation globale, elle introduit une dépendance artificielle entre `Outcome` et `Insulin` : les valeurs imputées sont calculées à partir de la médiane de leur propre classe, ce qui pourrait surestimer la contribution de cette variable. Une analyse de sensibilité — comparant les résultats avec et sans l'`Insulin` imputée — aurait permis de quantifier ce biais.

6.4.3 Absence d'interprétabilité locale

Les modèles Random Forest et XGBoost, malgré leurs excellentes performances, restent des boîtes noires du point de vue d'un clinicien. L'importance des variables (globale) ne suffit pas à expliquer une prédiction individuelle. L'intégration d'outils d'interprétabilité locale tels que **SHAP** (*SHapley Additive exPlanations*) permettrait de fournir, pour chaque patient, la contribution de chaque variable à la décision de classification. Cette dimension d'explicabilité est identifiée dans la littérature comme un prérequis à l'adoption clinique des modèles de ML (Wee et al., 2024).

6.4.4 Reproductibilité

L'ensemble du pipeline est reproductible grâce à la fixation d'une graine aléatoire (`RANDOM_STATE = 42`) et à l'utilisation de bibliothèques open-source. Le code source est disponible dans le notebook `diabetes_ultra_optimized_v2.ipynb`, permettant une vérification et une extension directes par des travaux futurs.

6.5 Positionnement par rapport à l'état de l'art

Le tableau 6.3 positionne nos résultats par rapport aux travaux identifiés dans le chapitre 4.

TABLE 6.3 – Positionnement des résultats obtenus face à l'état de l'art sur la PIDD

Étude	Meilleur al- gorithme	Accuracy	AUC-ROC
Zou et al. (Zou et al., 2018)	Random Forest	0.8084	n.d.
Iparraguirre et al. (Iparraguirre-Villanueva et al., 2023a)	K-NN (SMOTE)	0.7960	n.d.
Khanam & Foo (Khanam and Foo, 2021)	LR / SVM	0.7900	n.d.
Sisodia & Sisodia (Sisodia and Sisodia, 2018)	Naïve Bayes	0.7630	n.d.
Notre travail	XGBoost (Optuna)	0.8896	0.9496

Nos résultats surpassent les meilleures performances publiées sur la PIDD, notamment Zou et al. (0.8084 vs 0.8896 en accuracy). Cet écart s'explique principalement par la combinaison de l'ingénierie de caractéristiques avancée, du Borderline-SMOTE et de l'optimisation bayésienne des hyperparamètres — des techniques peu ou pas combinées dans les travaux antérieurs sur ce jeu de données.

6.6 Perspectives

Ce travail ouvre plusieurs directions de recherche et d'amélioration.

Validation externe : La première priorité serait de valider les modèles appris sur d'autres cohortes diabétiques (par exemple, le Sylhet Diabetes Hospital Dataset ou des données cliniques européennes) pour évaluer leur généralisation au-delà de la population Pima.

Intégration de l'explicabilité SHAP : L'implémentation de SHAP permettrait de produire des explications individuelles (contribution de chaque variable par patient), rendant le système exploitable en aide à la décision clinique.

Apprentissage en ligne : Les modèles actuellement développés supposent un jeu de données statique. Un déploiement en environnement hospitalier nécessiterait des capacités d'apprentissage incrémental permettant de mettre à jour le modèle au fur et à mesure de l'arrivée de nouvelles données.

Approches de deep learning : Pour des jeux de données plus volumineux, l'exploration de réseaux de neurones profonds (Transformers tabulaires, TabNet) pourrait apporter des gains supplémentaires. Dans le notebook, un MLP a d'ailleurs été intégré comme composant de l'ensemble, illustrant le potentiel de ces approches hybrides.

Détection non invasive : L'un des enjeux majeurs identifiés dans l'état de l'art est le développement de modèles basés sur des mesures non invasives (anthropométriques, comportementales) pour un dépistage de masse accessible. S'inscrire dans cette direction serait un prolongement à fort impact clinique et sociétal.

Conclusion

Ce chapitre a fourni une analyse approfondie des résultats obtenus, révélant la supériorité des méthodes ensemblistes (XGBoost, Random Forest) sur le SVM dans ce contexte, et démontrant le gain substantiel apporté par le pipeline d'optimisation avancé. Les résultats ont été confrontés à la littérature existante, positionnant ce travail comme une contribution compétitive dans le domaine de la détection automatique du diabète sur la PIDD. Les limites identifiées — validité externe, biais d'imputation, et manque d'explicabilité — délimitent des axes de recherche futurs qui permettraient de consolider ces résultats et d'envisager un déploiement clinique réel.

CONCLUSION GÉNÉRALE

Ce mémoire avait pour ambition d'évaluer, de manière rigoureuse et cliniquement orientée, trois algorithmes fondamentaux de l'apprentissage automatique supervisé — les Machines à Vecteurs de Support (SVM), les Forêts Aléatoires (Random Forest) et le Gradient Boosting par Extrême Régularisation (XGBoost) — dans le contexte précis de la détection précoce du diabète de type 2 sur la base de données Pima Indians Diabetes Database.

Synthèse des contributions

La **Partie I** a fourni les fondements théoriques nécessaires à une compréhension profonde des algorithmes employés. Pour les SVM, nous avons développé le formalisme mathématique de l'hyperplan à marge maximale, du problème dual de Lagrange, du *kernel trick* et des marges souples, permettant de comprendre pourquoi cet algorithme excelle dans les espaces de grande dimension mais peut montrer des limites sur des données tabulaires de taille modeste. Pour les Forêts Aléatoires, nous avons analysé le mécanisme de construction des arbres CART, l'importance du tirage bootstrap et de la sélection aléatoire des caractéristiques comme sources de décorrélation des estimateurs. Pour XGBoost, nous avons expliqué comment l'approximation du second ordre de la fonction objectif, combinée à la régularisation structurelle des arbres, permet un apprentissage extrêmement efficace et régularisé.

L'état de l'art (chapitre 4) a mis en lumière l'hétérogénéité des protocoles publiés, le biais induit par une évaluation limitée à la seule exactitude, et les lacunes récurrentes en matière d'explicabilité et de généralisation externe.

La **Partie II** a présenté un pipeline expérimental complet et performant, dont les principales contributions sont :

1. **Un prétraitement avancé** combinant imputation par médiane conditionnelle à la classe, winsorisation aux percentiles extrêmes et transformation de Yeo-Johnson, traitement des spécificités des données médicales de manière chirurgicale.
2. **Une ingénierie de caractéristiques médicalement informée** : 8 nouvelles variables ont été construites à partir des 8 attributs originaux, dont le **Risk_Score** ($r = +0.535$ avec **Outcome**) et l'interaction **Glucose_BMI** ($r = +0.526$), portant à 16 le nombre final de caractéristiques.
3. **Un traitement rigoureux du déséquilibre des classes** par Borderline-SMOTE, équilibrant les classes à 400 instances chacune dans le jeu d'entraînement, combiné à l'optimisation des seuils de décision individuellement pour chaque modèle.
4. **Une optimisation bayésienne intensive** des hyperparamètres par Optuna (jusqu'à 200 essais pour XGBoost), conduisant à des configurations optimales sans exploration exhaustive de l'espace des paramètres.

Bilan des résultats

Les résultats obtenus démontrent la supériorité des méthodes ensemblistes sur le SVM dans ce contexte applicatif. **XGBoost** et **Random Forest** atteignent tous deux une exactitude de 89,0% et un F1-Score de 0.844, avec des AUC-ROC de **0.9496** et **0.9453** respectivement — des performances qui surpassent les meilleures valeurs publiées dans

la littérature comparative sur la PIDD. Le gain par rapport à une configuration basique est substantiel : +13,6 points d'exactitude, +20,9 points de F1-Score et +12,4 points d'AUC-ROC.

Le SVM, malgré une optimisation soignée, reste limité à une AUC-ROC de 0.859 et un F1-Score de 0.700, illustrant ses difficultés structurelles face à des données tabulaires présentant de fortes interactions entre variables et un déséquilibre modéré des classes.

Les architectures ensemblistes avancées (Voting, Stacking) n'ont pas amélioré les performances des meilleurs modèles individuels en raison de la forte corrélation entre prédicteurs.

Limites et perspectives

Ce travail comporte plusieurs limites qui motivent des directions de recherche futures. La validité externe des modèles reste à démontrer sur des populations autres que les femmes Pima. L'imputation massive de l'attribut **Insulin** (374 valeurs sur 768) introduit un biais potentiel. L'absence d'explicabilité locale (par exemple via SHAP) limite l'utilité clinique immédiate des modèles appris.

Les perspectives les plus prometteuses sont l'intégration d'outils d'explicabilité SHAP pour un déploiement en aide à la décision clinique, la validation sur des cohortes indépendantes, l'exploration d'architectures de deep learning tabulaire (TabNet, Transformers), et à plus long terme, le développement de systèmes de détection non invasifs basés sur des données anthropométriques et comportementales.

Mot final

Ce travail illustre comment une combinaison réfléchie de techniques de prétraitement, d'ingénierie des données et d'optimisation algorithmique peut transformer des performances ordinaires en résultats compétitifs sur un jeu de données de référence. Au-delà des chiffres, il souligne que la qualité des données et la rigueur méthodologique sont des déterminants aussi importants que le choix de l'algorithme lui-même — une leçon fondamentale pour tout praticien de l'apprentissage automatique appliqué aux sciences de la vie.

BIBLIOGRAPHIE

- Bertsekas, D. (2009). *Convex optimization theory*, volume 1. Athena Scientific.
- Boser, B. E., Guyon, I. M., and Vapnik, V. N. (1992). A training algorithm for optimal margin classifiers. In *Proceedings of the fifth annual workshop on Computational learning theory*, pages 144–152.
- Chen, T. and Guestrin, C. (2016). Xgboost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Devroye, L., Györfi, L., and Lugosi, G. (1996). Vapnik-chervonenkis theory. In *A probabilistic theory of pattern recognition*, pages 187–213. Springer.
- Gowthami, S., Venkata Siva Reddy, R., and Riyaz Ahmed, M. (2024). Exploring the effectiveness of machine learning algorithms for early detection of type-2 diabetes mellitus. *Measurement : Sensors*, 31 :100983.
- Gündoğdu, S. (2023). Efficient prediction of early-stage diabetes using XGBoost classifier with random forest feature selection technique. *Multimedia Tools and Applications*, 82 :34163–34181. PMC Open Access Subset.
- Iparraguirre-Villanueva, O., Espinola-Linares, K., Flores Castañeda, R. O., and Cabanillas-Carbonell, M. (2023a). Application of machine learning models for early detection and accurate classification of Type 2 Diabetes. *Diagnostics*, 13(14) :2383. Open Access — CC BY.
- Iparraguirre-Villanueva, O., Espinola-Linares, K., Flores Castañeda, R., and Cabanillas-Carbonell, M. (2023b). Application of machine learning models for early detection and accurate classification of type 2 diabetes. *Diagnostics*, 13(14) :2383.
- Juwono, F., Wong, W., Verma, S., and Shee, N. (2024). Machine learning and deep learning for diabetes detection : A comprehensive review of techniques, datasets, and preprocessing. *Multimedia Tools and Applications*.
- Kavakiotis, I., Tsave, O., Salifoglou, A., Maglaveras, N., Vlahavas, I., and Chouvarda, I. (2017). Machine learning and data mining methods in diabetes research. *Computational and Structural Biotechnology Journal*, 15 :104–116. Open Access — CC BY.
- Khanam, J. J. and Foo, S. Y. (2021). A comparison of machine learning algorithms for diabetes prediction. *ICT Express*, 7(4) :432–439. Open Access — CC BY-NC-ND.
- Lv, K., Cui, C., Fan, R., Zha, X., Wang, P., Zhang, J., Zhang, L., Ke, J., Zhao, D., Cui, Q., and Yang, L. (2023). Detection of diabetic patients in people with normal fasting glucose using machine learning. *BMC Medicine*, 21(1) :342.
- Saihood, Q. and Sonuç, E. (2023). A practical framework for early detection of diabetes using ensemble machine learning models. *Turkish Journal of Electrical Engineering and Computer Sciences*, 31(4) :722–740.

- Sisodia, D. and Sisodia, D. S. (2018). Prediction of diabetes using classification algorithms. *Procedia Computer Science*, 132 :1578–1585. Open Access — CC BY-NC-ND.
- Wee, B., Sivakumar, S., Lim, K., Wong, W., and Juwono, F. (2024). Diabetes detection based on machine learning and deep learning approaches. *Multimedia Tools and Applications*, 83 :24153–24185. Open Access via PMC.
- Zou, Q., Qu, K., Luo, Y., Yin, D., Ju, Y., and Tang, H. (2018). Predicting diabetes mellitus with machine learning techniques. *Frontiers in Genetics*, 9 :515. Open Access — CC BY.

ANNEXES